

XII SEMINARIO DE ESTADÍSTICA APLICADA
III ESCUELA DE VERANO
VII COLOQUIO REGIONAL DE ESTADÍSTICA

INTRODUCCIÓN AL ANÁLISIS DE DATOS
MULTIVARIADOS EN CIENCIAS SOCIALES

Profesor

ELKIN CASTAÑO V.

Facultad de Ciencias, Universidad Nacional de Colombia,
Medellín

Facultad de Ciencias Económicas, Universidad de
Antioquia

CONTENIDO

Capítulo 1. Aspectos Básicos del Análisis Multivariado

Capítulo 2. Vectores y Matrices Aleatorias

Capítulo 3. La Distribución Normal Multivariada

Capítulo 4. Análisis de Componentes Principales

Capítulo 5. Análisis de Factor

CAPÍTULO 1.

ASPECTOS BÁSICOS DEL ANÁLISIS MULTIVARIADO

1. INTRODUCCIÓN

- La investigación científica es un proceso iterativo aprendizaje
 - Los objetivos relacionados con la explicación de un fenómeno físico o social deben ser especificados y probados por medio de la consecución y el análisis de los datos.
 - A su vez, el análisis de los datos generalmente sugerirá modificaciones a la explicación del fenómeno: se agregarán o suprimirán variables.
- La complejidad de la mayoría de los fenómenos exigen que el investigador recoja información sobre muchas variables diferentes.
- El Análisis de datos multivariados proporciona al investigador métodos para analizar esta clase de datos:

➤ Métodos de reducción de datos

Tratan de obtener representaciones de los datos en forma tan simple como sea posible, sin sacrificar información.

➤ Métodos de Ordenamiento y agrupación

Tratan de crear grupos de objetos o de variables que sean similares.

Alternativamente, tratan de generar reglas para clasificar objetos dentro de grupos bien definidos.

➤ Métodos para investigar las relaciones de dependencia entre las variables, pues generalmente las relaciones entre las variables son de interés.

➤ Métodos de predicción

Establecidas las relaciones de las variables, se trata de predecir los valores de una o más variables sobre la base de las observaciones de las demás variables.

➤ Construcción y pruebas de hipótesis

Tratan de validar supuestos o reforzar convicciones a priori.

2. LOS DATOS Y SU ORGANIZACIÓN

- Tipos de datos: Los datos recolectados pueden ser generados por:
 - Experimentación: a través del diseño experimental
 - Observación: se recoge la información existente
- Presentación de los datos: su objetivo es facilitar el análisis
 - Tablas
 - Arreglos matriciales
 - Medidas resúmenes o descriptivas
 - Gráficos
- Tablas

Sea x_{jk} el valor que toma la k -ésima variable sobre el j -ésimo objeto (o individuo o unidad experimental). Si se toman n mediciones sobre p variables de interés, el conjunto de datos puede ser presentado como

Objeto	var 1	Var 2	...	Var k	...	Var p
1	x_{11}	x_{12}	...	x_{1k}	...	x_{1p}
2	x_{21}	x_{22}	...	x_{2k}	...	x_{2p}
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$
j	x_{j1}	x_{j2}	...	x_{jk}	...	x_{jp}
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$
p	x_{n1}	x_{n2}	...	x_{nk}	...	x_{np}

- Arreglos matriciales

Los datos también pueden ser presentados usando arreglos matriciales:

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1k} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2k} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots & & \vdots \\ x_{j1} & x_{j2} & \cdots & x_{jk} & \cdots & x_{jp} \\ \vdots & \vdots & & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nk} & \cdots & x_{np} \end{bmatrix}$$

- Estadísticas descriptivas:

- Los conjuntos de datos generalmente son voluminosos.
- Esto es un serio obstáculo para extraer información relevante visualmente.
- Mucha de la información contenida en X puede ser evaluada por medio de medidas que describen cuantitativamente

ciertas características de los datos: localización, dispersión, correlación, simetría, curtosis.

La media aritmética o media muestral: es una medida de localización. Para los datos de la i -ésima variable se define como

$$\bar{x}_i = \frac{1}{n} \sum_{j=1}^n x_{ji}$$

La varianza muestral: Es una medida de dispersión. Para los datos de la i -ésima variable se define como

$$s_i^2 = \frac{1}{n} \sum_{j=1}^n (x_{ji} - \bar{x}_i)^2$$

Observación: Algunos autores definen la varianza muestral usando $n-1$ en lugar de n en el denominador. Existen razones teóricas para hacerlo, especialmente cuando n es pequeño.

La desviación estándar muestral: Es otra medida de dispersión. Tiene la ventaja de que posee las mismas unidades de medición de los datos. Para los datos de la i -ésima variable se define como

$$s_i = +\sqrt{s_i^2}$$

Covarianza muestral: es una medida de asociación lineal entre los datos de dos variables. Para los datos de la i-ésima y k-ésima variable se define como

$$s_{ik} = \frac{1}{n} \sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k)$$

Interpretación:

$s_{ik} > 0$ indica una asociación lineal positiva entre los datos de las variables

$s_{ik} < 0$ indica una asociación lineal negativa entre los datos de las variables

$s_{ik} = 0$ indica que no hay una asociación lineal entre los datos de las variables

Observación: como la varianza muestral es la covarianza muestral entre los datos de la i-ésima variable con ella misma, algunas veces se denotará como s_{ii}

Correlación muestral: Es otra medida de asociación lineal. Para los datos de la i-ésima y k-ésima variable se define como

$$r_{ik} = \frac{s_{ik}}{\sqrt{s_{ii}} \sqrt{s_{kk}}}$$

A diferencia de la covarianza muestral, que no indica cuál es la fortaleza de la relación lineal, la correlación está acotada entre -1 y 1.

Propiedades de r_{ik} :

1) $|r_{ik}| \leq 1$

$r_{ik}=1$ indica que hay una asociación lineal positiva y perfecta entre los datos de las variables. Los datos caen sobre una línea recta de pendiente positiva.

$0 < r_{ik} < 1$ indica que hay una asociación lineal positiva imperfecta entre los datos de las variables. Los datos caen alrededor de una línea recta de pendiente positiva.

$r_{ik}=-1$ indica que hay una asociación lineal negativa y perfecta entre los datos de las variables. Los datos caen sobre una línea recta de pendiente negativa.

$-1 < r_{ik} < 0$ indica que hay una asociación lineal negativa imperfecta entre los datos de las variables. Los datos caen alrededor de una línea recta de pendiente negativa.

$r_{ik} = 0$ indica que no hay una asociación lineal entre los datos de las variables.

2) Considere las versiones estandarizadas de las variables x_i y x_k

$$z_{ji} = \frac{x_{ji} - \bar{x}_i}{\sqrt{s_{ii}}} \quad \text{y} \quad z_{jk} = \frac{x_{jk} - \bar{x}_k}{\sqrt{s_{kk}}}$$

Entonces r_{ik} es la covarianza muestral entre z_{ji} y z_{jk} .

3) Considere las transformaciones

$$y_{ji} = ax_{ji} + b$$

$$y_{jk} = cx_{jk} + d$$

Entonces la correlación muestral entre x_{ji} y x_{jk} es la misma que la que hay entre y_{ji} y y_{jk} , dado que a y c tengan el mismo signo.

4) s_{ik} y r_{ik} solamente informan sobre la existencia o no de una asociación lineal.

5) s_{ik} y r_{ik} son muy sensibles a la existencia de datos atípicos (outliers). Cuando existen observaciones sospechosas, es recomendable calcularlas con y sin dichas observaciones.

Coefficiente de asimetría muestral: es una medida que describe la asimetría de la distribución de los datos con respecto a la media muestral. Se define como:

$$sk(x_i) = \frac{\sqrt{n} \sum_{j=1}^n (x_{ji} - \bar{x}_i)^3}{\left[\sum_{j=1}^n (x_{ji} - \bar{x}_i)^2 \right]^{3/2}}$$

Cuando los datos proceden de una distribución simétrica, como la distribución normal, $sk(x_i) \simeq 0$

Coefficiente de curtosis muestral: es una medida que describe el comportamiento en las colas de la distribución de los datos. Se define como

$$k(x_i) = \frac{n \sum_{j=1}^n (x_{ji} - \bar{x}_i)^4}{\left[\sum_{j=1}^n (x_{ji} - \bar{x}_i)^2 \right]^2}$$

Cuando los datos proceden de una distribución como la normal, $k(x_i) \approx 3$.

ARREGLOS BASADOS EN ESTADÍSTICAS DESCRIPTIVAS

- Para las medias muestrales: El vector de media muestral se define como

$$\bar{x} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix}$$

- Para las varianzas y covarianzas muestrales: La matriz de varianza y covarianza muestral, o matriz de covarianza muestral, se define como

$$S = \begin{bmatrix} s_{11} & s_{12} & \dots & s_{1p} \\ s_{12} & s_{22} & \dots & s_{2p} \\ \vdots & \vdots & & \vdots \\ s_{1p} & s_{2p} & \dots & s_{pp} \end{bmatrix}$$

S es una matriz simétrica.

- Para las correlaciones muestrales: La matriz de correlaciones muestral se define como

$$R = \begin{bmatrix} 1 & r_{12} & \dots & r_{1p} \\ r_{12} & 1 & \dots & r_{2p} \\ \vdots & \vdots & & \vdots \\ r_{1p} & r_{2p} & \dots & 1 \end{bmatrix}$$

R es una matriz simétrica.

Ejemplo: Lectura de datos en R y cálculo de arreglos muestrales.

Datos sobre 8 variables para 22 compañías de servicio público.

X₁: Cargo fijo

X₂: Tasa de retorno del capital

X₃: Costo por kilovatio

X₄: Factor anual de carga

X₅: Crecimiento del pico de la demanda desde 1964.

X₆: Ventas

X₇: Porcentaje de generación nuclear

X₈: Costo total de combustible

Empleo del programa R

```
# lectura de los datos desde un archivo de texto con nombres de las variables
publ_util<-read.table("c:/unal/datos/j-wdata/t12-5_sin.dat", header = TRUE)
```

```
# visualización de los datos leídos
publ_util
```

```
# asignación de nombres a las variables: X1, X2, ....
attach(publ_util)
```

```
# obtención del vector de media muestral
```

```

medias<-mean(publ_util)
medias

# obtención de la matriz de covarianza muestral
mat_cov<-cov(publ_util)
mat_cov

# obtención de la matriz de correlación muestral
mat_cor<-cor(publ_util)
mat_cor

# obtención del coeficiente de asimetría muestral
skewness=function(x) {
m3=mean((x-mean(x))^3)
skew=m3/(sd(x)^3)
skew}
skewness(X1)

# obtención del coeficiente de curtosis muestral
kurtosis=function(x) {
m4=mean((x-mean(x))^4)
kurt=m4/(sd(x)^4)
kurt}
kurtosis(X1)

```

Observación: Los coeficientes de asimetría y curtosis muestrales también se pueden calcular usando librerías como **moments**, **e1071** y **fEcofin**.

RESULTADOS:

TABLA DE DATOS

	X1	X2	X3	X4	X5	X6	X7	X8
1	1.06	9.2	151	54.4	1.6	9077	0.0	0.628
2	0.89	10.3	202	57.9	2.2	5088	25.3	1.555
3	1.43	15.4	113	53.0	3.4	9212	0.0	1.058
4	1.02	11.2	168	56.0	0.3	6423	34.3	0.700
5	1.49	8.8	192	51.2	1.0	3300	15.6	2.044
6	1.32	13.5	111	60.0	-2.2	11127	22.5	1.241
7	1.22	12.2	175	67.6	2.2	7642	0.0	1.652
8	1.10	9.2	245	57.0	3.3	13082	0.0	0.309
9	1.34	13.0	168	60.4	7.2	8406	0.0	0.862
10	1.12	12.4	197	53.0	2.7	6455	39.2	0.623
11	0.75	7.5	173	51.5	6.5	17441	0.0	0.768
12	1.13	10.9	178	62.0	3.7	6154	0.0	1.897
13	1.15	12.7	199	53.7	6.4	7179	50.2	0.527
14	1.09	12.0	96	49.8	1.4	9673	0.0	0.588

15	0.96	7.6	164	62.2	-0.1	6468	0.9	1.400
16	1.16	9.9	252	56.0	9.2	15991	0.0	0.620
17	0.76	6.4	136	61.9	9.0	5714	8.3	1.920
18	1.05	12.6	150	56.7	2.7	10140	0.0	1.108
19	1.16	11.7	104	54.0	-2.1	13507	0.0	0.636
20	1.20	11.8	148	59.9	3.5	7287	41.1	0.702
21	1.04	8.6	204	61.0	3.5	6650	0.0	2.116
22	1.07	9.3	174	54.3	5.9	10093	26.6	1.306

MEDIAS MUESTRALES

X1	X2	X3	X4
1.114091	10.736364	168.181818	56.977273
X5	X6	X7	X8
3.240909	8914.045455	12.000000	1.102727

MATRIZ DE COVARIANZA MUESTRAL

	X1	X2	X3	X4
X1	0.034044372	0.2661299	-0.7812554	-6.752165e-02
X2	0.266129870	5.0357576	-32.1259740	-8.643723e-01
X3	-0.781255411	-32.1259740	1696.7272727	1.843290e+01
X4	-0.067521645	-0.8643723	18.4329004	1.990184e+01
X5	-0.149080087	-1.8201299	55.9207792	4.657359e-01
X6	-99.346385281	-76.6160173	4092.5151515	-4.560037e+03
X7	0.138809524	7.9676190	79.3095238	-1.229762e+01
X8	-0.001372165	-0.4088848	0.1195758	1.204446e+00
	X5	X6	X7	X8
X1	-0.14908009	-9.934639e+01	1.388095e-01	-1.372165e-03
X2	-1.82012987	-7.661602e+01	7.967619e+00	-4.088848e-01
X3	55.92077922	4.092515e+03	7.930952e+01	1.195758e-01
X4	0.46573593	-4.560037e+03	-1.229762e+01	1.204446e+00
X5	9.72348485	1.952874e+03	-1.001429e+00	-1.236926e-02
X6	1952.87424242	1.260239e+07	-2.227602e+04	-1.106557e+03
X7	-1.00142857	-2.227602e+04	2.819686e+02	-1.728324e+00
X8	-0.01236926	-1.106557e+03	-1.728324e+00	3.092451e-01

MATRIZ DE CORRELACIÓN MUESTRAL

	X1	X2	X3	X4
X1	1.00000000	0.642744766	-0.102793192	-0.08203019
X2	0.64274477	1.00000000	-0.347550467	-0.08634194
X3	-0.10279319	-0.347550467	1.00000000	0.10030926

X4	-0.08203019	-0.086341943	0.100309264	1.00000000
X5	-0.25911109	-0.260111168	0.435367718	0.03347975
X6	-0.15167116	-0.009617468	0.027987098	-0.28793559
X7	0.04480188	0.211444212	0.114661857	-0.16416254
X8	-0.01337310	-0.327655318	0.005220183	0.48550006
	X5	X6	X7	X8
X1	-0.259111089	-0.151671159	0.04480188	-0.013373101
X2	-0.260111168	-0.009617468	0.21144421	-0.327655318
X3	0.435367718	0.027987098	0.11466186	0.005220183
X4	0.033479746	-0.287935594	-0.16416254	0.485500063
X5	1.000000000	0.176415568	-0.01912532	-0.007133152
X6	0.176415568	1.000000000	-0.37368952	-0.560526327
X7	-0.019125318	-0.373689523	1.00000000	-0.185085916
X8	-0.007133152	-0.560526327	-0.18508592	1.000000000

COEFICIENTE DE ASIMETRÍA MUESTRAL DE x_1

-0.01711117

COEFICIENTE DE CURTOSIS MUESTRAL DE x_1

2.785947


• Gráficos

Los gráficos son ayudas importantes en el análisis de los datos. Aunque es imposible graficar simultáneamente los valores de todas las variables en el análisis y estudiar su configuración, los gráficos de las variables individuales y de pares de variables son muy informativos.


➤ Gráficos para variables individuales:

Sirven para conocer las distribuciones marginales de los datos para cada variable. Entre ellos se encuentran:


Gráficos de puntos: recomendados para muestras pequeñas.



Gráficos de cajas: recomendados para muestras moderadas o grandes. Sean Q_1 y Q_3 los cuartiles inferior y superior de la distribución de una variable aleatoria, y sea $IQR = Q_3 - Q_1$ el rango intercuartil. El gráfico de cajas es un gráfico esquemático de la distribución de la variable aleatoria, como se ilustra a continuación. Se compara con el caso de que la distribución teórica sea una normal.




Para los datos de la variable X_1 del ejemplo,



Los datos que caen más a la izquierda de $Q_1 - 1.5 * IQR$ y más a la derecha de $Q_3 + 1.5 * IQR$ son considerados datos atípicos o inusuales.


Histogramas: recomendados para muestras moderadas o grandes.




➤ **Gráficos para cada par de variables:**

Son utilizados para estudiar distribución de los datos para 2 variables. Dan indicaciones sobre la orientación de los datos en el plano cartesiano y la asociación que hay entre ellos. Son llamados diagramas de dispersión.


Hay varias clases diagramas de dispersión, por ejemplo:



b) Con marginales como diagramas de puntos




c) Con marginales como gráficos de cajas



El efecto de observaciones inusuales sobre la correlación muestral


Frecuentemente algunas observaciones de la muestra tienen un efecto considerable en el cálculo de la correlación muestral.

Considere el gráfico de dispersión para las variables X_1 y X_2 .



El coeficiente de correlación muestral es $r_{12}=0.643$

Ahora considere el gráfico de dispersión en el cual el tamaño del punto está relacionado con el cambio que tiene el coeficiente de correlación muestral cuando la observación correspondiente a ese punto es eliminada.





Los resultados muestran que al eliminar la observación denominada “consolid”, el coeficiente de correlación muestral tiene un cambio mayor de 0.10.


El coeficiente calculado sin esta observación es 0.836. Entonces su eliminación produce un cambio positivo de 0.193, el cual corresponde a una variación porcentual del 30%!

➤ Gráficos para tres variables: Diagramas de dispersión tridimensionales

Son utilizados para estudiar los aspectos tridimensionales de los datos. Generalmente estos gráficos permiten rotación.

El siguiente ejemplo presenta el diagrama de dispersión tridimensional para X_1 , X_2 y X_3 con tres rotaciones.







➤ **Matrices de dispersión o múltiples diagramas de dispersión:**

Presentan conjuntamente todos los diagramas de dispersión de los datos para cada par variables. Se pueden construir varias clases de matrices de dispersión, dependiendo del contenido en su diagonal. Por ejemplo:


a) con diagramas de puntos en la diagonal




a) con gráficos de cajas en la diagonal



c) con histogramas en la diagonal



d) con histogramas suavizados (curvas Kernel) en la diagonal




➤ **Representaciones pictóricas de datos multivariados:**

Son imágenes que representan los valores de tres o más variables medidas para cada individuo, objeto o unidad experimental. A diferencia de los gráficos anteriores, no están diseñadas para transmitir información numérica absoluta. En general, su objetivo es ayudar a reconocer o observaciones similares.

Cuando se usan estos gráficos, se recomienda que todas las variables estén medidas en la misma escala. Si no es así, se deben emplear los datos estandarizados.

Gráficos de estrellas:

Suponga que los datos consisten de observaciones sobre $p \geq 2$ variables. Se obtienen de la siguiente manera. En dos dimensiones se construyen círculos de radio fijo con p rayos igualmente espaciados emanando del centro del círculo. Las longitudes de los rayos representan los valores de las variables.





Curvas de Andrews:

Es un método potente para identificar agrupamientos de observaciones. Las curvas de Andrews son las componentes de Fourier de los datos y el resultado para cada observación es una onda formada por funciones seno y coseno de sus componentes. Se construyen de la siguiente forma:

$$f_{x_j}(t) = \frac{x_{j1}}{\sqrt{2}} + x_{j2}\sin(t) + x_{j3}\cos(t) + x_{j4}\sin(2t) + x_{j5}\cos(2t) + \dots$$


donde $-\pi < t < \pi$.




Caras de Chernoff:

Es otra forma efectiva de agrupar datos multivariados, particularmente para un procesamiento de la memoria de largo plazo. Fueron introducidas por Chernoff (1973), quien usa varias características de la cara para representar los datos de las variables. Algunos paquetes estadísticos permiten representar hasta 20 variables (SYSTAT), mientras que R permite asignar 18 variables. Las características que SYSTAT permite asignar son:


- 1 Curvatura de la boca
- 2 Ángulo de la ceja
- 3 Amplitud de la nariz
- 4 Longitud de la nariz
- 5 Longitud de la boca
- 6 Altura del centro de la boca
- 7 Separación de los ojos
- 8 Altura del centro de los ojos
- 9 Inclinación de los ojos
- 10 Excentricidad de los ojos
- 11 Longitud media de los ojos
- 12 Posición de las pupilas
- 13 Altura de la ceja
- 14 Longitud de la ceja
- 15 Altura de la cara
- 16 Excentricidad de la elipse superior de la cara
- 17 Excentricidad de la elipse inferior de la cara
- 18 Nivel de las orejas
- 19 Radio de las orejas
- 20 Longitud del cabello



Identificación de casos similares (grupos)



Caras Asimétricas: Flury y Riedwyl (1981) proponen una nueva cara en la cual los parámetros del lado derecho de la cara pueden variar independientemente de los parámetros del lado izquierdo. Esta cara puede ser aplicada de la misma manera que las caras de Chernoff y permite representar hasta 36 variables, en lugar de las 18 variables originales de Chernoff. Para dibujar estas caras se puede emplear el programa de uso libre FACEPLOT.



Lecturas recomendadas:

Jacob, R. J. K. (1983). Investigating the space of Chernoff faces. *Recent advances in statistics: A festschrift in honor of Herman Chernoff's sixtieth birthday*. M. H. Rzv, J.

Wang, P. C., ed. (1978). *Graphical representation of multivariate data*. New York: Academic Press.

Wilkinson, L (2007) “Cognitive Science and Graphic Design’, SYSTAT® 12 Graphics, SYSTAT Software, Inc.

Wilkinson, L. (1982). An experimental evaluation of multivariate graphical point representations. *Human Factors in Computer Systems: Proceedings*. Gaithersburg, Md. 202–209.

Empleo del programa R

```
# lectura de los datos desde un archivo de texto
publ_util<-read.table("c:/unal/datos/j-wdata/t12-5.dat", header = TRUE)

# visualización de los datos leídos
publ_util

# asignación de nombres a las variables: V1, V2, ....
attach(publ_util)

# gráfico de puntos
stripchart(X1, method="stack")

# histograma
hist(X1)

# gráfico de caja
boxplot(X1)

# matriz de dispersión
# pegado de las variables en la matriz X
X<-as.matrix(cbind(X1, X2, X3, X4, X5, X6, X7,X8))
pairs(X)

# gráfico de estrellas
# estandarización de las variables
X1s=(X1-mean(X1))/sd(X1)
X2s=(X2-mean(X2))/sd(X2)
X3s=(X3-mean(X3))/sd(X3)
X4s=(X4-mean(X4))/sd(X4)
X5s=(X5-mean(X5))/sd(X5)
X6s=(X6-mean(X6))/sd(X6)
X7s=(X7-mean(X7))/sd(X7)
X8s=(X8-mean(X8))/sd(X8)
```

```
# pegado de las variables estandarizadas en la matriz Xs
Xs<-as.matrix(cbind(X1s, X2s, X3s, X4s, X5s, X6s, X7s,X8s))

# los nombres de las observaciones son colocadas en el vector obs
obs=as.vector(X9)
stars(Xs, labels = obs, key.loc=c(10,1.8))


# invocar la librería aplpack para los gráficos de caras
library(aplpack)

# gráficos de caras
faces(Xs, labels = obs)
```

3. EL CONCEPTO DE DISTANCIA ESTADÍSTICA

- Casi todas las técnicas del análisis multivariado están basadas en el concepto de distancia.
- Distancia Euclidiana: considere el punto $P=(x_1, x_2)$ en el plano. La distancia Euclidiana del origen $(0, 0)$ a P es

$$d(0, P) = \sqrt{x_1^2 + x_2^2} \quad (\text{Teorema de Pitágoras})$$



- El conjunto de todos los puntos P cuya distancia cuadrática a O es la misma, satisface

$$x_1^2 + x_2^2 = c^2, \text{ con } c > 0$$

El lugar geométrico corresponde a la circunferencia.

- En general, si $P=(x_1, x_2, \dots, x_p)$, su distancia euclidiana al origen O es

$$d(0, P) = \sqrt{x_1^2 + x_2^2 + \dots + x_p^2}$$

y el conjunto de todos los puntos P cuya distancia cuadrática a O es la misma, satisface

$$x_1^2 + x_2^2 + \dots + x_p^2 = c^2, \text{ con } c > 0$$


El lugar geométrico de estos puntos corresponde a una hiper-esfera.

- La distancia euclidiana generalmente no es satisfactoria en la mayoría de las aplicaciones estadística. El problema es que cada coordenada contribuye igualmente en su cálculo. Esto supone:

- Que todos los puntos pueden ocurrir igualmente
 - Que no existen relaciones entre ellos.
-
- Sin embargo, los datos generados por diferentes variables aleatorias pueden tener diferente variabilidad y estar relacionados.
 - Debemos desarrollar una distancia que tenga en cuenta estas características.

Supongamos que tenemos n pares de medidas para dos variables x_1 y x_2 .

Caso 1: Las mediciones varían independientemente, pero la variabilidad de x_1 es mayor que la de x_2 .



Una manera de proceder a calcular la distancia es “estandarizar” las coordenadas, es decir, se obtienen

$$x_1^* = \frac{x_1}{\sqrt{s_{11}}} \quad \text{y} \quad x_2^* = \frac{x_2}{\sqrt{s_{22}}}$$


Las nuevas coordenadas tienen la misma variabilidad y para calcular la distancia se puede usar la distancia Euclidiana. Entonces, la distancia *estadística* de un punto $P=(x_1, x_2)$ al origen $(0, 0)$ es

$$d(0, P) = \sqrt{(x_1^*)^2 + (x_2^*)^2} = \sqrt{\frac{x_1^2}{s_{11}} + \frac{x_2^2}{s_{22}}}$$

El conjunto de todos los puntos P cuya distancia cuadrática a O es la misma, satisface

$$\frac{x_1^2}{s_{11}} + \frac{x_2^2}{s_{22}} = c^2 \quad \text{con } c > 0$$

El lugar geométrico corresponde a una elipse centrada en el origen y cuyos ejes mayor y menor coinciden con los ejes de coordenadas.



La distancia anterior puede ser generalizada para calcular la distancia de un punto cualquiera $P=(x_1, x_2)$ a un punto fijo $Q=(y_1, y_2)$. Si las coordenadas varían independientemente unas de otras, la distancia estadística de P a Q esta dada por,

$$d(P, Q) = \sqrt{\frac{(x_1 - y_1)^2}{s_{11}} + \frac{(x_2 - y_2)^2}{s_{22}}}$$

La extensión a más de dos dimensiones es directa. Si $P=(x_1, x_2, \dots, x_p)$ y $Q=(y_1, y_2, \dots, y_p)$. Si las coordenadas varían independientemente unas de otras, la distancia estadística de P a Q fijo, está dada por


$$d(P, Q) = \sqrt{\frac{(x_1 - y_1)^2}{s_{11}} + \frac{(x_2 - y_2)^2}{s_{22}} + \dots + \frac{(x_p - y_p)^2}{s_{pp}}}$$

El lugar geométrico corresponde a una hiperelipsoide centrada en Q y cuyos ejes mayor y menor son paralelos a los ejes de coordenadas.

Observaciones:

1. La distancia de P al origen O se obtiene haciendo $y_1=y_2=\dots=y_p=0$.
2. Si $s_{11}=s_{22}=\dots=s_{pp}$, la fórmula de la distancia Euclidiana es apropiada.

Caso 2. Las variabilidades de las mediciones sobre las variables x_1 y x_2 son diferentes y están correlacionadas.
Considere el siguiente gráfico



Se observa que si rotamos el sistema original de coordenadas a través del ángulo θ , mantenido los puntos fijos y denominando los nuevos ejes como $\tilde{x}_1$ y $\tilde{x}_2$, la dispersión en términos de los nuevos ejes es similar al caso 1. Esto sugiere, que para calcular la distancia estadística del punto $P=(\tilde{x}_1, \tilde{x}_2)$ a origen $O=(0, 0)$ se puede usar

$$d(0, P) = \sqrt{\frac{\tilde{x}_1^2}{\tilde{s}_{11}} + \frac{\tilde{x}_2^2}{\tilde{s}_{22}}}$$

donde las $\tilde{s}_{ii}$ son varianzas muestrales de los datos $\tilde{x}_1$ y $\tilde{x}_2$.

La relación entre las coordenadas originales y las rotadas es

$$\tilde{x}_1 = x_1 \cos(\theta) + x_2 \sin(\theta)$$

$$\tilde{x}_2 = -x_1 \sin(\theta) + x_2 \cos(\theta)$$

Dadas estas relaciones, podemos expresar la distancia de P al origen O en términos de las coordenadas originales como,

$$d(0, P) = \sqrt{a_{11}x_1^2 + a_{22}x_2^2 + 2a_{12}x_1x_2}$$

donde a_{11} , a_{22} y a_{12} son constantes tales que la distancia es no negativa para todos los posibles valores de x_1 y x_2 .


En general, la distancia estadística de un punto $P=(x_1, x_2)$ a un punto fijo $Q=(y_1, y_2)$, es

$$d(0, P) = \sqrt{a_{11}(x_1 - y_1)^2 + a_{22}(x_2 - y_2)^2 + 2a_{12}(x_1 - y_1)(x_2 - y_2)}$$

El conjunto de puntos $P=(x_1, x_2)$ que tienen la misma distancia cuadrática al punto fijo $Q=(y_1, y_2)$ satisfacen que

$$a_{11}(x_1 - y_1)^2 + a_{22}(x_2 - y_2)^2 + 2a_{12}(x_1 - y_1)(x_2 - y_2) = c^2$$

El lugar geométrico de estos puntos corresponde a una elipse centrada en Q y cuyos ejes mayor y menor son paralelos a los ejes rotados.



La generalización de las fórmulas a p dimensiones es directa. Sea $P=(x_1, x_2, \dots, x_p)$ un punto cuyas coordenadas representan variables que están correlacionadas y sujetas a diferente variabilidad, y sea $Q=(y_1, y_2, \dots, y_p)$ un punto. Entonces la distancia estadística de P a Q está dada por

$$d(0, P) = \sqrt{a_{11}(x_1 - y_1)^2 + a_{22}(x_2 - y_2)^2 + \dots + a_{pp}(x_p - y_p)^2 + 2a_{12}(x_1 - y_1)(x_2 - y_2) + 2a_{13}(x_1 - y_1)(x_3 - y_3) + \dots + 2a_{p-1,p}(x_{p-1} - y_{p-1})(x_p - y_p)}$$

donde las constantes a_{ik} son tales que las distancias son siempre no negativas.

El lugar geométrico de todos los puntos P cuya distancia cuadrática a Q es la misma es una hiperelipsoide.

Observaciones:

1. Si las constantes a_{ik} son llevadas a una matriz simétrica de $p \times p$ de la forma

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{12} & a_{22} & \dots & a_{2p} \\ \vdots & \vdots & & \vdots \\ a_{1p} & a_{2p} & \dots & a_{pp} \end{bmatrix}$$

Entonces la distancia estadística de P a Q, se puede escribir como,

$$d(P, Q) = \sqrt{(x - y)' A (x - y)}$$

donde $x - y = \begin{bmatrix} x_1 - y_1 \\ x_2 - y_2 \\ \vdots \\ x_p - y_p \end{bmatrix}.$


2. Para que la distancia estadística sea no negativa, la matriz A debe ser definida positiva.

3. Cuando $A = S^{-1}$, la distancia estadística definida como

$$d(P, Q) = \sqrt{(x - y)' S^{-1} (x - y)}$$

Es llamada la distancia muestral de Mahalanobis y juega un papel central en el análisis multivariado.

La necesidad de usar la distancia estadística en lugar de la Euclidiana se ilustra heurísticamente a continuación. El siguiente gráfico presenta un grupo (cluster) de observaciones cuyo centro de gravedad (el vector de media muestrales) está señalado por el punto Q.



La distancia Euclidiana del punto Q al punto P es mayor que la distancia de Q a O. Sin embargo, P es más parecido a los puntos en el grupo que O. Si tomamos la distancia estadística

de Q a P, entonces Q estará más cerca de P que de O, lo cual parece razonable dada la naturaleza de gráfico de dispersión.

CAPÍTULO 2.

VECTORES Y MATRICES ALEATORIAS

- Vector aleatorio: es un vector cuyas componentes son variables aleatorias.
- Matriz aleatoria: es una matriz cuyas componentes son variables aleatorias.
- Notación: Si $\mathbf{X}$ es una matriz de $n \times p$ cuyos elementos son X_{ij} , se denota como

$$\mathbf{X} = [X_{ij}]$$

- Valor esperado de una matriz aleatoria:

$$E(\mathbf{X}) = \begin{bmatrix} E(X_{11}), E(X_{12}), \dots, E(X_{1p}) \\ E(X_{21}), E(X_{22}), \dots, E(X_{2p}) \\ \vdots \quad \quad \quad \vdots \quad \quad \quad \vdots \\ E(X_{n1}), E(X_{n2}), \dots, E(X_{np}) \end{bmatrix}$$

donde, para cada elemento de la matriz

$$E(X_{ij}) = \begin{cases} \int_R x_{ij} f_{ij}(x_{ij}) dx_{ij} & \text{para } X_{ij} \text{ continua} \\ \sum_{\substack{\text{todos} \\ x_{ij}}} x_{ij} p_{ij}(x_{ij}) & \text{para } X_{ij} \text{ discreta} \end{cases}$$

- Vectores de media

Suponga que $X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix}$ es un vector aleatorio de $p \times 1$.

Entonces,

- Cada variable aleatoria X_i tiene su propia distribución de probabilidades marginal la cual permite estudiar su comportamiento.

Media marginal de X_i :

$$\mu_i = E(X_i) = \begin{cases} \int_R x_i f_i(x_i) dx_i & \text{para } X_i \text{ continua} \\ \sum_{\substack{\text{todos} \\ x_i}} x_i p_i(x_i) & \text{para } X_i \text{ discreta} \end{cases}$$

A μ_i se le llama la media poblacional marginal de X_i .

Varianza marginal de X_i :

$$\sigma_i^2 = E(X_i - \mu_i)^2 = \begin{cases} \int_R (x_i - \mu_i)^2 f_i(x_i) dx_i & \text{para } X_i \text{ continua} \\ \sum_{\substack{\text{todos} \\ x_i}} (x_i - \mu_i)^2 p_i(x_i) & \text{para } X_i \text{ discreta} \end{cases}$$

A σ_i^2 se le llama la varianza poblacional marginal de X_i .

- El comportamiento conjunto de cada par de variables aleatorias X_i y X_k está descrito por su función de distribución conjunta.

Una medida de asociación lineal: la covarianza poblacional

$$\sigma_{ik} = E(X_i - \mu_i)(X_k - \mu_k)$$

donde

$$\sigma_{ik} = \begin{cases} \int_R \int_R (x_i - \mu_i)(x_k - \mu_k) f_{ik}(x_i, x_k) dx_i dx_k & \text{para } X_i \text{ y } X_k \text{ continuas} \\ \sum_{\substack{\text{todos} \\ x_i}} \sum_{\substack{\text{todos} \\ x_k}} (x_i - \mu_i)(x_k - \mu_k) p_{ik}(x_i, x_k) & \text{para } X_i \text{ y } X_k \text{ discretas} \end{cases}$$

A σ_{ik} se le llama la covarianza poblacional de X_i y X_k .

Interpretación

$\sigma_{ik} > 0$ indica una asociación lineal positiva entre X_i y X_k .

$\sigma_{ik} < 0$ indica una asociación lineal negativa entre X_i y X_k .

$\sigma_{ik} = 0$ indica que no hay una asociación lineal entre X_i y X_k .

Debido a que la varianza poblacional de X_i es la covarianza poblacional entre X_i y X_i , a veces se denota σ_i^2 como σ_{ii} .

Otra medida de asociación lineal: la correlación

$$\rho_{ik} = \frac{\sigma_{ik}}{\sqrt{\sigma_{ii}} \sqrt{\sigma_{kk}}}$$

Interpretación:

$\rho_{ik}=1$ indica una asociación lineal positiva perfecta entre X_i y X_k .

$0 < \rho_{ik} < 1$ indica una asociación lineal positiva imperfecta entre X_i y X_k . Mientras más cerca de 1 se encuentre, más fuerte es la relación.

$\rho_{ik}=-1$ indica una asociación lineal negativa perfecta entre X_i y X_k .

$-1 < \rho_{ik} < 0$ indica una asociación lineal negativa entre X_i y X_k . Mientras más cerca de -1 se encuentre, más fuerte es la relación.

$\rho_{ik}=0$ indica que no hay una asociación lineal entre X_i y X_k .

- El comportamiento conjunto de las p variables aleatorias $X_1, X_2, \dots, X_p$, está descrita por la función de distribución conjunta o por su función de densidad de probabilidad conjunta $f(x_1, x_2, \dots, x_p)$, si todas las variables aleatorias son continuas.

Las p variables aleatorias continuas son llamadas mutuamente estadísticamente independientes si

$$f(x_1, x_2, \dots, x_p) = f_1(x_1) f_2(x_2) \dots f_n(x_n)$$

Si X_i, X_k son estadísticamente independientes, entonces $\text{Cov}(X_i, X_k) = 0$. Lo contrario no es necesariamente cierto.

Vector de medias poblacional: El vector de $p \times 1$,

$$\mu = E(X) = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix}$$

es llamado el vector de medias poblacional.

La matriz de varianza y covarianza poblacional: La matriz de $p \times p$

$$\Sigma = E(X - \mu)(X - \mu)' = \begin{bmatrix} \sigma_{11}, \sigma_{12}, \dots, \sigma_{1p} \\ \sigma_{21}, \sigma_{22}, \dots, \sigma_{2p} \\ \vdots \quad \vdots \quad \quad \vdots \\ \sigma_{lp}, \sigma_{lp}, \dots, \sigma_{pp} \end{bmatrix}$$

Es llamada la matriz de varianza y covarianza (o de covarianza) poblacional.

La matriz de correlación poblacional: La matriz de $p \times p$

$$\rho = \begin{bmatrix} 1, & \rho_{12}, \dots, \rho_{1p} \\ \rho_{12}, & 1, \dots, \rho_{2p} \\ \vdots & \vdots & \quad \vdots \\ \rho_{lp}, & \rho_{2p}, \dots, & 1 \end{bmatrix}$$

Es llamada la matriz de correlación poblacional.

Relación entre Σ y ρ :

Sea

$$V^{1/2} = \begin{bmatrix} \sqrt{\sigma_{11}} & 0 & \dots & 0 \\ 0 & \sqrt{\sigma_{22}} & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & \sqrt{\sigma_{pp}} \end{bmatrix}$$

Entonces

$$\Sigma = V^{1/2} \rho V^{1/2}$$

y

$$\rho = (V^{1/2})^{-1} \Sigma (V^{1/2})^{-1}$$

• **Vector de Media y la matriz de Covarianza de Combinaciones Lineales**

1. Una sola combinación lineal de las variables del vector aleatorio X. Sea

$$c = \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_p \end{bmatrix}$$

y sea

$$Z_1 = c_1 X_1 + c_2 X_2 + \dots + c_p X_p = c' \mu$$

Entonces,

$$\mu_{Z_1} = E(Z_1) = c_1 \mu_1 + c_2 \mu_2 + \dots + c_p \mu_p = c' \mu$$

$$\text{Var}(Z_1) = \sum_{i=1}^p c_i^2 \sigma_{ii} + \sum_{i=1}^p \sum_{k=1}^p c_i c_k \sigma_{ik} = c' \Sigma c$$

2. q combinaciones lineales de las variables del vector aleatorio X. Sea

$$Z_1 = c_{11}X_1 + c_{12}X_2 + \dots + c_{1p}X_p$$

$$Z_2 = c_{21}X_1 + c_{22}X_2 + \dots + c_{2p}X_p$$

$$\vdots \quad \quad \quad \vdots$$

$$Z_q = c_{q1}X_1 + c_{q2}X_2 + \dots + c_{qp}X_p$$

o,

$$Z = \begin{bmatrix} Z_1 \\ Z_2 \\ \vdots \\ Z_q \end{bmatrix} = \begin{bmatrix} c_{11}, c_{12}, \dots, c_{1p} \\ c_{21}, c_{22}, \dots, c_{2p} \\ \vdots \quad \quad \quad \vdots \\ c_{q1}, c_{q2}, \dots, c_{qp} \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = CX$$

Entonces,

$$\mu_Z = E(Z) = C\mu$$

$$\Sigma_Z = E(Z - \mu_Z)(Z - \mu_Z)' = CVC'$$

Ejemplo. Suponga que $X' = [X_1, X_2]$ es un vector aleatorio con vector de medias $\mu'_X = [\mu_1, \mu_2]$ y matriz de covarianza

$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{bmatrix}$. Encuentre el vector de medias y la matriz de

covarianza del vector $Z = \begin{bmatrix} X_1 - X_2 \\ X_1 + X_2 \end{bmatrix}$.

Observe que $Z = \begin{bmatrix} X_1 - X_2 \\ X_1 + X_2 \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = CX$

Entonces,

$$\mu_Z = E(Z) = C\mu_X = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} = \begin{bmatrix} \mu_1 - \mu_2 \\ \mu_1 + \mu_2 \end{bmatrix}$$

y,

$$\Sigma_Z = Cov(Z) = C\Sigma_X C' = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{bmatrix} \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}$$

$$= \begin{bmatrix} \sigma_{11} - 2\sigma_{12} + \sigma_{22} & \sigma_{11} - \sigma_{22} \\ \sigma_{11} - \sigma_{22} & \sigma_{11} + 2\sigma_{12} + \sigma_{22} \end{bmatrix}$$

CAPÍTULO 3.

1. MUESTRAS ALEATORIAS

- Una observación multivariada consiste de las p mediciones tomadas a una unidad experimental. Para la j -ésima unidad experimental,

$$X_j = \begin{bmatrix} x_{j1} \\ x_{j2} \\ \vdots \\ x_{jp} \end{bmatrix}, j=1,2,\dots,n$$

es la j -ésima observación multivariada.

- Si se eligen n unidades experimentales, antes de observarlas sus valores son aleatorios, y el conjunto completo de ellas puede ser colocado en una matriz aleatoria $\mathbf{X}$ de $n \times p$,

$$\mathbf{X} = \begin{bmatrix} X_{11}, X_{12}, \dots, X_{1p} \\ X_{21}, X_{22}, \dots, X_{2p} \\ \vdots \\ X_{n1}, X_{n2}, \dots, X_{np} \end{bmatrix} = \begin{bmatrix} \mathbf{X}'_1 \\ \mathbf{X}'_2 \\ \vdots \\ \mathbf{X}'_n \end{bmatrix}$$

donde,

$$\mathbf{X}_j = \begin{bmatrix} X_{j1} \\ X_{j2} \\ \vdots \\ X_{jp} \end{bmatrix}, j=1,2,\dots,n$$

es la j -ésima observación multivariada.

- **Muestra aleatoria:** si los vectores $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$, son observaciones independientes de una misma distribución conjunta $f(\mathbf{x})=f(x_1, x_2, \dots, x_p)$, entonces $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ es llamada una muestra aleatoria de tamaño n de la población $f(\mathbf{x})$.

Observaciones:

1) Las mediciones de las p variables en una sola unidad experimental (o ensayo), generalmente estarán correlacionadas. Sin embargo, las mediciones para diferentes unidades deben ser independientes.

2) La independencia entre unidades experimentales puede no cumplirse cuando las variables son observadas en el tiempo. Por ejemplo, en un conjunto de precios de acciones o de indicadores económicos. La violación del supuesto de independencia puede tener un serio impacto sobre la calidad de la inferencia estadística.

- Si $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ es una muestra aleatoria de una distribución conjunta con vector de medias μ y matriz de covarianzas Σ , entonces

a) $E(\bar{X}) = \mu$, es decir $\bar{X}$ es un estimador insesgado para μ .

b) $\text{Cov}(\bar{X}) = \frac{1}{n} \Sigma$

c) $E(S_n) = \frac{n-1}{n} \Sigma$, es decir S_n no es un estimador insesgado para Σ .

d) $S = \frac{n}{n-1} S_n = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})(X_j - \bar{X})'$ es un estimador insesgado para Σ .

2. VARIANZA GENERALIZADA

- Para una sola variable, la varianza muestral generalmente se usa para describir la variación de las mediciones de la variable.
- Cuando se observan p variables, una manera de describir su variación es usar la matriz de covarianzas muestral, S .

S contiene p varianzas y $p(p-1)/2$ covarianzas, las cuales describen la variabilidad de los datos de cada variable y la asociación lineal para los datos de cada par de variables.

- Otra generalización de la varianza muestral es llamada la *Varianza Generalizada muestral* definida como,

$$\text{Varianza generalizada muestral} = |S|$$

A diferencia de S , $|S|$ es un solo número.

Interpretación geométrica:


Considere el vector que contiene los datos para la i -ésima variable

$$y_i = \begin{bmatrix} y_{1i} \\ y_{2i} \\ \vdots \\ y_{ni} \end{bmatrix}$$

y el vector de desviaciones con respecto a la media

$$d_i = \begin{bmatrix} y_{1i} - \bar{x}_i \\ y_{2i} - \bar{x}_i \\ \vdots \\ y_{ni} - \bar{x}_i \end{bmatrix}$$

Para $i=1,2$, sean L_{d1} y L_{d2} sus longitudes.



El área del trapezoide es $\|L_{d1} \sin(\theta)\|L_{d2}$

Dado que

$$L_{d_i} = \sqrt{\sum_{j=1}^n (x_{ji} - \bar{x}_i)^2} = \sqrt{(n-1)s_{ii}}, \quad i=1,2$$

y

$$r_{12} = \frac{s_{12}}{\sqrt{s_{11}}\sqrt{s_{22}}} = \cos(\theta)$$

Entonces

$$(\text{Área})^2 = (n-1)^2 |S|$$

o,

$$\text{Varianza Generalizada muestral, } |S| = (n-1)^{-2} (\text{Área})^2$$

Por tanto, la VGM es proporcional al cuadrado del área generada por los vectores de desviaciones.

En general, para p vectores de desviaciones,

$$|S| = (n-1)^{-p} (\text{volumen})^2$$

Es decir, para un conjunto fijo de datos, la VGM es proporcional al cuadrado del volumen generado por los p vectores de desviaciones.

Observaciones:


1) Para una muestra de tamaño fijo, $|S|$ aumenta cuando:

- a) La longitud de cualquier d_i aumenta (o cuando s_{ii} aumenta.

b) Los vectores de desviaciones de longitud fija son movidos hasta que formen ángulos rectos con los demás.

2) Para una muestra de tamaño fijo $|S|$ será pequeña cuando:

- a) Uno de los s_{ii} son pequeños
- b) uno de los vectores cae cerca del hiperplano formado por los otros.
- c) Se dan los dos casos anteriores.



La VGM también tiene interpretación en el gráfico de dispersión p dimensional que representa los datos. Se puede probar que el volumen de la hiper-elipsoide dada por

$$\{x \in \mathbb{R}^p : (x - \bar{x})' S^{-1} (x - \bar{x}) \leq c^2\}$$

Es tal que

$$\text{Volumen}(\{x \in \mathbb{R}^p : (x - \bar{x})' S^{-1} (x - \bar{x}) \leq c^2\}) = k_p |S|^{1/2} c^p$$

Es decir,

$$(\text{Volumen}(\text{hiper-elipsoide}))^2 = \text{constante} |S|$$

Por tanto, un volumen grande (datos muy dispersos) corresponde a una VGM grande.

Observación:


Aunque la VGM tiene interpretaciones intuitivas importantes, sufre de debilidades.

Ejemplo. Interpretación de la varianza generalizada

Suponga se tienen datos para tres vectores aleatorios bidimensionales tales que tienen el mismo vector de media muestral $\bar{x}=[1, 2]$ y sus matrices de covarianza muestrales son

$$S = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}, \quad S = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix} \quad \text{y} \quad S = \begin{bmatrix} 5 & -4 \\ -4 & 5 \end{bmatrix}$$

Los diagramas de dispersión correspondientes son los siguientes:



Estos gráficos muestran patrones de correlación muy diferentes.


Cada matriz de covarianza muestral contiene la información sobre la variabilidad de las variables y la información requerida para calcular el coeficiente de correlación muestral correspondiente. En este caso S captura la orientación y el tamaño del patrón de dispersión.

Sin embargo, la varianza generalizada muestral, $|S|$ da el mismo valor, $|S|=9$ para los tres casos y no proporciona información sobre la orientación del patrón de dispersión. Solamente nos informa que los tres patrones de dispersión tienen aproximadamente la misma área. Por tanto, la varianza generalizada es más fácil de interpretar cuando las muestras que se comparan tienen aproximadamente la misma orientación.

Se puede probar que S contiene la información sobre la orientación y el tamaño del patrón de dispersión a través de sus valores propios y vectores propios:

La dirección de los vectores propios determinan la direcciones de mayor variabilidad del patrón de dispersión de los datos, y valores propios proporcionan información sobre la variabilidad en cada una de estas direcciones.

La siguiente gráfica muestra, para cada patrón de dispersión, las direcciones de mayor variabilidad y el tamaño de ella.



3. LA VGM DETERMINADA POR R.

La VGM, $|S|$, está afectada por las unidades de medición de cada variable.

Por ejemplo, suponga que una s_{ii} es grande o muy pequeña. Entonces, geoméricamente, el correspondiente vector de

desviaciones d_i es muy largo o muy corto, y por tanto será un factor determinante en el cálculo del volumen.

En consecuencia, algunas veces es útil escalar todos los vectores de desviaciones de manera que todos tengan a misma longitud.

Esto se puede hacer reemplazando las observaciones x_{jk} por su valor estandarizado $(x_{jk} - \bar{x}_k)/\sqrt{s_{kk}}$. La matriz de covarianza muestral de las variables estandarizadas es R , que es la matriz de correlación muestral de las variables originales.

Se define,


$$\left(\begin{array}{l} \text{Varianza Generalizada} \\ \text{muestral de las} \\ \text{variables estandarizadas} \end{array} \right) = |R|$$

Puesto que los vectores estandarizados

$$\begin{bmatrix} (x_{1k} - \bar{x}_k)/\sqrt{s_{kk}} \\ (x_{j2} - \bar{x}_k)/\sqrt{s_{kk}} \\ \vdots \\ (x_{nk} - \bar{x}_k)/\sqrt{s_{kk}} \end{bmatrix}$$

para $k=1, 2, \dots, p$, tienen todos a misma longitud $\sqrt{n-1}$, la varianza generalizada muestral de las variables estandarizadas

será grande cuando estos vectores sean aproximadamente perpendiculares y será pequeña cuando dos o más vectores están casi en la misma dirección.



Como para el caso de S , el volumen generado por los vectores de desviaciones de las variables estandarizadas está relacionado con la varianza generalizada como,

$$\left(\begin{array}{l} \text{Varianza Generalizada} \\ \text{muestral de las} \\ \text{variables estandarizadas} \end{array} \right) = |R| = (n-1)^{-p} (\text{volumen})^2$$

Las varianzas generalizadas $|S|$ y $|R|$ están conectadas por medio de la relación

$$|S| = (s_{11}s_{22}\dots s_{pp})|R|$$

Entonces,

$$(n-1)^p |S| = (n-1)^p (s_{11}s_{22}\dots s_{pp}) |R|$$

Lo que implica que el cuadrado del volumen al cuadrado $(n-1)^p |S|$ es proporcional al volumen al cuadrado $(n-1)^p |R|$.

La constante de proporcionalidad es el producto de las varianzas, la cual a su vez es proporcional al producto de las longitudes cuadráticas de las $(n-1)s_{ii}$ de las d_i .

4. OTRA GENERALIZACIÓN DE LA VARIANZA

La *varianza total muestral* se define como

$$\text{varianza total muestral} = s_{11} + s_{22} + \dots + s_{pp}$$

Geométricamente, la varianza total muestral es la suma de los cuadrados de las longitudes de p vectores de desviaciones, dividido por $n-1$. Este criterio no tiene en cuenta la estructura de correlación de los vectores de desviaciones.

CAPÍTULO 4.

LA DISTRIBUCIÓN NORMAL MULTIVARIADA

1. INTRODUCCIÓN


- La generalización a varias dimensional de la densidad normal univariada juega un papel fundamental en el análisis multivariado.
- La importancia de la distribución normal multivariada se basa en su papel dual:
 - Muchos de los fenómenos naturales del mundo real pueden ser estudiados por medio de la distribución normal multivariada.
 - Aunque el fenómeno estudiado no siga este modelo de distribución, las distribuciones de muchos de los estadísticos usados en el análisis multivariado tiene una distribución aproximadamente normal multivariada.

2. LA DENSIDAD NORMAL MULTIVARIADA Y SUS PROPIEDADES

- Recuerde que la distribución normal univariada con media μ y varianza σ^2 tiene una función de densidad de probabilidad dada por:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad -\infty < x < \infty$$

Si X es una variable aleatoria que sigue esta distribución, se denota como $X \sim N(\mu, \sigma^2)$.



En la gráfica, están representadas las áreas bajo la curva dentro de los intervalos $\mu \pm \sigma$ y $\mu \pm 2\sigma$. Estas áreas son probabilidades y en la normal

$$P(\mu - \sigma \leq X \leq \mu + \sigma) = 0.68$$

$$P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) = 0.95$$

- El término en el exponente

$$\left(\frac{x - \mu}{\sigma} \right)^2 = (x - \mu)(\sigma^2)^{-1}(x - \mu)$$

Es la distancia cuadrática de x a μ medida en unidades de desviación estándar. Esta cantidad puede ser generalizada para un vector p -dimensional x de observaciones sobre p variables, como

$$(x - \mu)' \Sigma^{-1}(x - \mu)$$

donde $E(X) = \mu$ y $\text{Cov}(X) = \Sigma$, con Σ simétrica y definida positiva. La expresión $(x - \mu)' \Sigma^{-1}(x - \mu)$ es el cuadrado de la distancia generalizada de x a μ .

- La distribución normal multivariada puede ser obtenida reemplazando la distancia univariada por la distancia generalizada en la densidad de la normal univariada.
- Cuando se hace este reemplazo es necesario cambiar la constante $(2\pi)^{-1/2}(\sigma^2)^{-1/2}$ de la normal univariada por una constante más general de forma tal que el volumen bajo la

superficie de la normal multivariada sea 1. La nueva constante es $(2\pi)^{-p/2} |\Sigma|^{-1/2}$.

- La función de densidad de probabilidad normal multivariada para un vector aleatorio X es

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu)'\Sigma^{-1}(x-\mu)}$$

donde $-\infty < x_i < \infty$, $i=1, 2, \dots, p$.

La distribución normal multivariada se denota como $X \sim N(\mu, \Sigma)$.

Ejemplo. La distribución normal bivariada

Para $p=2$, la distribución normal bivariada tiene vector de medias


$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} \text{ y matriz de covarianza } \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{bmatrix}.$$

La matriz inversa de Σ es

$$\Sigma^{-1} = \frac{1}{\sigma_{11}\sigma_{22} - \sigma_{12}^2} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{12} & \sigma_{11} \end{bmatrix}$$

Reemplazando en la densidad multivariada general y haciendo operaciones, se obtiene que la densidad de la normal bivariada es

$$f(x_1, x_2) = \frac{1}{2\pi\sqrt{\sigma_{11}\sigma_{22}(1-\rho_{12}^2)}} e^{-\frac{1}{2(1-\rho_{12}^2)} \left[\left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 + \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 - 2\rho_{12} \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right) \right]}$$



- Contornos de densidad de probabilidad constantes:

La densidad de la normal multivariada es constante sobre superficies donde la distancia cuadrática $(x-\mu)' \Sigma^{-1}(x-\mu)$ es constante. Estos conjuntos de puntos son llamados *contornos*.

$$\begin{array}{l} \text{Contorno de densidad} \\ \text{probabilidad constante} \end{array} = \left\{ x : (x-\mu)' \Sigma^{-1}(x-\mu) = c^2 \right\}$$

- Un contorno corresponde a la superficie de una elipsoide centrada en μ . Los ejes están en la dirección de los vectores propios de Σ y sus ejes son proporcionales a las raíces cuadradas de sus vectores propios.

Si $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ son los valores propios de Σ y $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p$, son los correspondientes vectores propios, donde $\Sigma \mathbf{e}_i = \lambda_i \mathbf{e}_i$, entonces el contorno dado por $\left\{ x : (x-\mu)' \Sigma^{-1}(x-\mu) = c^2 \right\}$ es una elipsoide centrada en μ y cuyo eje mayor es $\pm c \sqrt{\lambda_1} \mathbf{e}_1$, el segundo eje mayor es $\pm c \sqrt{\lambda_2} \mathbf{e}_2$, etc.

Ejemplo: Contornos de una normal bivariada

Considere la normal bivariada donde $\sigma_{11} = \sigma_{22}$. Los ejes de los contornos están dados por los valores y vectores propios de Σ .

- Los valores propios se obtienen como solución a la ecuación $|\Sigma - \lambda I| = 0$, o

$$0 = \begin{vmatrix} \sigma_{11} - \lambda & \sigma_{12} \\ \sigma_{12} & \sigma_{11} - \lambda \end{vmatrix} = (\sigma_{11} - \lambda)^2 - \sigma_{12}^2 = (\lambda - \sigma_{11} - \sigma_{12})(\lambda - \sigma_{11} + \sigma_{12})$$

Por tanto los valores propios son

$$\lambda_1 = \sigma_{11} + \sigma_{12}$$

$$\lambda_2 = \sigma_{11} - \sigma_{12}$$

- El primer vector propio se determina como solución a $\Sigma \mathbf{e}_1 = \lambda_1 \mathbf{e}_1$, es decir,

$$\begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{11} \end{bmatrix} \begin{bmatrix} e_{11} \\ e_{21} \end{bmatrix} = (\sigma_{11} + \sigma_{12}) \begin{bmatrix} e_{11} \\ e_{21} \end{bmatrix}$$

o,

$$\sigma_{11}e_{11} + \sigma_{12}e_{21} = (\sigma_{11} + \sigma_{12})e_{11}$$

$$\sigma_{12}e_{11} + \sigma_{11}e_{21} = (\sigma_{11} + \sigma_{12})e_{21}$$

Estas ecuaciones implican que $e_{11} = e_{21}$. Después de normalización, el primer par valor propio-vector propio es

$$\lambda_1 = \sigma_{11} + \sigma_{12} , \quad \mathbf{e}_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

De manera similar se determina el segundo vector propio como solución a $\Sigma \mathbf{e}_2 = \lambda_2 \mathbf{e}_2$, resultando el segundo par valor propio-vector propio

$$\lambda_2 = \sigma_{11} - \sigma_{12} , \quad \mathbf{e}_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

➤ Si la covarianza σ_{12} (o la correlación ρ_{12}) es positiva:

$\lambda_1 = \sigma_{11} + \sigma_{12}$ es el mayor valor propio y su vector propio

asociado $\mathbf{e}_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$ cae sobre una recta de 45° a través de

punto $\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$. El eje mayor está determinado por

$$\pm c \sqrt{\sigma_{11} + \sigma_{12}} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$


$\lambda_2 = \sigma_{11} - \sigma_{12}$ es el menor valor propio y su vector propio

asociado $\mathbf{e}_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$ cae sobre una recta perpendicular a la

recta de 45° a través de punto $\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$. El eje menor está

determinado por

$$\pm c \sqrt{\sigma_{11} - \sigma_{12}} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$



➤ Si la covarianza σ_{12} (o la correlación ρ_{12}) es negativa:

$\lambda_2 = \sigma_{11} - \sigma_{12}$ es el mayor valor propio y su vector propio

asociado $\mathbf{e}_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$ cae sobre una recta perpendicular a la

recta de 45° a través de punto $\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$. El eje mayor está

determinado por

$$\pm c \sqrt{\sigma_{11} - \sigma_{12}} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

$\lambda_1 = \sigma_{11} + \sigma_{12}$ es el menor valor propio y su vector propio


asociado $\mathbf{e}_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$ cae sobre una recta de 45° a través de

punto $\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$. El eje menor está determinado por

$$\pm c \sqrt{\sigma_{11} + \sigma_{12}} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

- La densidad normal multivariada tiene un máximo valor cuando la distancia cuadrática $(x-\mu)' \Sigma^{-1}(x-\mu)$ es igual a cero, es decir, cuando $x=\mu$. Por tanto el punto μ es el punto de máxima densidad, o la *moda*, y también es la media.

Contornos para las distribuciones normales bivariadas graficadas



3. OTRAS PROPIEDADES DE LA DISTRIBUCIÓN NORMAL MULTIVARIADA

1. Si un vector aleatorio $X \sim N(\mu, \Sigma)$, entonces toda combinación lineal de las variables en X , $a'X = a_1X_1 + a_2X_2 + \dots + a_pX_p$ tiene una distribución $N(a'\mu, a'\Sigma a)$.
2. Si $a'X$ tiene una distribución $N(a'\mu, a'\Sigma a)$ para todo vector de constantes $a = [a_1, a_2, \dots, a_p]$, entonces $X \sim N(\mu, \Sigma)$.

3. Si un vector aleatorio $X \sim N(\mu, \Sigma)$, entonces el vector de q combinaciones lineales de X ,

$$AX = \begin{bmatrix} a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p \\ a_{21}X_1 + a_{22}X_2 + \cdots + a_{2p}X_p \\ \vdots \\ a_{q1}X_1 + a_{q2}X_2 + \cdots + a_{qp}X_p \end{bmatrix}$$

tienen una distribución $N(A\mu, A\Sigma A')$.

Ejemplo.

Suponga que $X \sim N_3(\mu, \Sigma)$ y considere el vector de combinaciones lineales

$$\begin{bmatrix} X_1 - X_2 \\ X_2 - X_3 \end{bmatrix} = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} = AX$$

Entonces $AX \sim N_2(A\mu, A\Sigma A')$, donde

$$A\mu = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{bmatrix} = \begin{bmatrix} \mu_1 - \mu_2 \\ \mu_2 - \mu_3 \end{bmatrix}$$

y

$$A\Sigma A' = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{12} & \sigma_{22} & \sigma_{23} \\ \sigma_{13} & \sigma_{23} & \sigma_{33} \end{bmatrix} \begin{bmatrix} 1 & 0 \\ -1 & 1 \\ 0 & -1 \end{bmatrix}$$

$$A\Sigma A' = \begin{bmatrix} \sigma_{11} + \sigma_{22} - 2\sigma_{12} & \sigma_{12} + \sigma_{23} - \sigma_{22} - \sigma_{13} \\ \sigma_{12} + \sigma_{23} - \sigma_{22} - \sigma_{13} & \sigma_{22} + \sigma_{33} - 2\sigma_{23} \end{bmatrix}$$

4. Si un vector aleatorio $X \sim N_p(\mu, \Sigma)$, entonces todos los subconjuntos de variables de X tienen distribución normal multivariada.

Ejemplo.

Suponga que $X \sim N_5(\mu, \Sigma)$. Encuentre la distribución del

subvector $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$.

$$\text{Sea } X = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \\ X_4 \\ X_5 \end{bmatrix} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}, \text{ donde } X_1 = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}.$$

Entonces, por el resultado anterior

$$X_1 \sim N_2\left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{bmatrix}\right)$$

5. Si $X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_{q_1+q_2} \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right)$, donde X_1 es de $q_1 \times 1$, X_2 es de $q_2 \times 1$, μ_1 es el vector de medias de X_1 , μ_2 es el vector de medias de X_2 , Σ_{11} es la matriz de covarianza de X_1 , Σ_{22} es la matriz de covarianza de X_2 y Σ_{12} es la matriz de covarianza entre las variables X_1 y X_2 , entonces X_1 y X_2 son independientes estadísticamente si y sólo si $\Sigma_{12} = \mathbf{0}$.

Ejemplo.

Suponga que $X \sim N_3(\mu, \Sigma)$, con $\Sigma = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 3 & 0 \\ 0 & 0 & 2 \end{bmatrix}$.

Son X_1 y X_2 independientes? No porque $\sigma_{12} \neq 0$.

Son $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ y X_3 independientes?

Observe que la matriz de covarianza entre $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ y X_3 es

$$\text{cov} \left(\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}, X_3 \right) = \begin{bmatrix} \sigma_{13} \\ \sigma_{23} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Por tanto, $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ y X_3 son independientes.

Además cada componente de $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ es independiente de X_3 .

6. Si $X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_{q_1+q_2} \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right)$, donde X_1 es de $q_1 \times 1$, X_2

es de $q_2 \times 1$. Entonces la distribución condicional de X_1 dado $X_2 = x_2$ es normal multivariada con vector de media

$$\mu_{1.2} = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

y matriz de covarianza

$$\Sigma_{1.2} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

Ejemplo.

Suponga que $X \sim N_2(\mu, \Sigma)$. Encuentre la distribución condicional de X_1 dado $X_2 = x_2$.

Por resultado anterior, la distribución condicional de

$$X_1 / X_2 = x_2 \sim N(\mu_{1.2}, \Sigma_{1.2})$$

donde

$$\mu_{1.2} = \Sigma_{11} + \Sigma_{12} \Sigma_{22}^{-1} (x_2 - \mu_2) = \sigma_{11} + \sigma_{12} \sigma_{22}^{-1} (x_2 - \mu_2)$$

$$\Sigma_{1,2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} = \sigma_{11} - \sigma_{12}\sigma_{22}^{-1}\sigma_{12} = \sigma_{11} - \frac{\sigma_{12}^2}{\sigma_{22}}$$

Observaciones.

- i) En la regresión multivariada, la media condicional $\mu_{1,2} = E(X_1 / X_2)$ es llamada la curva de regresión.

$$\text{Sea } \Sigma_{12}\Sigma_{22}^{-1} = \begin{bmatrix} \beta_{1,q+1} & \beta_{1,q+2} & \cdots & \beta_{1,p} \\ \beta_{2,q+1} & \beta_{2,q+2} & \cdots & \beta_{2,p} \\ \vdots & \vdots & & \vdots \\ \beta_{q,q+1} & \beta_{q,q+2} & \cdots & \beta_{q,p} \end{bmatrix}.$$

Entonces la curva de regresión en la normal multivariada, $\mu_{1,2} = E(X_1 / X_2)$, se puede escribir como

$$E(X_1 / X_2) = \begin{bmatrix} E(X_1 / X_{q+1}, X_{q+2}, \dots, X_p,) \\ E(X_2 / X_{q+1}, X_{q+2}, \dots, X_p,) \\ \vdots \\ E(X_q / X_{q+1}, X_{q+2}, \dots, X_p,) \end{bmatrix} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2)$$

$$= \begin{bmatrix} \mu_1 + \beta_{1,q+1}(x_{q+1} - \mu_{q+1}) + \beta_{1,q+2}(x_{q+2} - \mu_{q+2}) + \cdots + \beta_{1,p}(x_p - \mu_p) \\ \mu_2 + \beta_{2,q+1}(x_{q+1} - \mu_{q+1}) + \beta_{2,q+2}(x_{q+2} - \mu_{q+2}) + \cdots + \beta_{2,p}(x_p - \mu_p) \\ \vdots \\ \mu_q + \beta_{q,q+1}(x_{q+1} - \mu_{q+1}) + \beta_{q,q+2}(x_{q+2} - \mu_{q+2}) + \cdots + \beta_{q,p}(x_p - \mu_p) \end{bmatrix}$$

Es decir,

$$\begin{bmatrix} E(X_1 / X_{q+1}, X_{q+2}, \dots, X_p,) \\ E(X_2 / X_{q+1}, X_{q+2}, \dots, X_p,) \\ \vdots \\ E(X_q / X_{q+1}, X_{q+2}, \dots, X_p,) \end{bmatrix} = \begin{bmatrix} \beta_{01} + \beta_{1,q+1}x_{q+1} + \beta_{1,q+2}x_{q+2} + \dots + \beta_{1,p}x_p \\ \beta_{02} + \beta_{2,q+1}x_{q+1} + \beta_{2,q+2}x_{q+2} + \dots + \beta_{2,p}x_p \\ \vdots \\ \beta_{0q} + \beta_{q,q+1}x_{q+1} + \beta_{q,q+2}x_{q+2} + \dots + \beta_{q,p}x_p \end{bmatrix}$$

Esto implica que, cuando la distribución conjunta de las variables en una regresión (dependientes e independientes) es normal multivariada, todas las curvas de regresión son lineales.

- ii) La matriz de covarianza condicional $\Sigma_{1,2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$ es constante pues no depende de los valores de las variables condicionantes. Por tanto, la curva de regresión es homocedástica.

7. Si un vector aleatorio $X \sim N(\mu, \Sigma)$, entonces

$$(x-\mu)' \Sigma^{-1}(x-\mu) \sim \chi_p^2$$

4. MUESTREO EN LA DISTRIBUCIÓN NORMAL MULTIVARIADA Y ESTIMACIÓN DE MÁXIMA VEROSIMILITUD

Suponga que $X_1, X_2, \dots, X_n$, es una muestra aleatoria de una población $N(\mu, \Sigma)$.

Entonces, la función de densidad de probabilidad conjunta de $X_1, X_2, \dots, X_n$ es

$$f(x_1, x_2, \dots, x_n) = \prod_{j=1}^n \left\{ \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} e^{-\frac{1}{2}(x_j - \mu)' \Sigma^{-1} (x_j - \mu)} \right\}$$

$$f(x_1, x_2, \dots, x_n) = \frac{1}{(2\pi)^{np/2} |\Sigma|^{n/2}} e^{-\frac{1}{2} \sum_{j=1}^n (x_j - \mu)' \Sigma^{-1} (x_j - \mu)}$$

Cuando se observan los valores de la muestra y son sustituidos la función anterior, la ecuación es considerada como una función de μ y Σ dadas las observaciones $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ y es llamada la función de *verosimilitud*. Se denotará como $L(\mu, \Sigma)$.

Una manera de obtener los estimadores para μ y Σ es seleccionarlos como aquellos que maximicen a $L(\mu, \Sigma)$. Este procedimiento proporciona los *estimadores máximo verosímiles* para μ y Σ , dados por

$$\hat{\mu} = \bar{X}$$

$$\hat{\Sigma} = \frac{1}{n} \sum_{j=1}^n (X_j - \bar{X})(X_j - \bar{X})' = \frac{n-1}{n} S$$

Los valores observados de $\hat{\mu}$ y $\hat{\Sigma}$ son llamadas *estimaciones máximo verosímiles* (EMV) de μ y Σ .

Propiedades.

Los estimadores máximo verosímiles poseen la propiedad de *invarianza*. Sea $\hat{\theta}$ el EMV para θ , y sea $h(\theta)$ una función continua de θ . Entonces el EMV para $h(\theta)$ está dado por $h(\hat{\theta})$.

Es decir $\widehat{h(\theta)} = h(\hat{\theta})$.

Por ejemplo, el EMV para la función $\mu' \Sigma \mu$ es $\hat{\mu}' \hat{\Sigma} \hat{\mu}$.

El EMV para $\sqrt{\sigma_{ii}}$ es $\sqrt{\hat{\sigma}_{ii}}$, donde

$$\hat{\sigma}_{ii} = \frac{1}{n} \sum_{j=1}^n (X_{ji} - \bar{X}_i)^2$$

es el EMV para $\sigma_{ii} = \text{Var}(X_i)$

5. DISTRIBUCIONES MUESTRALES DE $\bar{X}$ y S

Suponga que $X_1, X_2, \dots, X_n$, es una muestra aleatoria de una población $N_p(\mu, \Sigma)$. Entonces,

1. $\bar{X} \sim N_p(\mu, \frac{1}{n}\Sigma)$.
2. $(n-1)S$ tiene una distribución Wishart con $n-1$ grados de libertad, la cual es una generalización de la distribución chi-cuadrado.
3. $\bar{X}$ y S son independientes estadísticamente.

6. COMPORTAMIENTO DE $\bar{X}$ y S EN MUESTRAS GRANDES

- **La ley de los grandes números.** Sean $Y_1, Y_2, \dots, Y_n$ observaciones independientes de una población univariada con media $E(Y_i) = \mu$. Entonces, $\bar{Y} = \frac{1}{n} \sum_{j=1}^n Y_j$ converge en probabilidad a la verdadera media μ , a medida que n crece sin cota. Es decir, que para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P[|\bar{Y} - \mu| < \varepsilon] = 1$$

Empleando este resultado fácilmente se puede probar que, en el caso multivariado,

- El vector $\bar{X}$ converge en probabilidad al vector μ
- S o $\hat{\Sigma}$ convergen en probabilidad a Σ .

La interpretación práctica de estos resultados es que:

- No se requiere de normalidad multivariada para que se de la convergencia. Solamente se necesita que exista el vector de medias poblacional.
 - Con alta probabilidad $\bar{X}$ estará cerca al vector μ y S estará cerca a Σ cuando el tamaño muestral es grande.
- **Teorema Central del Límite.** Suponga que $X_1, X_2, \dots, X_n$, son observaciones independientes de una población con vector de medias μ y matriz de covarianza Σ . Entonces,

$\sqrt{n}(\bar{X} - \mu)$ tiene **aproximadamente** una distribución $N_p(\mathbf{0}, \Sigma)$.

o,

$\bar{X}$ tiene **aproximadamente** una distribución $N_p(\mu, \frac{1}{n}\Sigma)$

cuando $n-p$ es grande.

➤ Observe la diferencia con el caso en el cual la muestra es tomada de una población $N_p(\mu, \Sigma)$ donde $\bar{X}$ tiene exactamente una distribución $N_p(\mu, \frac{1}{n}\Sigma)$.

- Suponga que $X_1, X_2, \dots, X_n$, son observaciones independientes de una población con vector de medias μ y matriz de covarianza Σ . Entonces,

$n(\bar{X} - \mu)' S^{-1}(\bar{X} - \mu)$ tiene **aproximadamente** una distribución χ_p^2

cuando $n-p$ es grande.

7. VERIFICACIÓN DEL SUPUESTO DE NORMALIDAD MULTIVARIADA

- La mayoría de las técnicas del análisis multivariado supone que las observaciones proceden de una población normal multivariada.
- Sin embargo, si la muestra es grande, y las técnicas empleadas solamente depende del comportamiento de $\bar{X}$ o de distancias

relacionadas con $\bar{X}$ de la forma $n(\bar{X} - \mu)' S^{-1}(\bar{X} - \mu)$, el supuesto de normalidad es menos crucial, debido a los resultados límites antes vistos. Sin embargo, la calidad de la inferencia obtenida por estos métodos depende de qué tan cercana esté la verdadera población de la distribución normal multivariada.

- Por tanto es necesario desarrollar procedimientos que permitan detectar desviaciones de la población patrón con respecto a la normal multivariada.
- Basados en las propiedades de la distribución normal multivariada, sabemos que todas las combinaciones lineales de las variables de vector son normales y que los contornos de la distribución normal multivariada son elipsoides. Por tanto, en la verificación de la normalidad multivariada se debería responder a:
 - Las marginales de las variables en el vector X parecen ser normales?
 - Algunas combinaciones lineales de las variables en X parecen ser normales?
 - Los diagramas de dispersión de los pares de variables de X presentan una apariencia elíptica?

- Existen observaciones inusuales que deberían ser confirmadas?

Evaluación de la normalidad univariada

- Las ayudas gráficas siempre importantes en el análisis. Por ejemplo:
 - Para n pequeños se usan los diagramas de puntos.
 - Para moderados y grandes se usan el gráfico de cajas y los histogramas

Estos gráficos permiten detectar asimetrías, es decir situaciones donde una cola es más grande que la otra.

Si los gráficos para X_i parecen razonablemente simétricos, se procede a chequear el número de observaciones en ciertos intervalos. La distribución normal asigna probabilidad de 0.683 al intervalo $(\mu_i - \sigma_i, \mu_i + \sigma_i)$ y de 0.954 al intervalo $(\mu_i - 2\sigma_i, \mu_i + 2\sigma_i)$. Por tanto, para n grande se esperaría que:

La proporción $\hat{p}_{i1}$ de observaciones que caen en el intervalo $(\bar{x}_i - \sqrt{s_{ii}}, \bar{x}_i + \sqrt{s_{ii}})$ esté alrededor de 0.683.

Similarmente, la proporción $\hat{p}_{i2}$ de observaciones que caen en el intervalo $(\bar{x}_i - 2\sqrt{s_{ii}}, \bar{x}_i + 2\sqrt{s_{ii}})$ esté alrededor de 0.954.

Usando la aproximación normal para las proporciones muestrales, es decir, que para n grande

$$\hat{p}_{ik} \xrightarrow{dist} N\left(p_{ik}, \frac{p_{ik}(1-p_{ik})}{n}\right), k=1,2. \text{ Entonces si,}$$

$$|\hat{p}_{i1} - 0.683| > 3\sqrt{\frac{(0.683)(0.317)}{n}} = \frac{1.396}{\sqrt{n}}$$

o si,

$$|\hat{p}_{i2} - 0.954| > 3\sqrt{\frac{(0.954)(0.046)}{n}} = \frac{0.628}{\sqrt{n}}$$

Sería indicativo de alejamientos de la distribución normal.

- El gráfico cuantil-cuantil o gráfico Q-Q. Son gráficos especiales que pueden ser usados para evaluar la normalidad de cada variable.
- En ellos se grafican los cuantiles muestrales contra los cuantiles que se esperaría observar si las observaciones realmente provienen de una distribución normal.

➤ Los pasos para construir un gráfico Q-Q son:

- i) Ordene las observaciones originales de menor a mayor. Sean $x_{(1)}, x_{(2)}, \dots, x_{(n)}$. Las probabilidades correspondientes a ellos son $(1-\frac{1}{2})/n, (2-\frac{1}{2})/n, \dots, (n-\frac{1}{2})/n$.
- ii) Calcule los cuantiles de la normal estándar $q_{(1)}, q_{(2)}, \dots, q_{(n)}$, correspondientes a dichas probabilidades.
- iii) Grafique los pares de observaciones $(q_{(1)}, x_{(1)}), (q_{(2)}, x_{(2)}), \dots, (q_{(n)}, x_{(n)})$.

Si los datos proceden de una distribución normal, estos pares estarán aproximadamente relacionados por la relación lineal $x_{(j)} \approx \mu + \sigma q_{(j)}$. Por tanto, cuando los puntos caen muy próximos a una línea recta, la normalidad es sostenible.

Ejemplo.

Considere una muestra de $n=10$ observaciones, las cuales fueron ordenadas de menor a mayor en la siguiente tabla.

Ordered observations $x_{(j)}$	Probability levels $(j - \frac{1}{2})/n$	Standard normal quantiles $q_{(j)}$
-1.00	.05	-1.645
-.10	.15	-1.036
.16	.25	-.674
.41	.35	-.385
.62	.45	-.125
.80	.55	.125
1.26	.65	.385
1.54	.75	.674
1.71	.85	1.036
2.30	.95	1.645


Por ejemplo, el cálculo del cuantil de la $N(0,1)$, para una probabilidad de 0.65 busca el cuantil que satisface

$$P[Z \leq q_{(7)}] = 0.65$$

Para esta distribución, el cuantil es $q_{(7)}=0.385$, puesto que

$$P[Z \leq 0.385] = \int_{-\infty}^{0.385} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = 0.65$$

La construcción del gráfico Q-Q se basa en el diagrama de dispersión de los puntos $(q_{(j)}, x_{(j)})$, $j=1, 2, \dots, 10$.




los cuales caen muy cerca de una recta, lo que conduce a no rechazar que estos datos provengan de una distribución normal.

Ejemplo.

El departamento de control de calidad de una empresa que produce hornos micro-ondas requiere monitorear la cantidad de radiación emitida por ellos cuando tienen la puerta cerrada. Aleatoriamente se eligieron $n=42$ hornos y se observó dicha cantidad.

Oven no.	Radiation	Oven no.	Radiation	Oven no.	Radiation
1	.15	16	.10	31	.10
2	.09	17	.02	32	.20
3	.18	18	.10	33	.11
4	.10	19	.01	34	.30
5	.05	20	.40	35	.02
6	.12	21	.10	36	.20
7	.08	22	.05	37	.20
8	.05	23	.03	38	.30
9	.08	24	.05	39	.30
10	.10	25	.15	40	.40
11	.07	26	.10	41	.30
12	.02	27	.15	42	.05
13	.01	28	.09		
14	.10	29	.08		
15	.10	30	.18		

El gráfico Q-Q para estos datos es



La apariencia del gráfico indica que los datos no parecen provenir de una distribución normal. Los puntos señalados con un círculo

son observaciones atípicas, pues están muy lejos del resto de los datos.

Observación.

Para esta muestra, varias observaciones son iguales (observaciones empatadas). Cuando esto ocurre, a las observaciones con valores iguales se les asigna un mismo cuantil, el cual se obtiene usando el promedio de los cuantiles que ellas hubieran tenido si hubieran sido ligeramente distintas.

- La linealidad de un gráfico Q-Q puede ser medida calculando el coeficiente de correlación para los puntos del gráfico,

$$r_Q = \frac{\sum_{j=1}^n (x_{(j)} - \bar{x})(q_{(j)} - \bar{q})}{\sqrt{\sum_{j=1}^n (x_{(j)} - \bar{x})^2} \sqrt{\sum_{j=1}^n (q_{(j)} - \bar{q})^2}}$$

Basados en él, se puede construir una prueba potente de normalidad (Filliben, 1975; Looney y Gulledge, 1985; Shapiro y Wilk, 1965). Formalmente, se rechaza la hipótesis de normalidad a un nivel de significancia α si $r_Q < r_Q(\alpha, n)$ donde los valores críticos $r_Q(\alpha, n)$ se encuentran en la siguiente tabla.

Valores críticos para el coeficiente de correlación
del gráfico Q-Q para probar normalidad

Sample size <i>n</i>	Significance levels α		
	.01	.05	.10
5	.8299	.8788	.9032
10	.8801	.9198	.9351
15	.9126	.9389	.9503
20	.9269	.9508	.9604
25	.9410	.9591	.9665
30	.9479	.9652	.9715
35	.9538	.9682	.9740
40	.9599	.9726	.9771
45	.9632	.9749	.9792
50	.9671	.9768	.9809
55	.9695	.9787	.9822
60	.9720	.9801	.9836
75	.9771	.9838	.9866
100	.9822	.9873	.9895
150	.9879	.9913	.9928
200	.9905	.9931	.9942
300	.9935	.9953	.9960

Ejemplo.

Para el primer ejemplo donde $n=10$, el cálculo del coeficiente de correlación entre los puntos $(q_{(j)}, x_{(j)})$, $j=1, 2, \dots, 10$, del gráfico Q-Q, es

$$r_Q = \frac{8.584}{\sqrt{8.472} \sqrt{8.795}} = 0.994$$

Para un nivel de significancia $\alpha=0.10$, el valor crítico es $r_Q(0.10, 10) = 0.9351$. Como $r_Q > r_Q(0.10, 10)$, no rechazamos la hipótesis de normalidad.

Observación.

Para muestras grandes, las pruebas basadas en r_Q y la de Shapiro Wilk, una potente prueba de normalidad, son aproximadamente las mismas.

Análisis de combinaciones lineales de las variables en X


Considere los valores propios de S, $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \hat{\lambda}_p$ y sus correspondientes vectores propios $\hat{e}_1, \hat{e}_2, \dots, \hat{e}_p$. Se sugiere verificar normalidad para las combinaciones lineales

$$\hat{e}_1' X_j \text{ y } \hat{e}_p' X_j$$

donde $\hat{e}_1$ y $\hat{e}_p$ son los vectores propios correspondientes al mayor y menor valor propio de S, respectivamente.

Evaluación de la Normalidad Bivariada

Si las observaciones fueran generadas por una distribución normal multivariada, todas las distribuciones bivariadas serían normales y los contornos de densidad constante deberían ser elipses. Observe el siguiente diagrama de dispersión generado por una muestra simulada de una normal bivariada.



Además, por resultado anterior, el conjunto de puntos bivariados $\mathbf{x}$ tal que

$$(\mathbf{x}-\boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}) \leq \chi^2_2(\alpha)$$

tendrá una probabilidad α .

Por ejemplo, si $\alpha=0.5$, para muestras grandes se esperaría que alrededor del 50% de las observaciones caigan dentro de la elipse dada por

$$\left\{ \mathbf{x} : (\mathbf{x} - \bar{\mathbf{x}})' S^{-1}(\mathbf{x} - \bar{\mathbf{x}}) \leq \chi^2_2(0.5) \right\}$$

Si no es así, la normalidad es sospechosa.

Ejemplo.

Considere los pares de datos para las variables $x_1 =$ ventas y $x_2 =$ ganancias para las 10 mayores corporaciones industriales de E.U. Observe que este conjunto de datos no forman una muestra aleatoria.

Company	$x_1 =$ sales (millions of dollars)	$x_2 =$ profits (millions of dollars)	$x_3 =$ assets (millions of dollars)
General Motors	126,974	4,224	173,297
Ford	96,933	3,835	160,893
Exxon	86,656	3,510	83,219
IBM	63,438	3,758	77,734
General Electric	55,264	3,939	128,344
Mobil	50,976	1,809	39,080
Philip Morris	39,069	2,946	38,528
Chrysler	36,156	359	51,038
Du Pont	35,209	2,480	34,715
Texaco	32,416	2,413	25,636

Para estos datos

$$\bar{x} = \begin{bmatrix} 63.309 \\ 2927 \end{bmatrix}, \quad S = \begin{bmatrix} 10005.20 & 255.76 \\ 255.76 & 14.30 \end{bmatrix} \times 10^5$$

y

$$S^{-1} = \begin{bmatrix} 0.000184 & -0.003293 \\ -0.003293 & 0.128831 \end{bmatrix} \times 10^{-5}$$

Para $\alpha=0.5$, de la distribución chi-cuadrado en dos grados de libertad, $\chi^2_2(0.5)=1.39$. Entonces, cualquier observación $x=(x_1, x_2)$

que satisface

$$\begin{bmatrix} x_1 - 62.309 \\ x_2 - 2927 \end{bmatrix}' \left(\begin{bmatrix} 0.000184 & -0.003293 \\ -0.003293 & 0.128831 \end{bmatrix} \times 10^{-5} \right) \begin{bmatrix} x_1 - 62.309 \\ x_2 - 2927 \end{bmatrix} \leq 1.39$$

Debe estar sobre o dentro del contorno estimado del 50% de probabilidad.

Para las 10 observaciones sus distancias generalizadas son 4.34, 1.20, 0.59, 0.83, 1.88, 1.01, 1.02, 5.33, 0.81 y 0.97. Si los datos proceden de una distribución normal, se esperaría que aproximadamente el 50% de las observaciones caiga dentro o sobre el contorno estimado anterior, o dicho de otro modo, el 50% de las distancias calculadas deberían ser menores o iguales que 1.39. Se observa que 7 de estas distancias son menores que 1.39, lo que implica que la proporción estimada es de 0.70. La gran diferencia entre de esta proporción con 0.50 proporciona evidencia para rechazar normalidad bivariada en estos datos. Sin embargo, la muestra es muy pequeña para permitir obtener esta conclusión.

- El procedimiento anterior es útil, pero bastante burdo. Un método más formal para evaluar la normalidad conjunta está basado en las distancias cuadráticas generalizadas,

$$d_j^2 = (x_j - \bar{x})' S^{-1} (x_j - \bar{x}), j=1, 2, \dots, n$$

El siguiente procedimiento, el cual no está limitado al caso divariado, y puede ser usado par $p \geq 2$. Para $n-p$ grande, las distancias d_j^2 , $j=1, 2, \dots, n$, deberían comportarse como una variable chi-cuadrado. Aunque estas distancia *no son independientes*, o exactamente chi-cuadrado, es útil graficarlas como si lo fueran. El gráfico resultante es llamado *gráfico chi-cuadrado*, y se construye de la siguiente manera:

- i) Ordene las distancias de menor a mayor como $d_{(1)}^2 \leq d_{(2)}^2 \leq \dots \leq d_{(n)}^2$.
- ii) Grafique los pares $(q_{c,p}((j-1/2)/n), d_j^2)$, para $j=1, 2, \dots, n$, donde $q_{c,p}((j-1/2)/n)$ es el cuantil $q_{c,p}((j-1/2)/n)$ de la distribución chi-cuadrado con p grados de libertad.


Bajo normalidad, el gráfico debería mostrar un patrón lineal a través del origen y con pendiente 1. Un patrón sistemáticamente curvo sugiere falta de normalidad.

Ejemplo.

Gráfico chi-cuadrado para el ejemplo anterior. Las distancias ordenadas y los correspondientes percentiles chi-cuadrado aparecen en la siguiente tabla.

j	$d_{(j)}^2$	$q_{c,2}\left(\frac{j-\frac{1}{2}}{10}\right)$
1	.59	.10
2	.81	.33
3	.83	.58
4	.97	.86
5	1.01	1.20
6	1.02	1.60
7	1.20	2.10
8	1.88	2.77
9	4.34	3.79
10	5.33	5.99

A continuación se presenta el gráfico chi-cuadrado para esos datos.



Se observa que los puntos no caen en una línea recta de pendiente 1. Las distancias pequeñas parecen demasiado grandes y las distancias del medio parecen ser demasiado pequeñas con respecto a las distancias esperadas en una normal bivariada. Debido a que la muestra es pequeña no se puede obtener una conclusión definitiva.


8. DETECCIÓN DE OBSERVACIONES INUSUALES O ATÍPICAS

- La mayoría de los conjuntos de datos contienen unas pocas observaciones inusuales que no parecen pertenecer al patrón de variabilidad seguido por las otras observaciones.
- Estas observaciones son denominadas observaciones atípicas y antes de proceder a identificarlas se debe enfatizar que no todas las observaciones atípicas son números equivocados. Ellas pueden formar parte del grupo y pueden conducir a comprender mejor el fenómeno que se está estudiando.
- La detección de observaciones atípicas puede ser mejor realizada visualmente, es decir por medio de gráficos.

- **El caso de una variable:** Se deben buscar observaciones que estén lejos de las demás. Para visualizarlas podemos usar, por ejemplo, diagramas de puntos (muestras pequeñas) o gráficos de cajas esquemáticas.


Ejemplo.

Considere el siguiente diagrama de puntos para una variable



El diagrama de puntos revela una sola observación grande.

- **El caso de dos variables:** En el caso bivariado la situación es más complicada. Considere el siguiente diagrama de dispersión con diagramas de puntos marginales, en el cual parecen existir dos observaciones inusuales.



El dato señalado con un círculo arriba a la derecha está lejos del patrón de los datos. Su segunda coordenada es grande con relación al resto de mediciones para la variable x_2 , como lo muestra el diagrama de puntos vertical.

El segundo dato atípico, también señalado con un círculo, está lejos del patrón elíptico del resto de puntos, pero separadamente cada una de sus componentes tiene un valor típico. Esta observación atípica no puede ser detectada por medio de diagramas de puntos marginales.

Para el caso bivariado el diagrama de dispersión proporciona la información visual requerida para detectar datos atípicos. Sin embargo, en altas dimensiones, los datos atípicos pueden no ser detectados por gráficos univariados o aún diagramas de dispersión. En estas situaciones se recomienda usar gráficos multivariados vistos anteriormente, tales como las curvas de Andrews, las gráficas de caras y de estrellas. Estos gráficos son muy potentes para detectar casos atípicos multivariados.

Además, en altas dimensiones un valor grande de

$$d_j^2 = (x_j - \bar{x})' S^{-1} (x_j - \bar{x}), j=1, 2, \dots, n,$$

sugerirá una observación inusual, aunque no la hallamos visualizado gráficamente.

Pasos para la detección de observaciones atípicas

- 1) Haga un diagrama de puntos o un gráfico de cajas para cada variable.
- 2) Haga un diagrama de dispersión para cada par de variables.

- 3) Calcule los valores estandarizados $z_{jk} = (x_{jk} - \bar{x}_k) / \sqrt{s_{kk}}$, para $j=1, 2, \dots, n$ y $k=1, 2, \dots, p$. Examine estos nk valores conjuntamente para detectar observaciones muy grandes o muy pequeñas.
- 4) Calcule las distancias estandarizadas $d_j^2 = (x_j - \bar{x})' S^{-1} (x_j - \bar{x})$, $j=1, 2, \dots, n$. Examine aquellas distancia inusualmente grandes.

Observaciones.

- i) En el paso 3, “grande” debe ser interpretado con respecto al tamaño de la muestra y al número de variables. Por ejemplo, cuando $n=100$ y $p=5$, hay 500 valores. Puesto que, para una normal estándar $P[|Z|>3]=0.0026$, entonces esperaríamos que 1 o 2 excedan el valor de 3 o sean menores que -3, puesto $n \times P[|Z|>3]=500 \times 0.0026=1.3$. Como una guía se puede usar 3.5 como un valor grande en muestras moderadas.
- ii) En el paso 4., “grande” está medido por el percentil de la distribución chi-cuadrado con p grados de libertad. Por ejemplo, si $n=100$, se debería esperar que 5 observaciones excedan el percentil 0.05-superior de la distribución chi-cuadrado. Un percentil más extremo debe servir para

determinar las observaciones que no se ajustan al patrón del resto de datos.

Ejemplo.


La siguiente tabla presenta los datos para 4 variables que indican la rigidez de tablas de madera. También se presentan los datos estandarizados y sus distancias generalizadas cuadráticas.

TABLE 4.4 FOUR MEASUREMENTS OF STIFFNESS WITH STANDARDIZED VALUES

x_1	x_2	x_3	x_4	Observation no.	z_1	z_2	z_3	z_4	d^2
1889	1651	1561	1778	1	-.1	-.3	.2	.2	.60
2403	2048	2087	2197	2	1.5	.9	1.9	1.5	5.48
2119	1700	1815	2222	3	.7	-.2	1.0	1.5	7.62
1645	1627	1110	1533	4	-.8	-.4	-1.3	-.6	5.21
1976	1916	1614	1883	5	.2	.5	.3	.5	1.40
1712	1712	1439	1546	6	-.6	-.1	-.2	-.6	2.22
1943	1685	1271	1671	7	.1	-.2	-.8	-.2	4.99
2104	1820	1717	1874	8	.6	.2	.7	.5	1.49
2983	2794	2412	2581	9	3.3	3.3	3.0	2.7	12.26
1745	1600	1384	1508	10	-.5	-.5	-.4	-.7	.77
1710	1591	1518	1667	11	-.6	-.5	.0	-.2	1.93
2046	1907	1627	1898	12	.4	.5	.4	.5	.46
1840	1841	1595	1741	13	-.2	.3	.3	.0	2.70
1867	1685	1493	1678	14	-.1	-.2	-.1	-.1	.13
1859	1649	1389	1714	15	-.1	-.3	-.4	-.0	1.08
1954	2149	1180	1281	16	.1	1.3	-1.1	-1.4	16.85
1325	1170	1002	1176	17	-1.8	-1.8	-1.7	-1.7	3.50
1419	1371	1252	1308	18	-1.5	-1.2	-.8	-1.3	3.99
1828	1634	1602	1755	19	-.2	-.4	.3	.1	1.36
1725	1594	1313	1646	20	-.6	-.5	-.6	-.2	1.46
2276	2189	1547	2111	21	1.1	1.4	.1	1.2	9.90
1899	1614	1422	1477	22	-.0	-.4	-.3	-.8	5.06
1633	1513	1290	1516	23	-.8	-.7	-.7	-.6	.80
2061	1867	1646	2037	24	.5	.4	.5	1.0	2.54
1856	1493	1356	1533	25	-.2	-.8	-.5	-.6	4.58
1727	1412	1238	1469	26	-.6	-1.1	-.9	-.8	3.40
2168	1896	1701	1834	27	.8	.5	.6	.3	2.38
1655	1675	1414	1597	28	-.8	-.2	-.3	-.4	3.00
2326	2301	2065	2234	29	1.3	1.7	1.8	1.6	6.28
1490	1382	1214	1284	30	-1.3	-1.2	-1.0	-1.4	2.58


La última columna revela que la observación 16 es una observación atípica multivariada, puesto que $\chi^2_4(0.005)=14.86$. La observación 9 también tiene una gran distancia d_j^2 .

Estas dos observaciones son claramente diferentes de las demás observaciones y le dan apariencia de curvo al patrón que exhibe el correspondiente gráfico chi-cuadrado



Una vez han sido removidas, el patrón que queda se ajusta a una recta.

El siguiente gráfico presenta la matriz de diagramas de dispersión para estos datos.



Los puntos sólidos corresponden a las observaciones 9 y 16. Aunque la observación 16 cae siempre lejos en todos los gráficos, la observación 9 se esconde en el diagrama de dispersión de x_3 contra x_4 , y casi se esconde en el de x_1 contra x_3 .

8. TRANSFORMACIONES PARA ACERCAR A LA NORMALIDAD

- Si la normalidad no es un supuesto viable, cuál es el siguiente paso a seguir?

- Ignorar la no normalidad y proceder como si los datos fueron normalmente distribuidos. Esta práctica no es recomendada, puesto que, en muchos casos, conduciría a conclusiones incorrectas.
- Hacer que los datos no normales parezcan más normales haciendo transformaciones sobre los datos originales. A continuación se pueden realizar los análisis basados en la teoría normal sobre los datos transformados.
- Las transformaciones son solamente reexpresiones de los datos en diferentes unidades. Por ejemplo, cuando un histograma de observaciones positivas muestra una gran cola derecha, una transformación de ellos tomando el logaritmo o la raíz cuadrada generalmente mejora la simetría con respecto a la media y aproxima la distribución a la normalidad.
- Las transformaciones pueden ser sugeridas por consideraciones teóricas o por los datos mismos.
 - Consideraciones teóricas: Por ejemplo, los datos de conteos pueden ser más normales si se les toma la raíz cuadrada. Similarmente, para datos de proporciones la transformación logit y la transformación de Fisher para coeficientes de

correlación, proporcionan cantidades que están aproximadamente normalmente distribuidas.

<u>Escala original</u>	<u>Escala transformada</u>
1. Conteos, y	$\sqrt{y}$
2. Proporciones, $\hat{p}$	$\text{logit}(\hat{p}) = \frac{1}{2} \log\left(\frac{\hat{p}}{1-\hat{p}}\right)$
3. Correlaciones, r	La transf. de Fisher $z(r) = \frac{1}{2} \log\left(\frac{1+r}{1-r}\right)$

- Transformaciones sugeridas por los mismos datos: en algunos casos la transformación para mejorar la aproximación a normalidad no es obvia. En esta situación es conveniente dejar que los datos sugieran una transformación.
- Una familia de transformaciones útil para este propósito es la familia de *transformaciones potenciales*. Existe un método analítico conveniente para escoger una transformación potencial dentro de dicha familia.
- Box y Cox (1964) consideran la familia de transformaciones potenciales

$$x^{(\lambda)} = \begin{cases} \frac{x^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \ln(x), & \lambda = 0 \end{cases}$$

La cual es continua en λ para $x > 0$.

- Dadas las observaciones $x_1, x_2, \dots, x_n$, la solución de Box y Cox para escoger la transformación λ adecuada, es aquella que maximiza la expresión

$$l(\lambda) = -\frac{n}{2} \ln \left[\frac{1}{n} \sum_{j=1}^n \left(x_j^{(\lambda)} - \overline{x^{(\lambda)}} \right)^2 + (\lambda - 1) \sum_{j=1}^n \ln x_j \right]$$

donde $\overline{x^{(\lambda)}} = \frac{1}{n} \sum_{j=1}^n x_j^{(\lambda)}$, es la media aritmética de las observaciones transformadas.

- La expresión $l(\lambda)$ es, aparte de una constante, el logaritmo de la función de verosimilitud de una normal, después de haberla maximizado con respecto a los parámetros de media y varianza.
- El proceso de maximización es fácil de realizar por medio de un computador, seleccionando muchos diferentes valores para λ y calculando el respectivo valor de $l(\lambda)$. Es útil hacer un

gráfico de $l(\lambda)$ versus λ para estudiar el comportamiento en el valor de máximo $\hat{\lambda}$.

- Algunos autores, recomiendan un procedimiento equivalente para encontrar λ , creando una nueva variable

$$y_j^{(\lambda)} = \frac{x_j^\lambda - 1}{\lambda \left[\left(\prod_{j=1}^n x_j \right)^{1/n} \right]^{\lambda-1}}, \quad j=1, 2, \dots, n$$

y calculando su varianza muestral. El mínimo de la varianza ocurre en el mismo valor λ que maximiza $l(\lambda)$.


Ejemplo.

Para los $n=42$ datos de la radiación de hornos micro-ondas con la puerta cerrada, el gráfico Q-Q indica que las observaciones se desvían de lo que esperaríamos si fueran normalmente distribuidas. Puesto que todas las observaciones son positivas, se puede utilizar una transformación potencial de los datos con la esperanza de acercarlos a la normalidad.

Los pares $(\lambda, l(\lambda))$, en el proceso de búsqueda se encuentran en la siguiente tabla.

λ	$\ell(\lambda)$	λ	$\ell(\lambda)$
-1.00	70.52	.40	106.20
-.90	75.65	.50	105.50
-.80	80.46	.60	104.43
-.70	84.94	.70	103.03
-.60	89.06	.80	101.33
-.50	92.79	.90	99.34
-.40	96.10	1.00	97.10
-.30	98.97	1.10	94.64
-.20	101.39	1.20	91.96
-.10	103.35	1.30	89.10
.00	104.83	1.40	86.07
.10	105.84	1.50	82.88
.20	106.39		
.30	106.51		


El gráfico de $\ell(\lambda)$ contra λ , nos permite determinar el máximo con más precisión, el cual se alcanza en $\hat{\lambda}=0.28$. Por conveniencia elegimos $\hat{\lambda}=0.28=1/4$.



Los datos son transformados como

$$x_j^{(1/4)} = \frac{x_j^{1/4} - 1}{(1/4)}, j=1, 2, \dots, 42.$$

Para verificar si los datos transformados son más normales, a continuación se presenta su gráfico cuantil-cuantil.



Los pares de cuantiles caen muy cerca de una recta, lo que permite concluir que $x_j^{(1/4)}$ es aproximadamente normal.

Transformación de las Observaciones Multivariadas

- Para las observaciones multivariadas se debe seleccionar una transformación para cada una de las variables. Sean $\lambda_1, \lambda_2, \dots, \lambda_p$ las transformaciones potenciales para las p variables. Las transformaciones pueden ser obtenidas:

- Individualmente. Para cada una de las variables se escoge la transformación usando el procedimiento anterior. La j -ésima observación transformada es

$$x_j^{(\hat{\lambda})} = \begin{bmatrix} \frac{x_{j1}^{(\hat{\lambda}_1)} - 1}{\hat{\lambda}_1} \\ \frac{x_{j2}^{(\hat{\lambda}_2)} - 1}{\hat{\lambda}_2} \\ \vdots \\ \frac{x_{jp}^{(\hat{\lambda}_p)} - 1}{\hat{\lambda}_p} \end{bmatrix}$$

donde $\hat{\lambda}_1, \hat{\lambda}_2, \dots, \hat{\lambda}_p$ son los valores que individualmente maximizan a $l(\lambda_k)$, $k=1, 2, \dots, p$.

Este procedimiento es equivalente a hacer cada distribución aproximadamente normal. Aunque la normalidad marginal de cada componente no es suficiente para garantizar que todas la distribución conjunta sea normal multivariada, frecuentemente esta condición es suficiente.

- Si no lo es, se pueden usar estos valores $\hat{\lambda}_1, \hat{\lambda}_2, \dots, \hat{\lambda}_p$ como valores iniciales para obtener un conjunto de valores

$\lambda' = [\lambda_1, \lambda_2, \dots, \lambda_p]$ los cuales conjuntamente maximizan la función

$$l(\lambda_1, \lambda_2, \dots, \lambda_p) = -\frac{n}{2} \ln |S(\lambda)| + (\lambda_1 - 1) \sum_{j=1}^n \ln x_{j1} \\ + (\lambda_2 - 1) \sum_{j=1}^n \ln x_{j2} + \dots + (\lambda_p - 1) \sum_{j=1}^n \ln x_{jp}$$

Donde $S(\lambda)$ es la matriz de covarianza muestral calculada usando las observaciones multivariadas transformadas

$$x_j^{(\lambda)} = \begin{bmatrix} \frac{x_{j1}^{(\lambda_1)} - 1}{\lambda_1} \\ \frac{x_{j2}^{(\lambda_2)} - 1}{\lambda_2} \\ \vdots \\ \frac{x_{jp}^{(\lambda_p)} - 1}{\lambda_p} \end{bmatrix}, j=1, 2, \dots, n$$


y $l(\lambda_1, \lambda_2, \dots, \lambda_p)$ es (parte de la constante) la función de verosimilitud de la normal multivariada después de maximizarla con respecto a μ y a Σ .

La maximización de la función anterior $l(\lambda_1, \lambda_2, \dots, \lambda_p)$ no es solamente más difícil que la maximización de las funciones

individuales $l(\lambda_k)$, sino que puede no proporcionar mejores resultados (Hernández y Johnson (1980)).


Ejemplo.

Las mediciones de la radiación también fueron recogidas para los mismos $n=42$ hornos del ejemplo anterior, pero con las puertas abiertas. El siguiente es el gráfico Q-Q para los nuevos datos, cuyo patrón curvo, se aleja de la normalidad.



La selección de una transformación para normalizar los datos produce un $\hat{\lambda}=0.30$, la cual se aproximó a 0.25 por conveniencia.

El siguiente es el gráfico Q-Q para los datos transformados.



Se observa que los datos transformados están más cerca de la normalidad que los datos sin transformar. Sin embargo, la aproximación no es tan buena como en el caso de los datos para las puertas cerradas.

Consideremos ahora la distribución conjunta de las dos variables y determinemos simultáneamente el par de potencias (λ_1, λ_2) que aproximan la distribución a una normal bivariada. La maximización de $l(\lambda_1, \lambda_2)$ produce el par de transformaciones potenciales $(\hat{\lambda}_1, \hat{\lambda}_2) = (0.16, 0.16)$, las cuales no difieren sustancialmente de las obtenidas en forma univariada.

Empleo del programa R

```
# lectura de los datos desde un archivo de texto
radiac<-read.table("c:/unal/datos/j-wdata/radiac_cerr_abier.dat", header = TRUE)
list(radiac)
attach(radiac)

# obtención de los gráficos Q-Q para evaluar normalidad univariada
par(mfrow=c(1,2))
qqnorm(cerrada); qqline(cerrada)
qqnorm(abierta); qqline(abierta)

# obtención del gráfico chi-cuadrado para evaluar normalidad bivariada
library(mvoutlier)
chisq.plot(radiac)

# obtención de las transformaciones potenciales para cada variable individual
# llamar la librería car
library(car)
box.cox.powers(abierta)
box.cox.powers(cerrada)

# obtención de las transformaciones potenciales simultáneas
box.cox.powers(radiac)

# transformación de los datos: se usan transformaciones de 0.25 para cada variable
cerr_t=cerrada^0.25
abie_t=abierta^0.25

# obtención de los gráficos Q-Q individuales para las dos variables transformadas
par(mfrow=c(1,2))
qqnorm(cerr_t); qqline(cerr_t)
qqnorm(abie_t); qqline(abie_t)
```

CAPÍTULO 5.

ANÁLISIS DE COMPONENTES PRINCIPALES

1. INTRODUCCIÓN

El objetivo del análisis de componentes principales es explicar la estructura de la matriz de covarianza de un conjunto de variables por medio de unas pocas combinaciones lineales de las variables originales. Su propósito general es proporcionar una reducción de datos y facilitar la interpretación.

- Aunque se necesitan las p componentes principales para reproducir toda la variabilidad del sistema, generalmente la mayor parte de esa variabilidad es explicada por un número pequeño k de componentes principales. En estos casos las k primeras componentes principales reemplazan las p variables originales, logrando una reducción del sistema original.
- Con frecuencia, el análisis de componentes principales revela relaciones de las que no se sospechaba inicialmente, y por tanto este análisis permite interpretaciones de los datos que no podrían ser derivadas directamente de las variables originales.

2. COMPONENTES PRINCIPALES POBLACIONALES

- Algebraicamente, las componentes principales son combinaciones lineales especiales de las p variables aleatorias $X_1, X_2, \dots, X_p$ de un vector p -dimensional X .
- Geométricamente, estas combinaciones lineales representan la selección de un nuevo sistema de coordenadas que se obtiene al rotar el sistema original donde $X_1, X_2, \dots, X_p$ son los ejes de coordenadas.
- Los nuevos ejes representan las direcciones ortogonales con variabilidad máxima y proporciona una descripción más simple y más parsimoniosa de la estructura de covarianza.
- El desarrollo del procedimiento de componentes principales no requiere del supuesto de la normalidad multivariada. Sin embargo, las componentes principales derivadas de poblaciones normales multivariadas tienen interpretaciones muy útiles en términos de elipsoides de densidad constante. Además, en este caso se puede hacer inferencia basada en las componentes principales muestrales.

- Suponga que

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix}$$

es un vector aleatorio que tiene una matriz de covarianza Σ con valores propios $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$.

Considere las siguientes combinaciones lineales

$$\begin{aligned} Y_1 &= a_1' X = a_{11}X_1 + a_{12}X_2 + \dots + a_{1p}X_p \\ Y_2 &= a_2' X = a_{21}X_1 + a_{22}X_2 + \dots + a_{2p}X_p \\ &\vdots \\ Y_p &= a_p' X = a_{p1}X_1 + a_{p2}X_2 + \dots + a_{pp}X_p \end{aligned}$$

Entonces,

$$Var(Y_i) = a_i' \Sigma a_i, \text{ para } i=1, 2, \dots, p$$

$$Cov(Y_i, Y_k) = a_i' \Sigma a_k, \text{ para } i, k=1, 2, \dots, p$$

- Las *componentes principales* son aquellas combinaciones lineales $Y_1, Y_2, \dots, Y_p$, que no están correlacionadas y cuyas varianzas son tan grandes como sea posible.

- La primera componente principal es la combinación lineal con varianza mayor. Es decir es aquella que maximiza $Var(Y_1) = a_1' \Sigma a_1$. Puesto que dicha varianza puede ser incrementada multiplicando a a_1 por una constante, se debe eliminar esta indeterminación eligiendo el vector a_1 de forma que tenga longitud 1.

Se define:

Primera componente principal=la combinación lineal $Y_1 = a_1' X$ que maximiza $Var(Y_1) = a_1' \Sigma a_1$, sujeta a $a_1' a_1 = 1$

Segunda componente principal=la combinación lineal $Y_2 = a_2' X$ que maximiza $Var(Y_2) = a_2' \Sigma a_2$, sujeta a $a_2' a_2 = 1$ y $Cov(a_1' X, a_2' X) = 0$

.....

i-ésima componente principal=la combinación lineal $Y_i = a_i' X$ que maximiza $Var(Y_i) = a_i' \Sigma a_i$, sujeta a $a_i' a_i = 1$ y $Cov(a_i' X, a_k' X) = 0$, para $k < i$

- **Determinación de las componentes principales.** Sea Σ la matriz de covarianza asociada al vector aleatorio p-

dimensional X . Suponga que Σ posee pares de valores-
 vectores propios $(\lambda_1, e_1), (\lambda_2, e_2), \dots, (\lambda_p, e_p)$ donde
 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$. Entonces la i -ésima componente principal
 está dada por la combinación lineal
 $Y_i = e_i'X = e_{i1}X_1 + e_{i2}X_2 + \dots + e_{ip}X_p, i=1, 2, \dots, p$, donde

$$Var(Y_i) = e_i' \Sigma e_i = \lambda_i \quad i=1, 2, \dots, p$$

$$Cov(e_i'X, e_k'X) = e_i' \Sigma e_k = 0 \quad i \neq k$$

- Si algunos λ_i son iguales, las elecciones de sus correspondientes vectores propios, y por tanto las Y_i , no son únicas.
- Suponga que Σ es la matriz de covarianza asociada al vector aleatorio p -dimensional X que posee pares de valores-vectores propios $(\lambda_1, e_1), (\lambda_2, e_2), \dots, (\lambda_p, e_p)$ donde $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$. Sean $Y_i = e_i'X = e_{i1}X_1 + e_{i2}X_2 + \dots + e_{ip}X_p, i=1, 2, \dots, p$, las componentes principales. Entonces

$$\sum_{i=1}^p Var(X_i) = \sigma_{11} + \sigma_{22} + \dots + \sigma_{pp} = \lambda_1 + \lambda_2 + \dots + \lambda_p = \sum_{i=1}^p Var(Y_i)$$

Observaciones:

1) Del resultado anterior

$$\text{Varianza Total} = \sigma_{11} + \sigma_{22} + \dots + \sigma_{pp} = \lambda_1 + \lambda_2 + \dots + \lambda_p$$

$$2) \left(\begin{array}{l} \text{Prop. de la varianza} \\ \text{total debido a la} \\ \text{k-ésima componente} \\ \text{principal} \end{array} \right) = \frac{\lambda_k}{\lambda_1 + \lambda_2 + \dots + \lambda_p}, \quad k=1, 2, \dots, p.$$

3) Si más del 80% o 90% de la varianza total poblacional, cuando p es grande, puede ser atribuido a la primera, a las dos primeras o a las tres primeras componentes principales, entonces estas componentes pueden reemplazar las variables originales sin mucha pérdida de información.

4) La k -ésima componente del vector propio

$$e'_i = [e_{i1}, \dots, e_{ik}, \dots, e_{ip}]$$

Mide la importancia de la k -ésima variable sobre la i -ésima componente principal, independientemente de las demás variables.

5) Si $Y_i = e_i'X = e_{i1}X_1 + e_{i2}X_2 + \dots + e_{ip}X_p$, $i=1, 2, \dots, p$ son las componentes principales obtenidas de la matriz de covarianza Σ , entonces

$$\rho_{Y_i, X_k} = \frac{e_{ik}\sqrt{\lambda_i}}{\sqrt{\sigma_{kk}}}, \quad i, k=1, 2, \dots, p$$

es el coeficiente de correlación entre la i -ésima componente principal y la variable X_k .

Ejemplo. Obtención de las Componentes Principales Poblacionales

Suponga que tres variables aleatorias X_1 , X_2 y X_3 tienen matriz de covarianza

$$\Sigma = \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

Los pares de valores-vectores propios de Σ son:

$$\lambda_1 = 5.83 \quad e_1 = \begin{bmatrix} 0.383 \\ -0.924 \\ 0 \end{bmatrix}$$

$$\lambda_2 = 2.00 \quad e_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$\lambda_3=0.17 \quad e_3=\begin{bmatrix} 0.924 \\ 0.383 \\ 0 \end{bmatrix}$$

Por tanto las componentes principales son:

$$Y_1 = e_1'X = 0.383X_1 - 0.924X_2$$

$$Y_2 = e_2'X = X_3$$

$$Y_3 = e_3'X = 0.924X_1 + 0.383X_2$$

- Debido a que X_3 no está correlacionada con X_1 ni X_2 , entonces X_3 es una de las componentes principales, pues su información no es llevada al nuevo sistema por ninguna de las otras componentes.
- La proporción de la varianza total explicada por la primera componente principal es

$$\frac{\lambda_1}{\lambda_1 + \lambda_2 + \lambda_3} = 5.83/8 = 0.73$$

Esto significa que el 73% de la varianza total es explicada por la primera componente principal.

- La proporción de la varianza total explicada por las dos primeras componentes principales es

$$\frac{\lambda_1 + \lambda_2}{\lambda_1 + \lambda_2 + \lambda_3} = (5.83 + 2)/8 = 0.98$$

Esto significa que el 98% de la varianza total es explicada por la primera componente principal.

➤ $\rho_{Y_1, X_1} = \frac{e_{11}\sqrt{\lambda_1}}{\sqrt{\sigma_{11}}} = 0.925$

$$\rho_{Y_1, X_2} = \frac{e_{21}\sqrt{\lambda_1}}{\sqrt{\sigma_{22}}} = -0.998$$

- En la primera componente principal, la variable X_2 tiene la mayor ponderación y ella también tiene la mayor correlación con Y_1 .
- La correlación de X_1 con Y_1 es casi tan grande, en magnitud, como la de X_2 con Y_1 , lo que indica que las dos variables son casi igualmente importantes para la primera componente principal.
- Los tamaños relativos de los coeficientes de X_1 y X_2 sugieren que X_2 contribuye más a la determinación de Y_1 que X_1 .

$$\text{➤ } \rho_{Y_2, X_1} = \rho_{Y_2, X_2} = 0 \text{ y } \rho_{Y_2, X_3} = \frac{\sqrt{\lambda_2}}{\sqrt{\sigma_{33}}} = \frac{\sqrt{2}}{\sqrt{2}} = 1$$


➤ Las demás correlaciones puede ser despreciadas puesto que la tercera componente principal no es importante.

- **Componentes Principales Derivadas de una Normal Multivariada**

Suponga que $X \sim N_p(\mu, \Sigma)$. Las componentes principales

$$Y_1 = e_1'X, Y_2 = e_2'X, \dots, Y_p = e_p'X$$

caen en la dirección de los ejes de la elipsoide de densidad constante $(x - \mu)' \Sigma^{-1} (x - \mu) = c^2$.



- **Componentes principales usando variables estandarizadas**

Las componentes principales también pueden ser obtenidas usando las variables estandarizadas

$$\begin{aligned} Z_1 &= \frac{X_1 - \mu_1}{\sqrt{\sigma_{11}}} \\ Z_2 &= \frac{X_2 - \mu_2}{\sqrt{\sigma_{22}}} \\ &\vdots \\ Z_p &= \frac{X_p - \mu_p}{\sqrt{\sigma_{pp}}} \end{aligned}$$

o, en notación matricial,

$$Z = (V^{1/2})^{-1} (X - \mu)$$

donde $V^{1/2} = \text{diagonal}(\sqrt{\sigma_{11}}, \sqrt{\sigma_{22}}, \dots, \sqrt{\sigma_{pp}}$ definida antes.

En este caso, $E(Z) = \mathbf{0}$ y $\text{Cov}(Z) = (V^{1/2})^{-1} \Sigma (V^{1/2})^{-1} = \rho$

➤ Las componentes principales se obtienen usando los vectores propios de la matriz de correlación ρ .

- Todos los resultados anteriores son válidos, con algunas simplificaciones ya que $\text{Var}(Z_i)=1$.
- En general, los pares valores-vectores propios derivados de Σ no son iguales a los de ρ .
- **Obtención de las componentes principales usando variables estandarizadas.** La i -ésima componente principal de las variables estandarizadas

$$Z = \begin{bmatrix} Z_1 \\ Z_2 \\ \vdots \\ Z_p \end{bmatrix}$$

con $\text{Cov}(Z) = \rho$, está dada por

$$Y_i = e_i' Z = e_i' (V^{1/2})^{-1} (X - \mu), \quad i=1, 2, \dots, p$$

Además,

$$\sum_{i=1}^p \text{Var}(Y_i) = \sum_{i=1}^p \text{Var}(Z_i) = p$$

y,

$$\rho_{Y_i, Z_k} = e_{ik} \sqrt{\lambda_i}, \quad i, k=1, 2, \dots, p$$

En este caso, $(\lambda_1, e_1), (\lambda_2, e_2), \dots, (\lambda_p, e_p)$ son los pares valores-vectores propio de ρ , donde $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$.

Observación:

$$\left(\begin{array}{l} \text{Prop. de la varianza} \\ \text{total debido a la} \\ \text{k-ésima componente} \\ \text{principal} \end{array} \right) = \frac{\lambda_k}{p}, \quad k=1, 2, \dots, p.$$

Ejemplo.

Considere un vector bivariado cuya matriz de covarianza es

$$\Sigma = \begin{bmatrix} 1 & 4 \\ 4 & 100 \end{bmatrix}. \text{ Entonces su matriz de correlación es } \rho = \begin{bmatrix} 1 & 0.4 \\ 0.4 & 1 \end{bmatrix}.$$

a) Las componentes principales derivadas de Σ .

Valores y vectores propios de Σ .

$$\lambda_1 = 100.16 \quad e_1 = \begin{bmatrix} 0.040 \\ 0.999 \end{bmatrix}$$

$$\lambda_2 = 0.840 \quad e_2 = \begin{bmatrix} 0.999 \\ -0.040 \end{bmatrix}$$

Entonces la componentes principales basadas en Σ son

$$Y_1 = e_1' X = 0.040X_1 + 0.999X_2$$

$$Y_2 = e_2' X = 0.999X_1 - 0.040X_2$$

Debido a que X_2 tiene una gran varianza, ella domina completamente la primera componente principal. Esta componente explica una proporción de

$$\frac{\lambda_1}{\lambda_1 + \lambda_2} = 100.16/101 = 0.992$$

de la varianza total.

b) Las componentes principales derivadas de ρ .

Valores y vectores propios de ρ .

$$\lambda_1 = 1.4 \quad e_1 = \begin{bmatrix} 0.707 \\ 0.707 \end{bmatrix}$$

$$\lambda_2 = 0.6 \quad e_2 = \begin{bmatrix} 0.707 \\ -0.707 \end{bmatrix}$$

Entonces la componentes principales basadas en ρ son

$$Y_1 = e_1' Z = 0.707Z_1 + 0.707Z_2$$

$$Y_2 = e_2' Z = 0.707Z_1 - 0.707Z_2$$

Cuando las variables están estandarizadas, las variables contribuyen igualmente a la primera componente principal.

Además, como

$$\rho_{Y,Z_1} = e_{11}\sqrt{\lambda_1} = 0.707\sqrt{1.4} = 0.837$$

$$\rho_{Y,Z_2} = e_{21}\sqrt{\lambda_1} = 0.707\sqrt{1.4} = 0.837$$

entonces las variables estandarizadas tienen la misma correlación con la primera componente principal.

La primera componente principal explica una proporción de

$$\frac{\lambda_1}{p} = 1.4/2 = 0.70$$

de la varianza total.

➤ **Conclusión:** Comparando los resultados en los dos casos, se observa que la estandarización afecta bastante los resultados, y que las componentes principales derivadas de Σ son diferentes de las derivadas de ρ .

Cuando usar la estandarización?

⇒ Cuando las variables están medidas en escalas con rangos muy diferentes.

⇒ Cuando las unidades de medida no son conmensurables.

Por ejemplo, si X_1 es una variable aleatoria que representa las ventas anuales en el rango \$20000000 y \$750000000, y X_2 es el cociente dado por (ingreso neto anual)/(Total de activos) que cae entre 0.01 y 0.60, entonces la variación total será debida casi exclusivamente a X_1 y esta variable tendrá una gran ponderación en la primera componente principal, que sería la única importante. Alternativamente si las variables son estandarizadas, sus magnitudes serán del mismo orden y en consecuencia X_2 o (Z_2) jugará un papel más importante en la construcción de las componentes principales.

3. COMPONENTES PRINCIPALES MUESTRALES

Suponga que $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, representan una muestra aleatoria de una población multivariada con vector de medias μ y matriz de covarianza Σ . Sean $\bar{\mathbf{x}}$, S y R el vector de media muestral, y las matrices de covarianza y correlación muestral, respectivamente.

Las *componentes principales muestrales* están definidas como aquellas combinaciones lineales no correlacionadas con máxima varianza que explican la mayor parte de la variación muestral. Específicamente,

➤ **Primera componente principal**=la combinación lineal

$$\hat{y}_1 = a_1' \mathbf{x}_j \quad \text{que maximiza la varianza muestral, sujeta a } a_1' a_1 = 1$$

➤ **Segunda componente principal**=la combinación lineal

$$\hat{y}_2 = a_2' \mathbf{x}_j \quad \text{que maximiza la varianza muestral, sujeta a } a_2' a_2 = 1 \text{ y la covarianza muestral entre } a_1' \mathbf{x}_j \text{ y } a_2' \mathbf{x}_j \text{ es cero.}$$

.....

➤ **i-ésima componente principal**=la combinación lineal

$$\hat{y}_i = a_i' \mathbf{x}_j \quad \text{que maximiza la varianza muestral, sujeta a } a_i' a_i = 1 \text{ y la covarianza muestral entre } a_i' \mathbf{x}_j \text{ y } a_k' \mathbf{x}_j \text{ es cero, para } k < i$$

- **Determinación de las componentes principales muestrales.**

Sea S la matriz de covarianza muestral de los datos de un vector aleatorio p -dimensional X . Suponga que S posee pares de valores-vectores propios $(\hat{\lambda}_1, \hat{e}_1), (\hat{\lambda}_2, \hat{e}_2), \dots, (\hat{\lambda}_p, \hat{e}_p)$

donde $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p \geq 0$ y $\mathbf{x}$ es una observación de las variables $X_1, X_2, \dots, X_p$. Entonces la *i-ésima componente principal muestral* está dada por la combinación lineal $\hat{y}_i = \hat{e}_i' \mathbf{x} = \hat{e}_{i1}x_1 + \hat{e}_{i2}x_2 + \dots + \hat{e}_{ip}x_p$, $i=1, 2, \dots, p$, donde

$$\text{Varianza muestral}(\hat{y}_i) = \hat{e}_i' S \hat{e}_i = \hat{\lambda}_i \quad i=1, 2, \dots, p$$

$$\text{Covarianza muestral}(\hat{y}_i, \hat{y}_k) = 0 \quad i \neq k$$

Además, la varianza total muestral

$$\sum_{i=1}^p s_{ii} = \hat{\lambda}_1 + \hat{\lambda}_2 + \dots + \lambda_p$$

y

$$r_{\hat{y}_i, x_k} = \frac{\hat{e}_{ik} \sqrt{\hat{\lambda}_i}}{\sqrt{s_{kk}}}, \quad i, k=1, 2, \dots, p$$

Observaciones:

- 1) No se hará diferencia en la notación para las componentes principales derivadas de S o de R .
- 2) Las componentes principales derivadas de S no son iguales a las derivadas de R .

- 3) A veces las observaciones $\mathbf{x}_j$ son centradas restando el vector $\bar{\mathbf{x}}$. Esto no afecta la matriz $\mathbf{S}$ y la i -ésima componente principal muestral es

$$\hat{y}_i = \hat{\mathbf{e}}_i'(\mathbf{x} - \bar{\mathbf{x}}), i=1, 2, \dots, p.$$

para cualquier observación $\mathbf{x}$.

- 4) Los valores de la i -ésima componente principal son

$$\hat{y}_{ji} = \hat{\mathbf{e}}_i'(\mathbf{x}_j - \bar{\mathbf{x}}), j=1, 2, \dots, n.$$

En este caso, la media muestral de la i -ésima componente principal es

$$\bar{\hat{y}}_i = \frac{1}{n} \sum_{j=1}^n \hat{y}_{ji} = \frac{1}{n} \sum_{j=1}^n \hat{\mathbf{e}}_i'(\mathbf{x}_j - \bar{\mathbf{x}}) = \frac{1}{n} \hat{\mathbf{e}}_i' \left(\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}}) \right) = \frac{1}{n} \hat{\mathbf{e}}_i' \mathbf{0} = 0$$

y su varianza muestral es $\hat{\lambda}_i$, es decir, no cambia.

Ejemplo.

Un censo proporcionó información sobre las siguientes variables socioeconómicas para 14 áreas de una región:

X_1 =Población total (en miles)

X_2 =Mediana de los años de escolaridad

X_3 =Empleo total (en miles)

X_4 =Empleo en servicios de salud (en cientos)

X_5 =Mediana del valor de la casa (en diez miles)

Tract	Total population (thousands)	Median school years	Total employment (thousands)	Health services employment (hundreds)	Median value home (\$10,000s)
1	5.935	14.2	2.265	2.27	2.91
2	1.523	13.1	.597	.75	2.62
3	2.599	12.7	1.237	1.11	1.72
4	4.009	15.2	1.649	.81	3.02
5	4.687	14.7	2.312	2.50	2.22
6	8.044	15.6	3.641	4.51	2.36
7	2.766	13.3	1.244	1.03	1.97
8	6.538	17.0	2.618	2.39	1.85
9	6.451	12.9	3.147	5.52	2.01
10	3.314	12.2	1.606	2.18	1.82
11	3.777	13.0	2.119	2.83	1.80
12	1.530	13.8	.798	.84	4.25
13	2.768	13.6	1.336	1.75	2.64
14	6.585	14.9	2.763	1.91	3.17

Observe que los datos para áreas censales adyacentes pueden estar correlacionados y por lo tanto las observaciones pueden no constituir una muestra aleatoria.

Estos datos producen

$$\bar{x}' = [4.32, 14.01, 1.95, 2.17, 2.45]$$

y

$$S = \begin{bmatrix} 4.308 & 1.683 & 1.803 & 2.155 & -0.253 \\ 1.683 & 1.768 & 0.588 & 0.177 & 0.176 \\ 1.803 & 0.588 & 0.801 & 1.065 & -0.158 \\ 2.155 & 1.177 & 1.065 & 1.970 & -0.357 \\ -0.253 & 0.176 & -0.158 & -0.357 & 0.504 \end{bmatrix}$$

Se puede resumir la variación muestral por medio de una o dos componente principales?

Var	$\hat{e}_1 (r_{\hat{y}_1, x_k})$	$\hat{e}_2 (r_{\hat{y}_2, x_k})$	$\hat{e}_3$	$\hat{e}_4$	$\hat{e}_5$
X ₁	0.781(0.99)	-0.071(-.04)	0.004	0.542	-0.302
X ₂	0.306(0.61)	-0.764(-.76)	-0.162	-0.545	-0.010
X ₃	0.334(0.98)	0.083(0.12)	0.015	0.050	0.937
X ₄	0.426(0.80)	0.579(0.55)	0.220	-0.636	-0.173
X ₅	-0.054(-0.20)	-0.262(-0.49)	0.962	-0.051	0.024
Var ($\hat{\lambda}_i$)	6.931	1.786	0.390	0.230	0.014
Prop Acu	74.1	93.2	97.4	99.9	100.0

- La primera componente principal explica el 74.1% de la varianza total muestral.
- Las dos primeras componentes principales juntas explican el 93.2% de la varianza total muestral.

- Por tanto, la variación muestral puede ser resumida adecuadamente por medio de las dos primeras componentes principales.
- Dados los coeficientes de las componentes, la primera componente principal parece ser esencialmente un promedio ponderado de las primeras cuatro variables. La segunda componente principal parece contrastar los servicios de empleo en salud con un promedio ponderado de la mediana de los años de escolaridad y la mediana del valor de la casa.
- En la interpretación de las componentes principales se deben tener en cuenta los coeficientes $\hat{e}_{ik}$ de las componentes y las correlaciones $r_{\hat{y}_1, x_k}$. Las correlaciones permiten analizar la importancia de las variables aunque tengan diferentes varianzas. Sin embargo, miden solamente la importancia de una sola X_j sin tener en cuentas las otras variables presentes en la componente.


4. EL NÚMERO DE COMPONENTES PRINCIPALES

- Siempre está presente la pregunta de cuántas componentes principales debemos retener. No existe una respuesta definitiva a esta pregunta.

- Para responderla debemos considerar la cantidad de la varianza total muestral explicada, los tamaños relativos de los valores propios, y las interpretaciones de las componentes. Además, como se discutirá más adelante, una componente asociada a un valor propio cercano a cero, y por tanto claramente no importante, puede indicar una dependencia lineal no sospechada en los datos.
- Una ayuda visual útil para determinar el número de componentes es el gráfico *scree*, el cual presenta un gráfico de $\hat{\lambda}_i$ contra i , las magnitudes de los valores propios contra su número. Para determinar el número apropiado de componentes, buscamos un codo en el gráfico. El número de componentes que se toman es el determinado por aquel punto para el cual es resto de los valores propios son relativamente pequeños y aproximadamente del mismo tamaño.

Ejemplo.

El gráfico *scree* para el ejemplo anterior es



El codo ocurre alrededor de $i=3$, es decir, los valores propios después de $\hat{\lambda}_2$ son relativamente pequeños y aproximadamente del mismo tamaño. En este caso parece que dos (o quizá 3) componentes principales resumen apropiadamente la varianza total muestral.

Ejemplo.

En un estudio del tamaño y la forma de las tortugas pintadas, Jolicoeur y Mosimann (1963) midieron la longitud de la caparazón (X_1), su amplitud(X_2) y su altura(X_3). Los datos sugirieron que el análisis en términos de los logaritmos de las variables. (Jolicoeur, generalmente sugiere el empleo de los logaritmos en los estudios de tamaño y forma)

Female			Male		
Length (x_1)	Width (x_2)	Height (x_3)	Length (x_1)	Width (x_2)	Height (x_3)
98	81	38	93	74	37
103	84	38	94	78	35
103	86	42	96	80	35
105	86	42	101	84	39
109	88	44	102	85	38
123	92	50	103	81	37
123	95	46	104	83	39
133	99	51	106	83	39
133	102	51	107	82	38
133	102	51	112	89	40
134	100	48	113	88	40
136	102	49	114	86	40
138	98	51	116	90	43
138	99	51	117	90	41
141	105	53	117	91	41
147	108	57	119	93	41
149	107	55	120	89	40
153	107	56	120	93	44
155	115	63	121	95	42
155	117	60	125	93	45
158	115	62	127	96	45
159	118	63	128	95	45
162	124	61	131	95	46
177	132	67	135	106	47

El logaritmo natural de las dimensiones de las 24 tortugas machos produce

$$\bar{x}' = [4.725, 4.478, 3.703]$$


y

$$S = \begin{bmatrix} 11.072 & 8.019 & 8.160 \\ 8.019 & 6.417 & 6.005 \\ 8.160 & 6.005 & 6.773 \end{bmatrix}$$

El análisis de componentes principales proporciona el siguiente resumen.

Var	$\hat{e}_1 (r_{\hat{y}_1, x_k})$	$\hat{e}_2$	$\hat{e}_3$
ln(longitud)	0.683(0.99)	-0.159	-0.713
ln(amplitud)	0.510(0.97)	-0.594	0.622
ln(altura)	0.523(0.97)	0.788	0.324
Var ($\hat{\lambda}_i$)	23.30×10^{-3}	0.60×10^{-3}	0.36×10^{-3}
Prop acum.	96.1	98.5	100

El gráfico scree es el siguiente



- La primera componente principal explica el 96.1% de la varianza total muestral.
- La primera componente principal

$$\hat{y}_1 = 0.683 \ln(\text{longitud}) + 0.510 \ln(\text{amplitud}) + 0.523 \ln(\text{altura})$$

$$\hat{y}_1 = \ln[(\text{longitud})^{0.683}(\text{amplitud})^{0.510}(\text{altura})^{0.523}]$$

tiene una interpretación interesante, pues puede ser considerada como el volumen de una caja con dimensiones ajustadas. Por ejemplo, la altura ajustada es $(\text{altura})^{0.523}$, la cual influye en la forma redondeada de la caparazón.

5. INTERPRETACIÓN DE LAS COMPONENTES PRINCIPALES MUESTRALES

- Las componentes principales muestrales tienen varias interpretaciones.
- Suponga que $X \sim N_p(\mu, \Sigma)$. Entonces, las componentes principales muestrales $\hat{y}_i = \hat{e}_i'(\mathbf{x} - \bar{\mathbf{x}})$, son realizaciones de las componentes principales $Y_i = e_i'(\mathbf{x} - \mu)$, las cuales tienen una distribución $N_p(\mathbf{0}, \Lambda)$, donde $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$ y (λ_i, e_i) son los pares valores-vectores propios de la matriz Σ . Las componentes principales muestrales son los ejes de las hiper-elipsoides estimadas generadas por todos los puntos $\mathbf{x}$ que satisfacen


$$(\mathbf{x} - \bar{\mathbf{x}})' S^{-1} (\mathbf{x} - \bar{\mathbf{x}}) = c^2$$

cuando S es definida positiva. En este caso, la hipótesis de normalidad es útil para hacer inferencias, como se verá más adelante.

- Aún si la normalidad es sospechosa, y el patrón de dispersión se aleja algo del patrón elíptico, se pueden extraer los valores propios de S y obtener las componentes principales muestrales.


Las componentes principales pueden ser consideradas como el resultado de trasladar el origen del sistema de coordenadas original a $\bar{x}$ y luego rotar el sistema de ejes de coordenadas hasta que los nuevos ejes pasen a través de las direcciones de máxima varianza del patrón de dispersión.

- Interpretación geométrica: Suponga que $p=2$ y considere el siguiente gráfico que muestra una elipse de distancia constante, centrada en $\bar{x}$, con $\hat{\lambda}_1 > \hat{\lambda}_2$.



Las componentes principales están bien determinadas: caen a lo largo de los ejes de la elipse en direcciones perpendiculares en las direcciones de máxima varianza.

Ahora considere la elipse centrada en $\bar{\mathbf{x}}$ y con $\hat{\lambda}_1 = \hat{\lambda}_2$.



En este caso, los ejes de la elipse (círculo) de distancia constante no están determinados de manera única y caen en

cualquier par de direcciones perpendiculares, incluyendo las direcciones de los ejes del sistema original de coordenadas.

Cuando los contornos de la elipse de distancia constante son aproximadamente circulares, o equivalentemente, los valores propios de S son casi iguales, la variación es homogénea en todas las direcciones. En este caso, no es posible representar bien los datos en menos de p dimensiones.

Si los últimos valores propios son muy pequeños, de forma tal que la variación en las direcciones de los correspondientes vectores propios sea despreciable, las últimas componentes principales pueden ser ignoradas, y los datos pueden ser adecuadamente aproximados en el espacio de las componentes retenidas.

6. ESTANDARIZACIÓN DE LAS COMPONENTES PRINCIPALES MUESTRALES

- Las componentes principales muestrales no son, en general, invariantes con respecto a cambios en escala.

- Si $\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_n$, son las observaciones estandarizadas y su matriz de covarianza es $\mathbf{R}$, la i -ésima componente principal muestral está dada por la combinación lineal

$$\hat{y}_i = \hat{e}_i' \mathbf{z} = \hat{e}_{i1} z_1 + \hat{e}_{i2} z_2 + \dots + \hat{e}_{ip} z_p, \quad i=1, 2, \dots, p$$

donde $(\hat{\lambda}_i, \hat{e}_i)$ es el i -ésimo par valor-vector propio de la matriz $\mathbf{R}$ con $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p \geq 0$. Además,

$$\text{Varianza muestral}(\hat{y}_i) = \hat{\lambda}_i \quad i=1, 2, \dots, p$$

$$\text{Covarianza muestral}(\hat{y}_i, \hat{y}_k) = 0 \quad i \neq k$$

$$\text{varianza total muestral} = \sum_{i=1}^p s_{ii} = \hat{\lambda}_1 + \hat{\lambda}_2 + \dots + \lambda_p$$

$$r_{\hat{y}_i', x_k} = \hat{e}_{ik} \sqrt{\hat{\lambda}_i}, \quad i, k=1, 2, \dots, p$$

$$\left(\begin{array}{l} \text{prop. de la varianza} \\ \text{total muestral (estandarizada)} \\ \text{explicada por la } i\text{-ésima} \\ \text{componente principal} \\ \text{muestral} \end{array} \right) = \frac{\hat{\lambda}_i}{p}, \quad i=1, 2, \dots, p$$

- Como regla general, se sugiere retener solamente aquellas componentes principales cuyas varianzas $\hat{\lambda}_i$ sean mayores que la unidad, o equivalentemente, aquellas componentes

principales que, individualmente, expliquen al menos una proporción $1/p$ de la varianza total muestral.

Ejemplo.

Para el período de Enero de 1975 a Diciembre de 1976, se determinaron los rendimientos semanales de las acciones de 5 compañías.

Week	Allied Chemical	Du Pont	Union Carbide	Exxon	Texaco
1	.000000	.000000	.000000	.039473	-.000000
2	.027027	-.044855	-.003030	-.014466	.043478
3	.122807	.060773	.088146	.086238	.078124
4	.057031	.029948	.066808	.013513	.019512
5	.063670	-.003793	-.039788	-.018644	-.024154
6	.003521	.050761	.082873	.074265	.049504
7	-.045614	-.033007	.002551	-.009646	-.028301
8	.058823	.041719	.081425	-.014610	.014563
9	.000000	-.019417	.002353	.001647	-.028708
10	.006944	-.025990	.007042	-.041118	-.024630
⋮	⋮	⋮	⋮	⋮	⋮
91	-.044068	.020704	-.006224	-.018518	.004694
92	.039007	.038540	.024988	-.028301	.032710
93	-.039457	-.029297	-.065844	-.015837	-.045758
94	.039568	.024145	-.006608	.028423	-.009661
95	-.031142	-.007941	.011080	.007537	.014634
96	.000000	-.020080	-.006579	.029925	-.004807
97	.021429	.049180	.006622	-.002421	.028985
98	.045454	.046375	.074561	.014563	.018779
99	.050167	.036380	.004082	-.011961	.009216
100	.019108	-.033303	.008362	.033898	.004566

Las observaciones de estos 5 rendimientos parecen ser independientes, pero entre ellos parecen estar correlacionados.

Estos datos producen

$$\bar{x}' = [0.0054, 0.0048, 0.0057, 0.0063, 0.0037]$$

y

$$R = \begin{bmatrix} 1.000 & 0.577 & 0.509 & 0.387 & 0.462 \\ 0.577 & 1.000 & 0.599 & 0.389 & 0.322 \\ 0.509 & 0.599 & 1.000 & 0.436 & 0.426 \\ 0.387 & 0.389 & 0.436 & 1.000 & 0.523 \\ 0.462 & 0.322 & 0.426 & 0.523 & 1.000 \end{bmatrix}$$

➤ Valores y vectores propios de R.

$$\hat{\lambda}_1 = 2.857 \quad \hat{e}_1 = \begin{bmatrix} 0.464 \\ 0.457 \\ 0.470 \\ 0.421 \\ 0.421 \end{bmatrix} \quad \hat{\lambda}_2 = 0.802 \quad \hat{e}_2 = \begin{bmatrix} 0.240 \\ 0.509 \\ 0.260 \\ -0.526 \\ -0.582 \end{bmatrix}$$

$$\hat{\lambda}_3 = 0.540 \quad \hat{e}_3 = \begin{bmatrix} -0.612 \\ 0.178 \\ 0.335 \\ 0.541 \\ -0.435 \end{bmatrix} \quad \hat{\lambda}_4 = 0.452 \quad \hat{e}_4 = \begin{bmatrix} 0.387 \\ 0.206 \\ -0.662 \\ 0.472 \\ -0.382 \end{bmatrix}$$

$$\hat{\lambda}_5 = 0.343 \quad \hat{e}_5 = \begin{bmatrix} -0.451 \\ 0.676 \\ -0.400 \\ -0.176 \\ 0.385 \end{bmatrix}$$

- Las dos primeras componentes principales muestrales estandarizadas son

$$\hat{y}_1 = \hat{e}_1'z = 0.464z_1 + 0.457z_2 + 0.470z_3 + 0.421z_4 + 0.421z_5$$

$$\hat{y}_2 = \hat{e}_2'z = 0.240z_1 + 0.509z_2 + 0.260z_3 - 0.526z_4 - 0.582z_5$$

- Estas dos componentes explican el

$$\left(\frac{\hat{\lambda}_1 + \hat{\lambda}_2}{p} \right) \times 100\% = \left(\frac{2.857 + 0.809}{5} \right) \times 100\% = 73\%$$

de la varianza total muestral estandarizada.

- La primera componente principal es una suma equiponderada o un “índice” de las cinco acciones. Esta componente podría llamarse “*componente de mercado*”.
- La segunda componente representa un contraste entre acciones químicas (Allied Chemical, du Pont y Union Carbide) y las de petróleo (Exxon y Texaco). Esta componente podría ser llamada “*componente de industria*”.

- La mayoría de la variación muestral de los rendimientos de estas acciones se debe a la actividad del mercado y a la no correlacionada actividad industrial.
- Las componentes restantes no son fáciles de interpretar y, conjuntamente, representan la variación que probablemente es específica a cada acción. De todas formas, estas componentes no explican mucho de la varianza total muestral.
- Este ejemplo presenta un caso donde parece ser razonable retener una componente asociada con un valor propio menor que la unidad.

7. GRÁFICOS DE LAS COMPONENTES PRINCIPALES MUESTRALES

- Los gráficos de las componentes principales pueden ayudar a:
 - Verificar la hipótesis de normalidad: Dado que las componentes principales son combinaciones lineales de las variables originales, se puede esperar que sean aproximadamente normales. Se recomienda verificar que las primeras componentes principales estén distribuidas

normalmente cuando vayan a ser empleadas como insumos en otros análisis.

- Revelar observaciones sospechosas: Las últimas componentes principales pueden ayudar a detectar observaciones sospechosas.

Cada observación puede ser expresada como una combinación lineal de todos los vectores propios $\hat{e}_1, \hat{e}_2, \dots, \hat{e}_p$ como

$$\begin{aligned} x_j &= (x_j' \hat{e}_1) \hat{e}_1' + (x_j' \hat{e}_2) \hat{e}_2' + \dots + (x_j' \hat{e}_p) \hat{e}_p' \\ &= \hat{y}_{j1} \hat{e}_1' + \hat{y}_{j2} \hat{e}_2' + \dots + \hat{y}_{jp} \hat{e}_p' \end{aligned}$$

Esto significa que las magnitudes de las componentes principales determinan como de bien las primeras componentes principales ajustan a las observaciones.

Es decir, $\hat{y}_{j1} \hat{e}_1' + \hat{y}_{j2} \hat{e}_2' + \dots + \hat{y}_{j,q-1} \hat{e}_{q-1}'$ difiere de x_j en la cantidad $\hat{y}_{jq} \hat{e}_q' + \hat{y}_{j,q+1} \hat{e}_{q+1}' + \dots + \hat{y}_{jp} \hat{e}_p'$, cuya longitud al cuadrado es $\hat{y}_{j,q}^2 + \hat{y}_{j,q+1}^2 + \dots + \hat{y}_{j,p}^2$. Frecuentemente observaciones sospechosas son tales que al menos una de las

coordenadas $\hat{y}_{j,q}, \hat{y}_{j,q+1}, \dots, \hat{y}_{j,p}$ que contribuye a esta longitud cuadrática es grande.

Ejemplo.

Para los datos de las tortugas pintadas, las tres componentes principales son


$$\hat{y}_1 = 0.683(x_1 - 4.725) + 0.510(x_2 - 4.478) + 0.523(x_3 - 3.703)$$

$$\hat{y}_2 = -0.159(x_1 - 4.725) - 0.594(x_2 - 4.478) + 0.788(x_3 - 3.703)$$


$$\hat{y}_3 = -0.713(x_1 - 4.725) + 0.622(x_2 - 4.478) + 0.324(x_3 - 3.703)$$

donde $x_1 = \ln(\text{longitud})$, $x_2 = \ln(\text{amplitud})$, $x_3 = \ln(\text{altura})$.

El siguiente gráfico muestra el gráfico Q-Q para la segunda componente principal.




La observación para la primera tortuga encerrada en un círculo, cae lejos de las demás y parece sospechosa. Este punto debe ser verificado si fue producido por error de registro, o la tortuga puede tener anomalías estructurales. El siguiente es el diagrama de dispersión para las dos primeras componentes principales, el cual aparte del dato de la primera tortuga parece razonablemente elíptico. El análisis de los gráficos de las otras componentes principales no indica desviaciones sustanciales de la normalidad.



- **El gráfico biplot.** Un biplot es un gráfico de la información de una matriz de $n \times p$. En él están representadas dos clases de información contenidas en la matriz de datos. La información de las filas, que corresponden a las unidades muestrales, y la de las columnas que corresponden a las variables.

- Cuando solamente hay dos variables, el diagrama de dispersión puede ser usado para representar simultáneamente la información sobre ambas, las unidades muestrales y las variables.
- Este gráfico permite visualizar la posición de una unidad muestral con respecto a otra, y la importancia relativa de cada una de las dos variables en la posición de la unidad muestral.
- Cuando hay varias variables, se puede construir una matriz de dispersión, pero no existe un solo gráfico de las unidades muestrales. Sin embargo, un gráfico de dispersión de las unidades muestrales se puede obtener graficando las dos primeras componentes principales. La idea del biplot es agregar información sobre las variables al gráfico de las dos componentes principales.
- El siguiente es el biplot para las empresas de servicio público



Se puede observar cómo se agrupan las compañías y cuáles variables contribuyen a su posición dentro de la representación. Por ejemplo, X_4 =factor de carga y X_8 =costo total de combustible son las responsables de la agrupación de la mayoría de compañías costeras al lado inferior derecho. Las variables X_1 =cociente de cargo fijo y X_2 =tasa de retorno de capital juntan las compañías de la Florida y Louisiana.

8. INFERENCIAS PARA MUESTRAS GRANDES

- En la práctica, las decisiones sobre la calidad de la aproximación de las componentes principales debe ser realizada sobre la base de los pares valores-vectores propios de S o de R . Debido a la variación muestral, estos pares diferirán de sus contrapartes poblacionales.
- **Propiedades de $\hat{\lambda}_i$ y $\hat{e}_i$ en muestras grandes.** Se pueden obtener resultados para muestras grandes para $\hat{\lambda}_i$ y $\hat{e}_i$ cuando:
 - La muestra aleatoria procede de una población normal multivariada.
 - Los valores propios (desconocidos) de Σ son distintos y positivos, es decir $\lambda_1 > \lambda_2 > \dots > \lambda_p > 0$. La única excepción es el caso donde el número de valores propios iguales es conocido.
 - Aún cuando la hipótesis de normalidad sea violada, los intervalos obtenidos bajo normalidad todavía son capaces de proporcionar alguna indicación de la incertidumbre de $\hat{\lambda}_i$ y $\hat{e}_i$.

- Anderson (1963) y Girshick(1939) establecieron las siguientes propiedades para la distribución en muestra grandes de los valores propios $\hat{\lambda}' = [\hat{\lambda}_1, \hat{\lambda}_2, \dots, \hat{\lambda}_p]$ y los vectores propios $\hat{e}_i$, $i=1, 2, \dots, p$.

1) Sea Λ la matriz diagonal de los valores propios $\lambda_1, \lambda_2, \dots, \lambda_p$ de Σ . Entonces, $\sqrt{n}(\hat{\lambda} - \lambda)$ es aproximadamente $N_p(\mathbf{0}, 2\Lambda^2)$.

2) $\sqrt{n}(\hat{e}_i - e_i)$ es aproximadamente $N_p(\mathbf{0}, \mathbf{E}_i)$, donde

$$\mathbf{E}_i = \lambda_i \sum_{\substack{k=1 \\ k \neq i}}^p \frac{\lambda_i}{(\lambda_k - \lambda_i)^2} e_k e_i'$$

3) Cada $\hat{\lambda}_i$ está independientemente distribuida de los elementos de vector propio asociado $\hat{e}_i$.

➤ Por el resultado 1), los $\hat{\lambda}_i$ están independientemente distribuidas aproximadamente como $N(\lambda_i, 2\lambda_i^2/n)$. Por tanto, un intervalo aproximado de $(1-\alpha)\%$ de confianza para λ_i está dado por

$$\frac{\hat{\lambda}_i}{(1+z(\alpha/2)\sqrt{2/n})} \leq \lambda_i \leq \frac{\hat{\lambda}_i}{(1-z(\alpha/2)\sqrt{2/n})}$$

donde $z(\alpha/2)$ es el percentil $(\alpha/2)$ -superior de la $N(0,1)$.

- El resultado 2 implica que para muestras grandes, los $\hat{e}_i$ están normalmente distribuidos con respecto al verdadero e_i . Los elementos de $\hat{e}_i$ están correlacionados, y sus correlaciones dependen de que tan distantes estén los valores propios $\lambda_1, \lambda_2, \dots, \lambda_p$, y del tamaño muestral n . En la práctica se reemplaza E_i por $\hat{E}_i$ la cual se obtiene reemplazando los λ_i por $\hat{\lambda}_i$ y los e_i por $\hat{e}_i$.

Ejemplo.

Considere el ejemplo de los rendimientos de las acciones. Suponiendo que ellos proceden de una normal multivariada donde Σ es tal que sus valores propios $\lambda_1 > \lambda_2 > \dots > \lambda_5 > 0$. Puesto que $n=100$ es grande, y el primer valor propio $\hat{\lambda}_1=0.0036$, el intervalo aproximado del 95% de confianza para λ_1 es

$$\frac{0.0036}{(1+1.96\sqrt{2/100})} \leq \lambda_1 \leq \frac{0.0036}{(1-1.96\sqrt{2/100})}$$

o,

$$0.0028 \leq \lambda_1 \leq .0050$$

En general, los intervalos son amplios a la misma tasa que los $\hat{\lambda}_i$ sean grandes. Por tanto, se debe tener cuidado en eliminar o retener componentes principales basados solamente en el examen de las $\hat{\lambda}_i$.

Empleo del programa R

```
# lectura de los datos desde un archivo de texto
censo<-read.table("c:/unal/datos/j-wdata/censo.dat", header = TRUE)
list(censo)
attach(censo)

# obtención de matriz de covarianza
covar=cov(censo)
covar

# obtención de la componentes principales de la matriz de covarianza
summary(cp_censo <- princomp(censo, cor = FALSE))
loadings(cp_censo) # observe que las cantidades en blanco son pequeñas pero no cero
plot(cp_censo)     # presenta el gráfico scree
biplot(cp_censo)
cp_censo$score     # presenta los valores de las componentes principales

# obtención de la componentes principales de la matriz de correlación
summary(cp_censo_cor <- princomp(censo, cor = TRUE))
loadings(cp_censo_cor) #observe que las cantidades en blanco son pequeñas pero no cero
plot(cp_censo_cor) # presenta el gráfico scree
biplot(cp_censo_cor)
cp_censo_cor$scores # presenta los valores de las componentes principales
```

CAPÍTULO 6.

ANÁLISIS DE FACTOR

1. INTRODUCCIÓN

- El análisis de factor ha provocado bastante controversia a través de su historia. Sus inicios modernos datan de comienzos del siglo 20 con los intentos de Karl Pearson, Charles Spearman y otros por definir y medir la inteligencia. Debido a su temprana asociación con “construcciones” tales como la inteligencia, el análisis de factor fue nutrido y desarrollado principalmente por científicos interesados en la sicometría. Las controversias sobre las interpretaciones psicológicas en varios estudios iniciales, y la falta de facilidades computacionales potentes, impidieron su desarrollo como un método estadístico.

La llegada de computadores de alta velocidad ha generado un interés renovado en los aspectos tanto teóricos como computacionales del análisis de factor. Como consecuencia de los desarrollos recientes, la mayoría de las técnicas originales han sido abandonadas y se han resuelto las controversias iniciales. Sin embargo, todavía es cierto que cada aplicación de la técnica debe ser examinada sobre sus propios méritos para determinar su éxito.

- El propósito del Análisis de Factor es describir, si es posible, las relaciones de covarianza que existen en un grupo grande variables en términos de unas pocas, pero no observables, variables aleatorias llamadas *factores*.
- El Análisis de Factor es motivado por el siguiente argumento. Suponga que las variables pueden ser agrupadas por medio de sus correlaciones. Es decir, suponga que las variables dentro de un grupo están altamente correlacionadas entre ellas mismas, pero que tienen correlaciones pequeñas con las variables de otros grupos. Entonces es concebible pensar que cada grupo de variables representa un solo término subyacente, o factor, que es responsable de las correlaciones observadas dentro del grupo.
- Por ejemplo, las correlaciones dentro de un grupo de notas sobre pruebas en historia, Francés, Inglés, matemáticas y música recogidas por Spearman, sugieren un factor subyacente de “inteligencia” que las explica.

2. EL MODELO DE FACTOR ORTOGONAL

- Sea X vector aleatorio observable de p componentes que tiene media μ y matriz de covarianza Σ . El modelo de factor ortogonal considera que X es linealmente dependiente de:
 - Un grupo pequeño de variables aleatorias no observables $F_1, F_2, \dots, F_m$, llamadas *factores comunes*
 - De p fuentes adicionales de variación $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_p$, llamadas *errores*, o *factores específicos*.

En particular el modelo de factor es:

$$\begin{aligned}
 X_1 - \mu_1 &= l_{11}F_1 + l_{12}F_2 + \dots + l_{1m}F_m + \varepsilon_1 \\
 X_2 - \mu_2 &= l_{21}F_1 + l_{22}F_2 + \dots + l_{2m}F_m + \varepsilon_2 \\
 &\vdots \\
 X_p - \mu_p &= l_{p1}F_1 + l_{p2}F_2 + \dots + l_{pm}F_m + \varepsilon_p
 \end{aligned}$$

o, en notación matricial,

$$X - \mu = LF + \varepsilon$$

donde l_{ij} es la ponderación de la i -ésima variable sobre el j -ésimo factor.

La matriz L es llamada la matriz de las ponderaciones de los factores.

El i-ésimo factor específico está asociado únicamente con la i-ésima respuesta X_i .

Las p desviaciones $X_i - \mu_i$, para $i=1,2,\dots,p$, son expresadas en términos de $m+p$ variables aleatorias *no observables*.

- Esta es la diferencia del modelo de factor con el modelo de regresión multivariado, en el cual las variables explicativas o independientes (las F) son observadas.
- Supuestos

$$E(F)=\mathbf{0}, \quad \text{Cov}(F)=E(FF')=I$$

$$E(\varepsilon)=\mathbf{0}, \quad \text{Cov}(\varepsilon)=E(\varepsilon \varepsilon')=\Psi = \begin{bmatrix} \psi_1 & 0 & \dots & 0 \\ 0 & \psi_2 & \dots & 0 \\ \vdots & & & \\ 0 & 0 & \dots & \psi_p \end{bmatrix}$$

F y ε son independientes, por lo que

$$\text{Cov}(F, \varepsilon)=E(\varepsilon F')=\mathbf{0}$$

- El modelo ortogonal de factores implica que

$$\Sigma = LL' + \Psi$$

donde $\text{Cov}(X, F) = E(X - \mu)(F') = L$

- **La estructura de covarianza para el modelo de factor ortogonal**

$$1) \text{Cov}(X) = LL' + \Psi$$

Por lo que

$$\text{Var}(X_i) = l_{i1}^2 + l_{i2}^2 + \dots + l_{im}^2 + \psi_i$$

$$\text{Cov}(X_i, X_k) = l_{i1}l_{k1} + l_{i2}l_{k2} + \dots + l_{im}l_{km}$$

$$2) \text{Cov}(X, F) = L$$

Por lo que

$$\text{Cov}(X_i, F_j) = l_{ij}$$

- La porción de la varianza de la i-ésima variable explicada por los m factores comunes es llamada *comunalidad*, y se denota por h_i^2 .

- La porción de la varianza de la i -ésima variable debida al factor específico es llamada *unicidad* o *varianza específica*.

- De los resultados anteriores,

$$\text{Var}(X_i) = l_{i1}^2 + l_{i2}^2 + \dots + l_{im}^2 + \psi_i$$

o,

$$\sigma_{ii} = l_{i1}^2 + l_{i2}^2 + \dots + l_{im}^2 + \psi_i$$

o,

$$\sigma_{ii} = h_i^2 + \psi_i$$

donde,

$$h_i^2 = l_{i1}^2 + l_{i2}^2 + \dots + l_{im}^2$$

Ejemplo. Verificación de la relación $\Sigma = LL' + \Psi$ para dos factores

Considere la matriz de covarianza

$$\Sigma = \begin{bmatrix} 19 & 30 & 2 & 12 \\ 30 & 57 & 5 & 23 \\ 2 & 5 & 38 & 47 \\ 12 & 23 & 47 & 68 \end{bmatrix}$$

Entonces Σ puede ser reproducida como

$$\Sigma = \begin{bmatrix} 19 & 30 & 2 & 12 \\ 30 & 57 & 5 & 23 \\ 2 & 5 & 38 & 47 \\ 12 & 23 & 47 & 68 \end{bmatrix} = \begin{bmatrix} 4 & 1 \\ 7 & 2 \\ -1 & 6 \\ 1 & 8 \end{bmatrix} \begin{bmatrix} 4 & 7 & -1 & 1 \\ 1 & 2 & 6 & 8 \end{bmatrix} + \begin{bmatrix} 2 & 0 & 0 & 0 \\ 0 & 4 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 3 \end{bmatrix}$$

donde,

$$L = \begin{bmatrix} l_{11} & l_{12} \\ l_{21} & l_{22} \\ l_{31} & l_{32} \\ l_{41} & l_{42} \end{bmatrix} = \begin{bmatrix} 4 & 1 \\ 7 & 2 \\ -1 & 6 \\ 1 & 8 \end{bmatrix}$$

$$\Psi = \begin{bmatrix} \psi_1 & 0 & 0 & 0 \\ 0 & \psi_2 & 0 & 0 \\ 0 & 0 & \psi_3 & 0 \\ 0 & 0 & 0 & \psi_4 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 0 & 0 \\ 0 & 4 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 3 \end{bmatrix}$$

Por tanto, Σ tiene una estructura producida por un modelo de $m=2$ factores ortogonales.

La communalidad de X_1 es

$$h_1^2 = l_{11}^2 + l_{12}^2 = 4^2 + 1^2 = 17$$

y la varianza de X_1 puede ser descompuesta como

$$\sigma_{11} = (l_{11}^2 + l_{12}^2) + \psi_1 = h_1^2 + \psi_1 = 19$$

De manera similar se puede encontrar la descomposición para las otras variables.

- El modelo de factor asume que los $p+p(p-1)/2=p(p+1)/2$ elementos de Σ pueden ser reproducidos usando las mp ponderaciones l_{ij} de los factores, y las p varianzas específicas ψ_i .
- Cuando $m=p$, se puede probar que cualquier matriz de covarianza Σ puede ser reproducida exactamente como LL' , de forma que la matriz $\Psi=0$.
- Sin embargo, cuando m es pequeño con respecto a p , el análisis de factor es muy útil. En este caso, el modelo de factor proporciona una explicación simple de la covariación en X con menos parámetros que los $p(p+1)/2$ parámetros de Σ .
- Por ejemplo, si X contiene $p=12$ variables y un modelo de factor con $m=2$ factores ortogonales es apropiado, entonces los $p(p+1)/2=78$ elementos de Σ pueden ser descritos en

términos de $mp+p = 36$ parámetros l_{ij} y ψ_i del modelo de factor.

- Desafortunadamente, la mayoría de las matrices de covarianza no pueden ser factorizadas como $\Sigma = LL' + \Psi$, cuando el número de factores m es mucho más pequeño que p .

Ejemplo. No unicidad de una solución propia

Suponga que $p=3$ y $m=1$ y que

$$\Sigma = \begin{bmatrix} 1 & 0.9 & 0.7 \\ 0.9 & 1 & 0.4 \\ 0.7 & 0.4 & 1 \end{bmatrix}$$

Usando el modelo de factor ortogonal

$$\begin{aligned} X_1 - \mu_1 &= l_{11}F_1 + \varepsilon_1 \\ X_2 - \mu_2 &= l_{21}F_1 + \varepsilon_2 \\ X_3 - \mu_3 &= l_{31}F_1 + \varepsilon_3 \end{aligned}$$

La estructura de covarianza implica que $\Sigma = LL' + \Psi$

De donde se obtiene

$$\begin{aligned}
 1 &= l_{11}^2 + \psi_1 & 0.9 &= l_{11}l_{21} & 0.7 &= l_{11}l_{31} \\
 & & 1 &= l_{21}^2 + \psi_2 & 0.4 &= l_{21}l_{31} \\
 & & & & 1 &= l_{31}^2 + \psi_3
 \end{aligned}$$

El par de ecuaciones

$$\begin{aligned}
 0.7 &= l_{11}l_{31} \\
 0.4 &= l_{21}l_{31}
 \end{aligned}$$

Implican que

$$l_{21} = \left(\frac{0.4}{0.7} \right) l_{11}$$

Sustituyendo este resultado en la ecuación

$$0.9 = l_{11}l_{21}$$

Se obtiene que

$$l_{11}^2 = 1.575 \quad \text{o} \quad l_{11} = \pm 1.255$$

Puesto que $\text{Var}(F_1)=1$ por hipótesis del modelo, y $\text{Var}(X_1)=1$, entonces

$$l_{11} = \text{Cov}(X_1, F_1) = \text{Corr}(X_1, F_1)$$

cuya magnitud no puede ser mayor que 1. Sin embargo, la solución no satisface esta restricción.

Además de la ecuación

$$1 = l_{11}^2 + \psi_1 \quad \text{o} \quad \psi_1 = 1 - l_{11}^2,$$

se obtiene que

$$\psi_1 = 1 - 1.575 = -0.575$$

la cual no es adecuada puesto que $\text{Var}(\varepsilon_1) = \psi_1$.

Conclusión: Para este ejemplo con $m=1$, es posible obtener una solución numérica única a la ecuación $\Sigma = LL' + \Psi$. Sin embargo la solución no es consistente con la interpretación estadística de los coeficientes, y por tanto no es una solución propia.

- Cuando $m>1$ siempre hay una ambigüedad asociada al modelo de factor.

Considere una matriz ortogonal T de $m \times m$. Entonces,

$$TT' = T'T = I.$$

Con esta matriz, el modelo de factor ortogonal puede ser escrito como

$$X - \mu = LF + \varepsilon = LTT'F + \varepsilon = L^*F^* + \varepsilon$$

donde,

$$L^* = LT \quad \text{y} \quad F^* = T'F$$

y puesto que

$$E(F^*) = \mathbf{0} \quad \text{y} \quad \text{Cov}(F^*) = T' \text{Cov}(F) T = T' T = I$$

es imposible distinguir entre las ponderaciones L y las ponderaciones L^* basados en las observaciones del vector X . Es decir, los factores L y L^* tienen las mismas propiedades estadísticas, y aunque en general, L es diferente de L^* ellas generan la misma matriz de covarianza Σ , puesto que

$$\Sigma = LL' + \Psi = LTT'L' + \Psi = L^*L^{*'} + \Psi$$

- Esta ambigüedad es la base de la rotación de factores, puesto que las matrices ortogonales equivalen a la rotación del sistema de coordenadas para X .

- En conclusión, las ponderaciones L y $L^*=LT$ proporcionan la misma representación. Las communalidades, dadas por los elementos de la diagonal de $LL'=(L^*)(L^*)'$, no se afectan por la elección de T .
- El análisis de factor:
 - Se inicia imponiendo condiciones que permitan estimar de manera única a L y a Ψ .
 - A continuación se rota la matriz de ponderaciones (se multiplica por una matriz ortogonal), donde la rotación está determinada por algún criterio de “fácil interpretación”.
 - Una vez se hayan obtenido las ponderaciones y las varianzas específicas, se identifican los factores y los valores estimados para los factores mismos (llamados *scores* de los factores).

3. MÉTODOS DE ESTIMACIÓN

- Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución multivariada con vector de medias μ y matriz de covarianza Σ . La matriz de covarianza muestral S es un estimador de Σ . Si los elementos fuera de la diagonal de S son pequeños, o los

elementos de la matriz de correlaciones R son prácticamente cero, las variables no estarán relacionadas linealmente y el análisis de factor no es útil.

- Si S parece desviarse significativamente de una matriz diagonal, entonces, el modelo de factor puede ser probado y el problema inicial es estimar las ponderaciones l_{ij} de los factores y las varianzas específicas ψ_i .
- **El Método de la Componente Principal.** La descomposición espectral proporciona una factorización de la matriz de covarianza Σ . Suponga el par (λ_i, e_i) es el par valor-vector propio de Σ , donde $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$.

Entonces

$$\Sigma = P\Lambda P' = \begin{bmatrix} e_1 & e_2 & \dots & e_p \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & 0 \dots 0 \\ 0 & \lambda_2 & 0 \dots 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 \dots 0 \end{bmatrix} \begin{bmatrix} e_1' \\ e_2' \\ \vdots \\ e_p' \end{bmatrix}$$

$$\Sigma = \lambda_1 e_1 e_1' + \lambda_2 e_2 e_2' + \dots + \lambda_p e_p e_p'$$

$$\Sigma = \begin{bmatrix} \sqrt{\lambda_1} e_1 & \sqrt{\lambda_2} e_2 & \cdots & \sqrt{\lambda_p} e_p \end{bmatrix} \begin{bmatrix} \sqrt{\lambda_1} e'_1 \\ \sqrt{\lambda_2} e'_2 \\ \vdots \\ \sqrt{\lambda_p} e'_p \end{bmatrix}$$

Este ajuste supone que la estructura de covarianza para el modelo de análisis de factor tiene tantos factores como variables ($m=p$) y las varianzas específicas $\psi_i=0$.

El vector $\sqrt{\lambda_j} e_j$ es la j -ésima columna de la matriz de ponderaciones. Es decir,

$$\Sigma = LL' + \mathbf{0} = LL'$$

Fuera del factor de escala $\sqrt{\lambda_j}$, el vector de ponderaciones del j -ésimo factor son los coeficientes de la j -ésima componente principal de la población.

- Aunque la representación de Σ por el análisis de factor es exacta, no es útil, pues emplea tantos factores comunes como variables y no permite variaciones en los factores específicos ε .
- Se prefieren modelos que expliquen la estructura de la covarianza en términos de unos pocos factores comunes.

- Cuando los últimos $p-m$ valores propios son pequeños, una aproximación es eliminar la contribución de $\lambda_{m+1}e_{m+1}e'_{m+1} + \lambda_{m+2}e_{m+2}e'_{m+2} + \dots + \lambda_p e_p e'_p$ en Σ .

Eliminando esta contribución,

$$\Sigma \approx \begin{bmatrix} \sqrt{\lambda_1}e_1 & \sqrt{\lambda_2}e_2 & \dots & \sqrt{\lambda_m}e_m \end{bmatrix} \begin{bmatrix} \sqrt{\lambda_1}e'_1 \\ \sqrt{\lambda_2}e'_2 \\ \vdots \\ \sqrt{\lambda_m}e'_m \end{bmatrix} = LL'$$

Esta representación asume que los factores específicos son de menor importancia y pueden eliminados en la representación de Σ .

- Si se incluyen los factores específicos en el modelo, sus varianzas pueden ser asignadas como los elementos de la diagonal de la matriz $\Sigma - LL'$.

En este caso, la aproximación es

$$\Sigma \approx LL' + \Psi$$

Donde el i -ésimo elemento en la diagonal de Ψ es

$$\psi_i = \sigma_{ii} - \sum_{j=1}^m l_{ij}^2, \text{ para } i=1, 2, \dots, p.$$

- **Solución de la Componente Principal para el Modelo de Factor.** El análisis de factor de la componente principal para la matriz de covarianza muestral S está especificada en términos de los pares valor-vector propio $(\hat{\lambda}_i, \hat{e}_i)$, $i=1, 2, \dots, p$, donde $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p$.

Sea $m < p$ el número de factores comunes. Entonces, la matriz estimada de ponderaciones de los factores está dada por

$$\tilde{L} = \begin{bmatrix} \sqrt{\hat{\lambda}_1} e_1 & \sqrt{\hat{\lambda}_2} e_2 & \dots & \sqrt{\hat{\lambda}_m} e_m \end{bmatrix}$$

Las varianzas específicas estimadas están dadas por los elementos de la diagonal de la matriz $S - \tilde{L} \tilde{L}'$, es decir,

$$\tilde{\Psi} = \begin{bmatrix} \tilde{\psi}_1 & 0 & \dots & 0 \\ 0 & \tilde{\psi}_2 & \dots & 0 \\ \vdots & & & \\ 0 & 0 & \dots & \tilde{\psi}_p \end{bmatrix} \text{ donde } \tilde{\psi}_i = s_{ii} - \sum_{j=1}^m \tilde{l}_{ij}^2, \text{ para } i=1, 2, \dots, p$$

Las communalidades son estimadas como

$$\tilde{h}_i^2 = \tilde{l}_{i1}^2 + \tilde{l}_{i2}^2 + \dots + \tilde{l}_{im}^2$$

Observaciones.

- 1) En la aplicación del modelo de factor al conjunto de datos multivariados $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, se acostumbra centrar las observaciones con respecto al vector de medias muestral $\bar{\mathbf{x}}$.

Las observaciones centradas,

$$\mathbf{x}_j - \bar{\mathbf{x}} = \begin{bmatrix} x_{j1} - \bar{x}_1 \\ x_{j2} - \bar{x}_2 \\ \vdots \\ x_{jp} - \bar{x}_p \end{bmatrix}, j=1, 2, \dots, n$$

tienen la misma matriz de covarianzas $\mathbf{S}$ que las observaciones originales.

- 2) Cuando las unidades de las variables no son conmensurables, generalmente se trabaja con las observaciones estandarizadas

$$\mathbf{z}_j = \begin{bmatrix} \frac{x_{j1} - \bar{x}_1}{\sqrt{s_{11}}} \\ \frac{x_{j2} - \bar{x}_2}{\sqrt{s_{22}}} \\ \vdots \\ \frac{x_{jp} - \bar{x}_p}{\sqrt{s_{pp}}} \end{bmatrix}, j=1, 2, \dots, n$$

cuya matriz de covarianza es la matriz de correlación muestral R . Esto evita que variables con grandes varianzas afecten indebidamente las ponderaciones de los factores.

- 3) En la solución de componente principal, las ponderaciones estimadas para un factor no cambian a medida que se incrementa el número de factores.
 - 4) Selección del número de factores. El número de factores puede ser determinado por consideraciones a priori, tales como la teoría o el trabajo de los investigadores.
- Si no existen consideraciones a priori, la escogencia de m puede estar basada en los valores propios estimados, en forma similar a la de las componentes principales.

Considere la *matriz residual*

$$S - \tilde{L}\tilde{L}' - \tilde{\Psi}$$

resultante de la aproximación de S por medio de la solución de la componente principal. Los elementos de la diagonal son cero, y si los demás elementos también son pequeños, se puede considerar subjetivamente que el modelo de m factores es apropiado.

- Se puede probar que que si SC es Suma de cuadrados los elementos $(S - \tilde{L}\tilde{L}' - \tilde{\Psi})$, entonces

$$SC(S - \tilde{L}\tilde{L}' - \tilde{\Psi}) \leq \hat{\lambda}_{m+1}^2 + \hat{\lambda}_{m+2}^2 + \dots + \hat{\lambda}_p^2$$

Esto significa que un valor pequeño para la suma de cuadrados de los valores propios eliminados implica un valor pequeño para la suma de cuadrados de los errores de aproximación.

- Idealmente, las contribuciones de los primeros pocos factores a las varianzas muestrales deberían ser grandes. La contribución del primer factor común a la varianza muestral s_{ii} es $\tilde{l}_{i1}^2$. La contribución a la varianza *total* $s_{11} + s_{22} + \dots + s_{pp} = \text{traza}(S)$ es

$$\tilde{l}_{11}^2 + \tilde{l}_{21}^2 + \dots + \tilde{l}_{p1}^2 = \left(\sqrt{\hat{\lambda}_1} \hat{e}_1 \right)' \left(\sqrt{\hat{\lambda}_1} \hat{e}_1 \right) = \hat{\lambda}_1$$

En general,

$$\left(\begin{array}{l} \text{Prop. de la} \\ \text{varianza total} \\ \text{muestral debida} \\ \text{al factor } j \end{array} \right) = \left\{ \begin{array}{ll} \frac{\hat{\lambda}_j}{s_{11} + s_{22} + \dots + s_{pp}} & \text{si se usa S} \\ \frac{\hat{\lambda}_j}{p} & \text{si se usa R} \end{array} \right.$$

Este criterio se usa generalmente como una herramienta heurística para determinar el número apropiado de factores. El número de factores es incrementado hasta que una proporción adecuada de la varianza total muestral es apropiada.

- Una convención frecuentemente empleada por los paquetes de cómputo, es hacer m igual al número de valores propios de R mayores que 1, si se usa la matriz R en el análisis, o igual al número de valores propios positivos, si se usa la matriz S . El uso indiscriminado de estas reglas generales podrían no ser apropiado. Por ejemplo, si se usa la regla para S , entonces $m=p$, puesto que se espera que todos los valores propios de S sean positivos para grandes tamaños muestrales. La mejor regla es la de retener pocos en lugar de

muchos factores, suponiendo que esos factores proporcionen una interpretación adecuada de los datos y proporcionen un ajuste satisfactorio para S o R.

Ejemplo. Datos de preferencia para los consumidores

En un estudio sobre la preferencia de los consumidores, a una muestra aleatoria de consumidores se les pidió que evaluaran varios atributos de un nuevo producto. Los atributos seleccionados fueron:

X_1 =Gusto

X_2 = Buena compra por el dinero pagado

X_3 =Sabor

X_4 =Adecuado como pasaboca

X_5 =Proporciona gran energía

Sus respuestas, dadas sobre una escala semántica de 7 puntos, fueron tabuladas y se construyó la matriz de correlación de los atributos, la cual produjo.

$$R = \begin{bmatrix} 1.00 & 0.02 & 0.96 & 0.42 & 0.01 \\ 0.02 & 1.00 & 0.13 & 0.71 & 0.85 \\ 0.96 & 0.13 & 1.00 & 0.50 & 0.11 \\ 0.42 & 0.71 & 0.50 & 1.00 & 0.79 \\ 0.01 & 0.85 & 0.11 & 0.79 & 1.00 \end{bmatrix}$$

- De la matriz anterior es claro que las variables 1 y 3 y las variables 2 y 5 forman grupos. La variable 4 está “más cerca” al grupo (2,5) que al grupo (1,3).
- Dados estos resultados y el pequeño número de variables, se esperaría que las relaciones aparentes anteriores entre las variables, sean explicadas en términos de, a lo más, dos o a tres factores.
- Los dos primeros valores propios de R, $\hat{\lambda}_1=2.85$ y $\hat{\lambda}_2=1.81$, son los únicos valores propios de R mayores que 1.
- Para $m=2$ factores, se acumula una proporción de

$$\frac{\hat{\lambda}_1 + \hat{\lambda}_2}{p} = \frac{2.85 + 1.81}{5} = 0.93$$

de la varianza total muestral estandarizada.

- La siguiente tabla contiene las estimaciones de las ponderaciones de los factores, las communalidades y varianzas específicas.

Variable	Ponderac. estimadas		Communalidades	Varianzas Específicas
	F ₁	F ₂		
X ₁	0.56	0.82	0.98	0.02
X ₂	0.78	-0.53	0.88	0.12
X ₃	0.65	0.75	0.98	0.02
X ₄	0.94	-0.11	0.89	0.11
X ₅	0.80	0.93	0.93	0.07
Valores propios	2.85	1.81		
Prop. Acum	0.571	0.932		

➤ Chequeo. Observe que la matriz

$$\tilde{L}\tilde{L}' + \tilde{\Psi} = \begin{bmatrix} 0.56 & 0.82 \\ 0.78 & -0.53 \\ 0.65 & 0.75 \\ 0.94 & -0.10 \\ 0.80 & -0.54 \end{bmatrix} \begin{bmatrix} 0.56 & 0.78 & 0.65 & 0.94 & 0.80 \\ 0.82 & -0.53 & 0.75 & -0.10 & -0.54 \end{bmatrix}$$

$$+ \begin{bmatrix} 0.02 & 0 & 0 & 0 & 0 \\ 0 & 0.12 & 0 & 0 & 0 \\ 0 & 0 & 0.02 & 0 & 0 \\ 0 & 0 & 0 & 0.11 & 0 \\ 0 & 0 & 0 & 0 & 0.07 \end{bmatrix}$$

$$= \begin{bmatrix} 1.00 & 0.10 & 0.97 & 0.44 & 0.00 \\ 0.10 & 1.00 & 0.11 & 0.79 & 0.91 \\ 0.97 & 0.11 & 1.00 & 0.53 & 0.11 \\ 0.44 & 0.79 & 0.53 & 1.00 & 0.81 \\ 0.00 & 0.91 & 0.11 & 0.81 & 1.00 \end{bmatrix}$$

reproduce aproximadamente la matriz de correlación R.

- Por tanto, desde una base puramente descriptiva, el modelo de dos factores anteriores ajusta bien los datos. Las communalidades de 0.98, 0.88, 0.98, 0.89 y 0.93 indican que los dos factores explican un gran porcentaje de la varianza muestral de cada variable.
- La interpretación de los factores está sujeta a buscar una rotación que simplifique la estructura.

Ejemplo. Datos de los rendimientos de las acciones

Considere los n=100 datos de los rendimientos semanales de p=5 acciones, dados anteriormente.

- En ese ejemplo se encontraron las dos primeras componentes principales de la matriz R. Tomando m=1 o m=2, se puede obtener fácilmente soluciones al modelo de factor ortogonal.

- Para $m=1$, $m=2$, las siguiente tablas presentan las estimaciones de las ponderaciones, varianzas específicas y proporción de la varianza total muestral explicada por cada solución.

Solución para $m=1$

Variable	Ponderac. Estimadas	Varianzas
	F_1	Específicas
X_1	0.783	0.39
X_2	0.773	0.40
X_3	0.794	0.37
X_4	0.713	0.49
X_5	0.712	0.49
Prop. Acum	0.571	

Solución para $m=2$

Variable	Ponderac. Estimadas		Varianzas
	F_1	F_2	Específicas
X_1	0.783	-0.217	0.34
X_2	0.773	-0.458	0.19
X_3	0.794	-0.234	0.31
X_4	0.713	0.472	0.27
X_4	0.712	0.524	0.22
Prop. Acum	0.571	0.733	

- Communalidades: por ejemplo, para $m=2$,

$$\tilde{h}_1^2 = \tilde{l}_{11}^2 + \tilde{l}_{12}^2 = (0.783)^2 + (-0.217)^2 = 0.66$$

- Chequeo. La matriz residual correspondiente a la solución $m=2$ es

$$R - \tilde{L}\tilde{L}' - \tilde{\Psi} = \begin{bmatrix} 0 & -0.127 & -0.164 & -0.069 & 0.017 \\ -0.127 & 0 & -0.122 & 0.055 & 0.012 \\ -0.164 & -0.122 & 0 & -0.019 & -0.017 \\ -0.069 & 0.055 & -0.019 & 0 & -0.232 \\ 0.017 & 0.012 & -0.017 & -0.232 & 0 \end{bmatrix}$$

- La proporción de la varianza total explicada por la solución $m=2$ es mucho mayor que la explicada por la solución $m=1$. Sin embargo, para $m=2$, $\tilde{L}\tilde{L}'$ produce números que, son en general, mayores que las correlaciones muestrales (observe r_{45}).
- El primer factor representa las condiciones económicas generales del mercado y puede ser llamado como el *factor del mercado*. Todas las acciones tienen ponderaciones altas sobre este factor y son aproximadamente iguales.

- El segundo factor, contrasta las acciones químicas (con ponderaciones grandes y negativas) con las del petróleo (con ponderaciones grandes y positivas). Como este factor parece diferenciar las acciones de las diferentes industrias, el segundo factor puede ser llamado el *factor industria*.
- **Una Aproximación Modificada – La Solución del Factor Principal.** El procedimiento será descrito en términos de R, pero también es apropiado para S.

Si el modelo de factor

$$\rho = LL' + \Psi$$

está correctamente especificado, los m factores comunes deberían explicar los elementos fuera de la diagonal de ρ , así como también las porciones de communalidad de los elementos de la diagonal,

$$\rho_{ii} = 1 = h_i^2 + \psi_i$$

Si la contribución del factor específico ψ_i se remueve de la diagonal, o equivalentemente

$$\rho_{ii} = h_i^2$$

la matriz resultante es

$$\rho - \Psi = LL'$$

Suponga que se encuentran disponibles valores iniciales ψ_i^* para los factores específicos. Entonces, reemplazando el i-ésimo elemento de la diagonal de R por

$$h_i^{*2} = 1 - \psi_i^*$$

se obtiene una matriz de correlación muestral ‘reducida’

$$R_r = \begin{bmatrix} h_1^{*2} & r_{12} & \cdots & r_{1p} \\ r_{12} & h_2^{*2} & \cdots & r_{2p} \\ \vdots & \vdots & & \vdots \\ r_{1p} & r_{2p} & \cdots & h_p^{*2} \end{bmatrix}$$

Ahora, aparte de la variación muestral, todos los elementos de R_r , deberían ser explicados por los m factores comunes. En particular, R_r es factorizada como

$$R_r \doteq L_r^* L_r^{*'}$$

donde $L_r^* = [l_{ij}^*]$ son las ponderaciones estimadas.

El *método del factor principal* del análisis de factor usa las estimaciones

$$L_r^* = \left[\sqrt{\hat{\lambda}_1^*} e_1^* \sqrt{\hat{\lambda}_1^*} e_2^* \cdots \sqrt{\hat{\lambda}_m^*} e_m^* \right]$$

$$\psi_i^* = 1 - \sum_{j=1}^m l_{ij}^{*2}$$

donde $(\hat{\lambda}_i^*, \hat{e}_i^*)$, $i=1, 2, \dots, m$, son los pares mayores de valores-
vectores propios de R_r .

La re- estimación de las communalidades están dadas por

$$\tilde{h}_i^{*2} = l_{i1}^{*2} + l_{i2}^{*2} + \dots + l_{im}^{*2}$$

La solución del factor principal puede ser obtenida iterativamente, usando las estimaciones anteriores como valores iniciales para la próxima etapa.

En la solución del factor principal, los valores propios estimados $\hat{\lambda}_1^*, \hat{\lambda}_2^*, \dots, \hat{\lambda}_p^*$ ayudan a terminar el número de factores a ser retenidos.

Aparece una nueva complicación y es que ahora algunos de los valores propios pueden ser negativos debido al uso inicial de las communalidades estimadas. Idealmente, el número de factores comunes debería ser tomado igual al rango de la matriz *poblacional* reducida. Desafortunadamente, este rango no

siempre está bien determinado usando R_r , y se necesitan juicios adicionales.

Aunque hay muchas elecciones para los valores iniciales de las varianzas específicas, la más popular es $\psi_i^* = 1/r^{ii}$, donde r^{ii} es el i -ésimo elemento de la diagonal de R^{-1} . Con este valor, la communalidad estimada es

$$h_i^{*2} = 1 - \psi_i^* = 1 - \frac{1}{r^{ii}}$$

Este valor es igual al cuadrado del coeficiente de correlación múltiple entre X_i y las demás $p-1$ variables. Esto significa que h_i^{*2} puede ser calculada aunque R no sea de rango completo.

En la factorización de S , para los valores iniciales de las varianzas específicas se usa s^{ii} , los elementos de la diagonal de S^{-1} . Para otros valores iniciales ver Harmon (1967).

Aunque el método de la componente principal para R puede ser considerado como un método de factor principal con estimaciones iniciales de communalidad de la unidad, o varianzas específicas iguales a cero, los dos métodos son diferentes filosóficamente y geométricamente. En la práctica, si el número de variables es grande y el número de factores es pequeño, los dos métodos producen ponderaciones comparables para los factores.

- **El Método de la Máxima Verosimilitud.** Si los factores comunes F y los factores específicos siguen una distribución normal multivariada, entonces se pueden obtener los estimadores de máxima verosimilitud para las ponderaciones de los factores comunes y para las varianzas específicas.

Cuando F y ε son conjuntamente normales, las observaciones $X_j - \mu = LF_j + \varepsilon_j$ también tienen una distribución normal y la función de verosimilitud es

$$L(\mu, \Sigma) = (2\pi)^{-np/2} |\Sigma|^{-n/2} e^{-\left(\frac{1}{2}\right) \text{tr} \left[\Sigma^{-1} \left(\sum_{j=1}^n (x_j - \bar{x})(x_j - \bar{x})' + n(\bar{x} - \mu)(\bar{x} - \mu)' \right) \right]}$$

$$L(\mu, \Sigma) = (2\pi)^{-\frac{(n-1)p}{2}} |\Sigma|^{-\frac{(n-1)}{2}} e^{-\left(\frac{1}{2}\right) \text{tr} \left[\Sigma^{-1} \left(\sum_{j=1}^n (x_j - \bar{x})(x_j - \bar{x})' \right) \right]}$$

$$\times (2\pi)^{-\frac{p}{2}} |\Sigma|^{-\frac{1}{2}} e^{-\left(\frac{n}{2}\right) (\bar{x} - \mu) \Sigma^{-1} (\bar{x} - \mu)'}$$

La cual depende de L y Ψ a través de $\Sigma = LL' + \Psi$. Este modelo tampoco está bien definido debido a las múltiples elecciones para L por medio de transformaciones ortogonales. Para que L esté bien definida, se impone la restricción de unicidad

$$L' \Psi^{-1} L = \Delta$$

donde Δ es una matriz diagonal.

Los estimadores máximo verosímiles $\hat{L}$ y $\hat{\Psi}$ deben ser obtenidos por medio de maximización numérica de la función de verosimilitud.

- **Solución de Máxima Verosimilitud al Modelo de Factor.** Sea $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$, es una muestra aleatoria de una $N_p(\mu, \Sigma)$, donde $\Sigma = LL' + \Psi$ es la matriz de covarianza para el modelo de m factores comunes. Los estimadores máximo verosímiles $\hat{L}$, $\hat{\Psi}$ y $\hat{\mu} = \bar{X}$ maximizan la función de verosimilitud anterior sujeta a que $\hat{L}' \Psi^{-1} \hat{L}$ sea una matriz diagonal.

Los estimadores máximo verosímiles de las communalidades son

$$\hat{h}_i^2 = \hat{l}_{i1}^2 + \hat{l}_{i2}^2 + \dots + \hat{l}_{im}^2, \text{ para } i=1, 2, \dots, p$$

y

$$\left(\begin{array}{l} \text{Prop. de la} \\ \text{varianza total} \\ \text{muestral debida} \\ \text{al factor j} \end{array} \right) = \frac{\hat{l}_{1j}^2 + \hat{l}_{2j}^2 + \dots + \hat{l}_{pj}^2}{s_{11} + s_{22} + \dots + s_{pp}}$$

• **Solución de Máxima Verosimilitud al Modelo de Factor con variables estandarizadas.**

Si las variables están estandarizadas como $Z = V^{-1/2}(X - \mu)$, entonces la matriz de covarianza ρ de Z se puede representar por

$$\rho = V^{-1/2} \Sigma V^{-1/2} = (V^{-1/2} L)(V^{-1/2} L)' + V^{-1/2} \Psi V^{-1/2}$$

➤ Por tanto, ρ tiene una representación análoga al caso anterior, donde la matriz de las ponderaciones es

$$L_Z = V^{-1/2} L$$

y la matriz de varianzas específicas es

$$\Psi_Z = V^{-1/2} \Psi V^{-1/2}$$

➤ Por la propiedad de invarianza de los estimadores máximo verosímiles, el estimador máximo verosímil de ρ es

$$\hat{\rho} = (\hat{V}^{-1/2} \hat{L})(\hat{V}^{-1/2} \hat{L})' + \hat{V}^{-1/2} \hat{\Psi} \hat{V}^{-1/2}$$

$$= \hat{L}_Z \hat{L}_Z' + \hat{\Psi}_Z$$

donde $\hat{V}^{-1/2}$, $\hat{L}$ son los estimadores máximo verosímiles de $V^{-1/2}$ y L , respectivamente.

- Como consecuencia de la descomposición $\hat{L}_Z \hat{L}_Z' + \hat{\Psi}_Z$, si el análisis de máxima verosimilitud pertenece a la matriz de correlación,

$$\hat{h}_i^2 = \hat{l}_{i1}^2 + \hat{l}_{i2}^2 + \dots + \hat{l}_{im}^2, \quad i=1, 2, \dots, p$$

Son los estimadores máximo verosímiles de las communalidades, donde los elementos $\hat{l}_{ij}$ son los elementos de $\hat{L}_Z$.

- La importancia de los factores se evalúan de acuerdo a

$$\left(\begin{array}{l} \text{Prop. de la} \\ \text{varianza total} \\ \text{muestral debida} \\ \text{al factor } j \end{array} \right) = \frac{\hat{l}_{1j}^2 + \hat{l}_{2j}^2 + \dots + \hat{l}_{pj}^2}{p}$$

Ejemplo.

Análisis de los rendimientos de las acciones usando el método de máxima verosimilitud, suponiendo $m=2$.

La siguiente tabla contiene las estimaciones de las ponderaciones, communalidades, varianzas específicas y proporciones de la varianza total muestral explicada por cada factor, y los resultados vistos antes para estas mismas cantidades, usando el método de la componente principal.

Variable	Maximum likelihood			Principal components		
	Estimated factor loadings		Specific variances $\hat{\psi}_i = 1 - \hat{h}_i^2$	Estimated factor loadings		Specific variances $\tilde{\psi}_i = 1 - \tilde{h}_i^2$
	F_1	F_2		F_1	F_2	
1. Allied Chemical	.684	.189	.50	.783	-.217	.34
2. Du Pont	.694	.517	.25	.773	-.458	.19
3. Union Carbide	.681	.248	.47	.794	-.234	.31
4. Exxon	.621	-.073	.61	.713	.412	.27
5. Texaco	.792	-.442	.18	.712	.524	.22
Cumulative proportion of total (standardized) sample variance explained	.485	.598		.571	.733	

La matriz residual es

$$\mathbf{R} - \hat{\mathbf{L}}\hat{\mathbf{L}}' - \hat{\mathbf{\Psi}} = \begin{bmatrix} 0 & .005 & -.004 & -.024 & -.004 \\ .005 & 0 & -.003 & -.004 & .000 \\ -.004 & -.003 & 0 & .031 & -.004 \\ -.024 & -.004 & .031 & 0 & -.000 \\ -.004 & .000 & -.004 & -.000 & 0 \end{bmatrix}$$

- Los elementos de la matriz residual anterior son mucho menores que los de la matriz residual del método de la componente principal. Sobre esta base, se prefiere la solución de máxima verosimilitud.
- La proporción de la varianza total muestral explicada por el método de la componente principal es mayor que la obtenida por la solución de máxima verosimilitud. Esto no es sorprendente puesto que las ponderaciones obtenidas por ese método están relacionadas con las componentes principales, las cuales tienen, por construcción, una propiedad de varianza óptima.
- Para la solución de máxima verosimilitud, todas las variables tienen grandes ponderaciones positivas sobre el primer factor F_1 . Como en el caso del método de la componente principal, este factor es llamado el *factor de mercado*. Sin embargo, la interpretación del segundo factor no es clara como en el caso de la solución de la componente principal. Los signos de las ponderaciones son consistentes con un contraste, o *factor industria*, pero sus magnitudes son pequeñas en algunos casos, este factor podría ser identificado como una comparación entre Du Pont y Texaco.

➤ Los patrones de las ponderaciones iniciales para la solución de máxima verosimilitud están restringidas por la condición de unicidad de que $L' \Psi^{-1} L = \Delta$, donde Δ es una matriz diagonal. Por tanto, los patrones útiles de los factores no son revelados hasta que los factores sean rotados.

- **Prueba para el Número de Factores.** Si la población es normal, se puede construir una prueba sobre la especificación correcta del modelo.

Suponga que el modelo de m factores es correcto. En este caso $\Sigma = LL' + \Psi$ y probar si el modelo de m factores es adecuado es equivalente a probar

$$H_0: \Sigma_{p \times p} = L_{p \times m} L'_{m \times p} + \Psi_{p \times p}$$

contra $H_1: \Sigma$ es cualquier otra matriz definida positiva

➤ Cuando Σ no tiene una forma especial, es decir bajo H_1 , el estimador de máxima verosimilitud de Σ es $\hat{\Sigma} = \frac{n-1}{n} S$.

La función de verosimilitud maximizada es, aparte de la constante)

$$|S_n|^{-n/2} e^{-np/2}$$

- Cuando H_0 es cierto, es decir bajo H_0 : $\Sigma = LL' + \Psi$, el estimador restringido tiene la forma $\hat{\Sigma} = \hat{L}\hat{L}' + \hat{\Psi}$ y el máximo de la función de verosimilitud es

$$|\hat{\Sigma}|^{-n/2} e^{\left(-\frac{1}{2} \text{tr} \left[\hat{\Sigma}^{-1} \sum_{j=1}^n (x_j - \bar{x})(x_j - \bar{x})' \right] \right)}$$

$$= |\hat{L}\hat{L}' + \hat{\Psi}|^{-n/2} e^{\left(-\frac{1}{2} n \text{tr} \left[(\hat{L}\hat{L}' + \hat{\Psi})^{-1} S_n \right] \right)}$$

- El estadístico del cociente de verosimilitud para la prueba es

$$-2 \ln \Lambda = -2 \ln \frac{\text{max.Func.verosimilitud bajo } H_0}{\text{max.Func.verosimilitud bajo } H_1}$$

$$= -n \ln \left(\frac{|\hat{\Sigma}|}{|S_n|} \right)$$

- Bajo H_0 , el estadístico $-2 \ln \Lambda$ tiene una distribución aproximadamente χ_r^2 , donde los grados de libertad

$$r = \frac{1}{2} \left[(p - m)^2 - p - m \right]$$

- Bartlett (1954) mostró que la aproximación a la distribución chi-cuadrado del estadístico $-2\ln\Lambda$ puede ser mejorada reemplazando n por $(n-1-(2p+4m+5)/6)$.
- Usando estos resultados el estadístico del cociente de verosimilitud para probar H_0 es

$$NF = (n-1-(2p+4m+5)/6) \ln \frac{|\hat{L}\hat{L}' + \hat{\Psi}|}{|S_n|}$$

Bajo H_0 , y cuando n es grande, NF tiene una distribución aproximadamente $\chi^2_{[(p-m)^2 - p - m]/2}$

Regla de decisión: Para n grande y para un nivel de significancia aproximado de tamaño α , rechace H_0 si el valor observado de NF es tal que

$$NF > \chi^2_{[(p-m)^2 - p - m]/2}(\alpha)$$

donde $\chi^2_{[(p-m)^2 - p - m]/2}(\alpha)$ es el percentil α -superior de la distribución $\chi^2_{[(p-m)^2 - p - m]/2}$.

Ejemplo.

La solución de máxima verosimilitud de los datos sobre los rendimientos de las acciones, sugiere, al observar la matriz residual, que una solución de dos factores puede ser adecuada. Se quiere probar la hipótesis $H_0: \Sigma = LL' + \Psi$ con $m=2$ y un nivel de significancia $\alpha=0.05$.

El estadístico de la prueba está basado en

$$\frac{|\hat{\Sigma}|}{|S_n|} = \frac{|\hat{L}\hat{L}' + \hat{\Psi}|}{|S_n|} = \frac{|\hat{L}_Z\hat{L}_Z' + \hat{\Psi}_Z|}{|R|}$$

Empleando los resultados obtenidos antes,

$$\frac{|\hat{L}_Z\hat{L}_Z' + \hat{\Psi}_Z|}{|R|} = \frac{\begin{vmatrix} 1.000 & & & & & \\ .572 & 1.000 & & & & \\ .513 & .602 & 1.000 & & & \\ .411 & .393 & .405 & 1.000 & & \\ .458 & .322 & .430 & .523 & 1.000 & \\ 1.000 & & & & & \\ .577 & 1.000 & & & & \\ .509 & .599 & 1.000 & & & \\ .387 & .389 & .436 & 1.000 & & \\ .462 & .322 & .426 & .523 & 1.000 & \end{vmatrix}}{.193163} = \frac{.194414}{.193163} = 1.0065$$

Usando la aproximación de Bartlett,

$$NF = (n-1-(2p+4m+5)/6) \ln \frac{|\hat{L}\hat{L}' + \hat{\Psi}|}{|S_n|}$$

$$=[100-1-(10+8+5)/6]\ln(1.0065)=0.62$$

Puesto que los grados de libertad de la chi-cuadrado son

$$r = \frac{1}{2}[(p-m)^2 - p - m] = (1/2)[(5-2)^2 - 5 - 2] = 1$$

el percentil 0.05-superior de una chi-cuadrado con 1 grado de libertad es $\chi^2_{(0.05)}=3.84$.

Como $NF=0.62 < 3.84=\chi^2_{(0.05)}$, no podemos rechazar H_0 , y se concluye que los datos no contradicen modelo de dos factores.

4. ROTACIÓN DE FACTORES

- Como se mencionó antes, todas la ponderaciones obtenidas a partir de la solución inicial de las ponderaciones por medio de una transformación ortogonal tienen la misma habilidad para reproducir la matriz de covarianza (o de correlación).
- Del algebra, se sabe que toda transformación ortogonal corresponde a una rotación rígida de los ejes de coordenadas. Por esta razón, toda transformación ortogonal de las ponderaciones de los factores, que igualmente implica una

rotación ortogonal de los factores, es llamada una *rotación de los factores*.

Si $\hat{L}$ es la estimación de matriz de ponderaciones de los factores obtenida por cualquier método, entonces

$$\hat{L}^* = \hat{L}T, \text{ donde } TT' = T'T = I$$

es una matriz de $p \times m$ de las ponderaciones rotadas.

Además, la matriz estimada de covarianza (correlación) permanece inalterada, puesto que,

$$\hat{L}\hat{L}' + \hat{\Psi} = \hat{L}TT'\hat{L}' + \hat{\Psi} = \hat{L}^*\hat{L}^{*'} + \hat{\Psi}$$

Esto implica que la matriz residual, $S_n - \hat{L}\hat{L}' - \hat{\Psi} = S_n - \hat{L}^*\hat{L}^{*'} - \hat{\Psi}$ no cambia.

Además, las varianzas específicas $\hat{\psi}_i$ y $\hat{h}_i^2$ las communalidades, también permanecen iguales.

Puesto que la ponderaciones iniciales pueden no ser fácilmente interpretables, es una práctica usual rotarlas hasta que se logre una estructura ‘más simple’.

Idealmente, se pretende obtener un patrón de ponderaciones tales que cada una de las variables tenga una alta ponderación en un solo factor y tenga ponderaciones pequeñas o moderadas sobre los demás factores. Sin embargo, esto no siempre es posible obtener.

Ejemplo.

Lawley y Maxwell (1971) presentan la matriz de correlación de las notas en $p=6$ materias para $n=220$ estudiantes hombres.

$$\mathbf{R} = \begin{bmatrix} \text{Gaelic} & \text{English} & \text{History} & \text{Arithmetic} & \text{Algebra} & \text{Geometry} \\ 1.0 & .439 & .410 & .288 & .329 & .248 \\ & 1.0 & .351 & .354 & .320 & .329 \\ & & 1.0 & .164 & .190 & .181 \\ & & & 1.0 & .595 & .470 \\ & & & & 1.0 & .464 \\ & & & & & 1.0 \end{bmatrix}$$

La siguiente tabla presenta la solución máximo verosímil para $m=2$ de factores.

Variable	Estimated factor loadings		Communalities
	F_1	F_2	$\hat{h}_i^2$
1. Gaelic	.553	.429	.490
2. English	.568	.288	.406
3. History	.392	.450	.356
4. Arithmetic	.740	-.273	.623
5. Algebra	.724	-.211	.569
6. Geometry	.595	-.132	.372


- Todas las variables tienen ponderaciones positivas en el primer factor. Lawley y Maxwell que este factor refleja la respuesta global de los estudiantes a la instrucción, y podría ser llamado el factor de *inteligencia general*.
- Para el segundo factor, la mitad de las ponderaciones son positivas y la otra mitad negativas. Un factor con este patrón de ponderaciones es llamado un *factor bipolar* (la asignación de polo positivo y negativo es arbitraria puesto que los signos de las ponderaciones sobre el factor pueden ser reversados sin que se afecte el análisis).

La identificación de este factor no es fácil, pero es tal que los individuos que obtienen promedio altos en pruebas verbales también obtiene promedio altos en los scores de

este factor. Individuos con promedios altos en pruebas matemáticas obtiene promedios bajos sobre este factor.

Este factor podrá ser clasificado como un factor “matemática-no matemática”.

- El siguiente gráfico presenta los pares de ponderaciones $(\hat{l}_{i1}, \hat{l}_{i2})$ sobre los dos factores.



Los puntos tienen los números de las respectivas variables.

El gráfico también presenta una rotación en el sentido de las agujas del reloj de los ejes de coordenadas usando un ángulo $\phi \doteq 20^\circ$.

El ángulo fue escogido de forma tal que pasara por el punto $(\hat{l}_{41}, \hat{l}_{42})$. Cuando se hace esta rotación, observe todos los puntos caen en el primer cuadrante (todas las ponderaciones de los factores son positivas), y se revelan más claramente dos diferentes grupos de variables.

$\Rightarrow$ Las variables matemáticas tienen altas ponderaciones sobre F_1^* , pero sus ponderaciones sobre F_2^* son despreciables. Este factor podría ser llamado *factor de habilidad matemática*.

$\Rightarrow$ Las variables verbales tienen altas ponderaciones en F_2^* y ponderaciones moderadas en el factor F_1^* . El segundo factor podría ser llamado *factor de habilidad verbal*.

$\Rightarrow$ El factor de inteligencia general identificado inicialmente, queda sumergido en los factores F_1^* y F_2^* .

➤ La siguiente tabla presenta las estimaciones de ponderaciones y las communalidades para los factores rotados con $\phi \doteq 20^\circ$.

Variable	Estimated rotated factor loadings		Communalities $\hat{h}_i^{*2} = \hat{h}_i^2$
	F_1^*	F_2^*	
1. Gaelic	.369	.594	.490
2. English	.433	.467	.406
3. History	.211	.558	.356
4. Arithmetic	.789	.001	.623
5. Algebra	.752	.054	.568
6. Geometry	.604	.083	.372

Las magnitudes de las ponderaciones rotadas refuerza las interpretaciones sugeridas anteriormente.

Las estimaciones de las communalidades no cambian con la rotación, puesto que $\hat{L}\hat{L}' = \hat{L}T T' \hat{L}' = \hat{L}^* \hat{L}'^*$. Las communalidades son los elementos en la diagonal de estas matrices.

➤ Johnson y Wichern (1998) sugieren una rotación oblicua de las coordenadas.

⇒ Un nuevo eje pasaría a través del grupo (1, 2, 3) y el otro eje a través del grupo (4, 5, 6).

⇒ Para este ejemplo, la interpretación de los factores oblicuos sería muy parecida a la dada para los factores ortogonales.

- Kaiser (1958) sugiere una medida analítica de estructura simple conocida como el *criterio varimax*. Sean $\tilde{l}_{ij}^* = \hat{l}_{ij}^* / \hat{h}_i$ los coeficientes rotados y escalados usando las raíces cuadradas de las communalidades. Entonces, el procedimiento de rotación varimax selecciona una transformación T maximiza a

$$V = \frac{1}{p} \sum_{j=1}^m \left[\sum_{i=1}^p \tilde{l}_{ij}^{*4} - \left(\sum_{i=1}^p \tilde{l}_{ij}^{*2} \right)^2 / p \right]$$

Después de que se determina la transformación T, las ponderaciones $\tilde{l}_{ij}^*$ son multiplicadas por $\hat{h}_i$, lo que preserva las communalidades originales.

Aunque V parece bastante complicado, tiene una interpretación simple. En palabras V se puede describir como

$$V \text{ es proporcional } \sum_{i=1}^m \left(\begin{array}{l} \text{varianza de los cuadrados de las} \\ \text{ponderaciones escaladas del factor } j \end{array} \right)$$

Maximizar a V equivale a dispersar los cuadrados de las ponderaciones sobre cada factor tanto como sea posible. Por tanto, se espera encontrar grupos con ponderaciones grandes y otros con ponderaciones insignificantes, en cualquier columna de la matriz de ponderaciones rotadas $\hat{L}^*$.

Ejemplo.


Considere los datos de mercadeo sobre las preferencias del consumidor. La siguiente tabla presenta las estimaciones de las ponderaciones, communalidades y proporción explicada, usando el método de la componente principal. También se presentan las ponderaciones rotadas usando el procedimiento varimax.

Variable	Estimated factor loadings		Rotated estimated factor loadings		Communalities $\hat{h}_i^2$
	F_1	F_2	F_1^*	F_2^*	
1. Taste	.56	.82	.02	(.99)	.98
2. Good buy for money	.78	-.52	(.94)	-.01	.88
3. Flavor	.65	.75	.13	(.98)	.98
4. Suitable for snack	.94	-.10	(.84)	.43	.89
5. Provides lots of energy	.80	-.54	(.97)	-.02	.93
Cumulative proportion of total (standardized) sample variance explained	.571	.932	.507	.932	

- Es claro que las variables 2, 4 y 5 definen un factor (ponderaciones altas sobre el factor 1 y pequeñas o

despreciables en el factor 2). Este factor podría llamarse el *factor nutricional*.

- Las variables 1 y 3 definen el factor 2 (ponderaciones altas sobre el factor 2 y pequeñas o despreciables en el factor 1). Este factor podría llamarse el *factor del gusto*.
- El siguiente gráfico presenta las ponderaciones de los factores con respecto a los ejes de coordenadas originales y a los ejes rotados.



- La rotación de las ponderaciones es recomendada para el caso de estimación de máxima verosimilitud, puesto que las ponderaciones originales están sujetas a la restricción de

unicidad de que $\hat{L}'\hat{\Psi}^{-1}\hat{L}$ sea una matriz diagonal. Esta condición es conveniente computacionalmente, pero puede producir ponderaciones que no sean fáciles de interpretar.

Ejemplo.

Considere los datos sobre los rendimientos de las acciones de 5 compañías. Suponga un modelo con $m=2$ factores. La siguiente tabla presenta las estimaciones de ponderaciones iniciales y rotadas, así como las estimaciones de las varianzas específicas y las proporciones de varianza total muestral explicada por los factores.

Variable	Maximum likelihood estimates of factor loadings		Rotated estimated factor loadings		Specific variances $\hat{\psi}_i = 1 - \hat{h}_i^2$
	F_1	F_2	F_1^*	F_2^*	
Allied Chemical	.684	.189	.601	.377	.50
Du Pont	.694	.517	.850	.164	.25
Union Carbide	.681	.248	.643	.335	.47
Exxon	.621	-.073	.365	.507	.61
Texaco	.792	-.442	.208	.883	.18
Cumulative proportion of total sample variance explained	.485	.598	.335	.598	

- Anteriormente, usando las ponderaciones no rotadas se identificaron los dos factores como el *factor de mercado* y el *factor de industria*.
- Las ponderaciones rotadas indican que las acciones químicas tienen ponderaciones altas sobre el primer factor, mientras que las acciones petroleras tienen ponderaciones altas sobre el segundo factor.
- Los dos factores rotados, diferencian las industrias. El factor 1 representa aquellas fuerzas únicas de la economía que causan que las acciones químicas se muevan juntas. El factor 2 parece representar las condiciones económicas que afectan las acciones petroleras.
- **Rotaciones Oblicuas.** Las rotaciones ortogonales son apropiadas para un modelo de factor en el cual se asume independencia entre los factores comunes. Muchos investigadores en ciencias sociales consideran tanto rotaciones oblicuas (no ortogonales) como ortogonales. Las primeras son sugeridas después de que se observan las ponderaciones y no siguen un modelo postulado. Sin embargo, frecuentemente una rotación oblicua es una ayuda útil en el análisis de factor.

Si consideramos los m factores como los ejes de coordenadas, el punto con las m coordenadas $(\hat{l}_{i1}, \hat{l}_{i2}, \dots, \hat{l}_{im})$ representa la posición de la i -ésima variable en el *espacio de los factores*. Suponiendo que las variables están agrupadas en *clusters* que no se traslapan, una rotación ortogonal hacia una estructura simple, corresponde a una rotación rígida de los ejes de coordenadas, tales que dichos ejes, después de la rotación, pasan tan cerca como sea posible a los *clusters*.

Una rotación oblicua hacia una estructura simple corresponde a una rotación no rígida del sistema de coordenadas tal que los ejes rotados (ya no perpendiculares) pasan (cercanamente) a través de los clusters. Una rotación oblicua busca expresar cada variable en términos de un número mínimo de factores, preferiblemente un solo factor. Ver Lawley y Maxwell (1971), Harmon (1967).

5. SCORES DE LOS FACTORES

- En el análisis de factor, el interés generalmente se centra en los parámetros del modelo. Sin embargo, los valores estimados de los factores comunes, llamados *scores* de los factores, también pueden ser de utilidad. Estas cantidades son usadas

frecuentemente para propósitos de diagnóstico del modelo y como insumos para análisis posteriores.

Los scores de los factores no son estimaciones de parámetros desconocidos en el sentido usual. En realidad, son estimaciones de los valores para los vectores aleatorios no observables de los factores F_j , $j=1, 2, \dots, m$. Es decir,

$$\hat{f}_j = \text{estimaciones de los valores } f_j \text{ tomados por } F_j$$

A continuación se presentarán dos aproximaciones, que tienen dos elementos en común:

- 1) Tratan las ponderaciones estimadas $\hat{l}_{ij}$ y las varianzas específicas estimadas $\hat{\psi}_i$, como si fueran las verdaderas.
- 2) Usan transformaciones lineales de los datos originales, ya sea centrados o estandarizados. Generalmente, se usan las ponderaciones estimadas rotadas en lugar de las ponderaciones estimadas originales. Las fórmulas dadas a continuación no cambian cuando las ponderaciones no rotadas son sustituidas por las no rotadas.

- **Método de los Mínimos Cuadrados Ponderados.** Suponga que el vector μ , las ponderaciones de los factores L y las varianzas específicas Ψ son conocidas en el modelo de factor

$$X_{px1} - \mu_{px1} = L_{pxm} F_{mx1} + \varepsilon_{px1}$$

El modelo anterior puede ser considerado como un modelo de regresión donde los factores específicos son considerados como los errores. Como la $\text{Var}(\varepsilon_i) = \hat{\psi}_i$, $i=1, 2, \dots, p$, Bartlett (1937), sugirió usar mínimos cuadrados ponderados para estimar los valores de los factores comunes.

La solución es

$$\hat{f} = (L' \Psi^{-1} L)^{-1} L' \Psi^{-1} (X - \mu)$$

Usando las estimaciones $\hat{L}$, $\hat{\Psi}$ y $\hat{\mu} = \bar{x}$, como los verdaderos valores, los scores para el j -ésimo factor son

$$\hat{f}_j = (\hat{L}' \hat{\Psi}^{-1} \hat{L})^{-1} \hat{L}' \hat{\Psi}^{-1} (x_j - \bar{x})$$

Cuando $\hat{L}$, $\hat{\Psi}$ son determinados por máxima verosimilitud, satisfacen la condición de unicidad $\hat{L}' \hat{\Psi}^{-1} \hat{L} = \hat{\Delta}$

- **Scores de los factores obtenidos por Mínimos Cuadrados Ponderados usando estimaciones de Máxima Verosimilitud.**

De lo anterior:

$$\hat{f}_j = (\hat{L}' \hat{\Psi}^{-1} \hat{L})^{-1} \hat{L}' \hat{\Psi}^{-1} (x_j - \bar{x})$$

$$\hat{f}_j = \hat{\Delta}^{-1} \hat{L}' \hat{\Psi}^{-1} (x_j - \bar{x}), j=1, 2, \dots, m$$

Si se usa la matriz de correlación

$$\hat{f}_j = (\hat{L}_z' \hat{\Psi}_z^{-1} \hat{L}_z)^{-1} \hat{L}_z' \hat{\Psi}_z^{-1} z_j$$

$$\hat{f}_j = \hat{\Delta}_z^{-1} \hat{L}_z' \hat{\Psi}_z^{-1} z_j, j=1, 2, \dots, m$$

donde $z_j = D^{-1/2} (x_j - \bar{x})$ y $\hat{\rho} = \hat{L}_z \hat{L}_z' + \hat{\Psi}_z$

Los scores de los factores así generados, tienen media muestral cero y covarianzas muestrales cero.

Observación.

Si las ponderaciones de los factores son calculadas por medio del método de componente principal, se acostumbra generar los

scores de los factores usando el procedimiento de mínimos cuadrados ordinarios (no ponderados). Implícitamente se supone que los $\hat{\psi}_i$ son iguales o aproximadamente iguales. Los scores de los factores son

$$\hat{f}_j = (\hat{L}'\hat{L})^{-1}\hat{L}'(x_j - \bar{x})$$

o,

$$\hat{f}_j = (\hat{L}_z'\hat{L}_z)^{-1}\hat{L}_z'z_j$$

Los scores de los factores así generados, tienen media muestral cero y matriz de covarianza I.

Comparando con el análisis de Componentes Principales, los scores no son más que las m componentes principales evaluadas en x_j .

- **El método de la regresión.** Considerando el modelo de factor original $X - \mu = LF + \varepsilon$, inicialmente tratamos a la matriz de ponderaciones L y a la matriz de varianza específica Ψ como se fueran conocidas.

Cuando los factores comunes F y los factores específicos (o errores) ε tienen una distribución conjunta normal multivariada con vectores de media y matrices de covarianza dadas por

$$E(F)=\mathbf{0}, \quad \text{Cov}(F)=E(FF')=I$$

$$E(\varepsilon)=\mathbf{0}, \quad \text{Cov}(\varepsilon)=E(\varepsilon \varepsilon')=\Psi = \begin{bmatrix} \psi_1 & 0 & \dots & 0 \\ 0 & \psi_2 & \dots & 0 \\ \vdots & & & \\ 0 & 0 & \dots & \psi_p \end{bmatrix}$$

Las combinaciones lineales $X-\mu=LF+\varepsilon$ tienen una distribución $N_p(\mathbf{0}, LL'+\Psi)$.

Además la distribución conjunta de $X-\mu$ y F es $N_{p+m}(\mathbf{0}, \Sigma^*)$, donde

$$\Sigma^* = \begin{bmatrix} \Sigma=LL'+\Psi & L \\ L' & I \end{bmatrix}$$

y $\mathbf{0}$ es un vector de $(m+p) \times 1$ ceros.

Usando estos resultados, la distribución condicional de $F|x$ es normal multivariada con

$$E(F|x)=L' \Sigma^{-1} (x-\mu)=L'(LL'+\Psi)^{-1} (x-\mu)$$

y matriz de covarianza

$$\text{Cov}(F|x)=I-L' \Sigma^{-1} L=I-L'(LL'+\Psi)^{-1} L$$

Las cantidades $L'(LL' + \Psi)^{-1}$ son los coeficientes de una regresión multivariada de los factores sobre las variables. La estimación de estos coeficientes producen scores para los factores que son análogos a las estimaciones de las medias condicionales en el análisis de regresión multivariada.

Por tanto, dado cualquier vector de observaciones x_j , tomando las estimaciones máximo verosímiles $\hat{L}$ y $\hat{\Psi}$ como los verdaderos valores de L y Ψ , el j -ésimo valor del vector de factores está dado por

$$\hat{f}_j = \hat{L}' \hat{\Sigma}^{-1} (x_j - \bar{x}) = \hat{L}' (\hat{L} \hat{L}' + \hat{\Psi})^{-1} (x_j - \bar{x}), \quad j=1, 2, \dots, n$$

Observaciones.

1) El cálculo de $\hat{f}_j$ se puede simplificar usando la siguiente identidad matricial

$$\hat{L}' (\hat{L} \hat{L}' + \hat{\Psi})^{-1} = (I + \hat{L}' \hat{\Psi}^{-1} \hat{L})^{-1} \hat{L}' \hat{\Psi}^{-1}$$

Esta identidad nos permite comparar los scores anteriores con los generados por mínimos cuadrados ponderados.

Sea $\hat{f}_j^R$ los scores generados por el método de la regresión y $\hat{f}_j^{LS}$ los generados por mínimos cuadrados ponderados. Entonces, usando la identidad anterior,

$$\hat{f}_j^{LS} = (\hat{L}' \hat{\Psi}^{-1} \hat{L})^{-1} (I + \hat{L}' \hat{\Psi}^{-1} \hat{L})^{-1} \hat{f}_j^R = (I + (\hat{L}' \hat{\Psi}^{-1} \hat{L})^{-1}) \hat{f}_j^R$$

Para los estimadores máximo verosímiles, $(\hat{L}' \hat{\Psi}^{-1} \hat{L})^{-1} = \hat{\Delta}^{-1}$. Por tanto, si los elementos de esta matriz diagonal son cercanos a cero, el método de la regresión y el de mínimos cuadrados generalizados serán iguales.

2) En un intento por tratar de reducir los efectos de una (posible) determinación incorrecta del número de factores, algunos calculan los scores de los factores reemplazando $\hat{\Sigma} = \hat{L} \hat{L}' + \hat{\Psi}$ por S (la matriz de covarianza muestral original).

3) Si se usan los factores rotados $\hat{L}^* = \hat{L} T$ en lugar de las ponderaciones originales, los scores de los factores $\hat{f}_j^*$ están relacionados con $\hat{f}_j$ por medio de

$$\hat{f}_j^* = T' \hat{f}_j$$

4) Una medida de conciliación entre los dos diferentes procedimientos para calcular los scores está dada por el coeficiente de correlación muestral entre los scores de un mismo

factor. De los métodos presentados, ninguno es uniformemente superior.

Ejemplo.

Considere los datos sobre los rendimientos de las acciones de 5 compañías. Anteriormente, el método de la componente principal produjo las siguientes ponderaciones estimadas.

$$\tilde{L} = \begin{bmatrix} 0.784 & -0.216 \\ 0.773 & -0.458 \\ 0.795 & -0.234 \\ 0.712 & 0.473 \\ 0.712 & 0.524 \end{bmatrix} \quad \text{y} \quad \tilde{L}^* = \tilde{L}T = \begin{bmatrix} 0.746 & 0.323 \\ 0.889 & 0.128 \\ 0.766 & 0.316 \\ 0.258 & 0.815 \\ 0.226 & 0.854 \end{bmatrix}$$

- Para cada factor, tomando las mayores ponderaciones en $\tilde{L}$ y eliminando las ponderaciones más pequeñas, se crean las siguientes combinaciones lineales

$$\hat{f}_1 = x_1 + x_2 + x_3 + x_4 + x_5$$

$$\hat{f}_2 = x_4 + x_5 - x_2$$

Como un resumen de los factores. En la práctica estas variables se estandarizan.

- Si en lugar de usar $\tilde{L}$, se usan las ponderaciones rotadas con el criterio varimax, los scores de los factores serían

$$\hat{f}_1 = x_1 + x_2 + x_3$$

$$\hat{f}_2 = x_4 + x_5$$

- La identificación de ponderaciones grandes y pequeñas es en realidad bastante subjetiva. Se prefieren las combinaciones lineales que tengan sentido en el área de investigación

Observaciones.

- 1) Aunque con frecuencia se supone normalidad multivariada para las variables en un análisis de factor, en realidad es muy difícil justificar este supuesto cuando el número de variables es muy grande. Algunas veces, las transformaciones sobre las variables vistas anteriormente pueden ayudar a aproximar a la normalidad.
- 2) Se deben examinar los gráficos de los scores de los factores antes de usarlos en otros análisis. Los scores de los factores pueden producir toda clase de formas no elípticas, que pueden revelar valores atípicos y la desviación de la normalidad.

6. PERSPECTIVAS Y ESTRATEGIAS PARA EL ANÁLISIS DE FACTOR

Hay muchas decisiones que hay que tomar en cualquier estudio de análisis de factor.

- Probablemente la más importante tiene que ver con el número de factores, m .

Aunque una prueba para muestras grandes de la adecuación del modelo está disponible para un valor m dado, esta es adecuada solamente cuando los datos tienen distribución normal multivariada.

Además la prueba casi seguramente rechazará el modelo para m pequeño si el número de observaciones es grande. Sin embargo, esta es la situación en la que el análisis de factor proporciona una aproximación útil.

Frecuentemente, la elección final de m está basada en la combinación de:

⇒ La proporción de la varianza total muestral explicada.

⇒ Conocimiento de la disciplina.

⇒ La racionalidad de los resultados.

- La elección del método de solución y el tipo de rotación es una decisión menos crucial. En efecto, los análisis de factor más satisfactorios son aquellos en los cuales se realizan rotaciones con más de un método y todos los resultados confirman sustancialmente la misma estructura de factores.

Aunque hasta el presente no existe una estrategia sencilla para la solución del análisis de factor, Jonson y Wichern (1998) sugieren la siguiente:

- *Realice un análisis de factor usando el método de la componente principal.* Este método es particularmente adecuado para un primer análisis de los datos y no requiere que R o S sean no singulares.
- Busque observaciones sospechosas inspeccionando los gráficos de los scores de los factores. Calcule también los scores estandarizados para cada observación, y calcule las distancias cuadráticas generalizadas para evaluar normalidad y detectar observaciones sospechosas.
- Use la rotación varimax.

- *Realice un análisis de factor usando el método de la máxima verosimilitud, incluyendo la rotación varimax.*
- *Compare las soluciones obtenidas por los dos análisis.*
 - Las ponderaciones se agrupan de la misma manera?
 - Grafique los scores obtenidos por medio del método de la componente principal con los scores obtenidos por medio del método de máxima verosimilitud.
- *Repita los tres pasos anteriores para otros números de factores comunes m .*
 - ⇒ Los factores extra contribuyen al entendimiento e interpretación de los datos?
- *Para grandes conjuntos de datos, divídalos a la mitad y realice un análisis de factor sobre cada parte. Compare los resultados de los dos análisis y con el resultado obtenido con los datos completos para verificar la estabilidad de la solución (los datos podrían ser divididos aleatoriamente, o colocando la primera mitad en un grupo, y la segunda mitad en el otro).*

Ejemplo.

Considere las siguientes variables que indican las dimensiones de algunos de los huesos de los pollos. Los $n=276$ datos fueron las mediciones realizadas sobre:

Cabeza: X_1 = longitud del cráneo
 X_2 = amplitud del cráneo

Pierna: X_3 = longitud del fémur
 X_4 = longitud de la tibia

Ala: X_5 = longitud del húmero
 X_6 = longitud del cúbito

La matriz de correlación es

$$\mathbf{R} = \begin{bmatrix} 1.000 & .505 & .569 & .602 & .621 & .603 \\ .505 & 1.000 & .422 & .467 & .482 & .450 \\ .569 & .422 & 1.000 & .926 & .877 & .878 \\ .602 & .467 & .926 & 1.000 & .874 & .894 \\ .621 & .482 & .877 & .874 & 1.000 & .937 \\ .603 & .450 & .878 & .894 & .937 & 1.000 \end{bmatrix}$$

Se emplearon $m=3$ factores y se usaron los métodos de la componente principal y el método de máxima verosimilitud en el análisis. En la siguiente tabla se presentan los resultados.

Principal Component

Variable	Estimated factor loadings			Rotated estimated loadings			$\hat{\psi}_i$
	F_1	F_2	F_3	F_1^*	F_2^*	F_3^*	
1. Skull length	.741	.350	.573	.355	.244	.902	.00
2. Skull breadth	.604	.720	-.340	.235	.949	.211	.00
3. Femur length	.929	-.233	-.075	.921	.164	.218	.08
4. Tibia length	.943	-.175	-.067	.904	.212	.252	.08
5. Humerus length	.948	-.143	-.045	.888	.228	.283	.08
6. Ulna length	.945	-.189	-.047	.908	.192	.264	.07
Cumulative proportion of total (standardized) sample variance explained	.743	.873	.950	.576	.763	.950	

Maximum Likelihood

Variable	Estimated factor loadings			Rotated estimated loadings			$\hat{\psi}_i$
	F_1	F_2	F_3	F_1^*	F_2^*	F_3^*	
1. Skull length	.602	.214	.286	.467	.506	.128	.51
2. Skull breadth	.467	.177	.652	.211	.792	.050	.33
3. Femur length	.926	.145	-.057	.890	.289	.084	.12
4. Tibia length	1.000	.000	-.000	.936	.345	-.073	.00
5. Humerus length	.874	.463	-.012	.831	.362	.396	.02
6. Ulna length	.894	.336	-.039	.857	.325	.272	.09
Cumulative proportion of total (standardized) sample variance explained	.667	.738	.823	.559	.779	.823	

➤ Después de realizar la rotación, los dos métodos parecen dar resultados algo diferentes.

⇒ En el método de la componente principal, la proporción de varianza de la varianza total muestral explicada indica que el tercer factor parece significativo. El primer factor parece ser el *tamaño del cuerpo*, dominando por las dimensiones de las alas y

las piernas. El segundo y tercer factor, conjuntamente, representan la dimensión del cráneo, y podrían ser denominados, como las variables, *longitud del cráneo* y *amplitud del cráneo*.

⇒ Las ponderaciones rotadas producidas por el método de máxima verosimilitud para el primer factor, son consistentes con las generadas por el método de la componente principal, pero no para los factores 2 y 3.


Para el método de máxima verosimilitud, el segundo factor parece representar el tamaño de la cabeza. L significado del tercer factor no está claro, parece que no se necesita.

- Otro soporte para retener tres o menos factores está dado por la matriz residual obtenida por los estimaciones máximo verosímiles:

$$\mathbf{R} - \hat{\mathbf{L}}_z \hat{\mathbf{L}}_z' - \hat{\Psi}_z = \begin{bmatrix} .000 & & & & & \\ -.000 & .000 & & & & \\ -.003 & .001 & .000 & & & \\ .000 & .000 & .000 & .000 & & \\ -.001 & .000 & .000 & .000 & .000 & \\ .004 & -.001 & -.001 & .000 & -.000 & .000 \end{bmatrix}$$

Todos los elementos en la matriz son muy pequeños. Para el ejemplo, continuamos con este modelo con $m=3$.

- El siguiente gráfico presenta los scores para los factores 1 y 2 producidas por el método de la regresión con las estimaciones máximo verosímiles: éste grafico nos permite detectar las observaciones que, por diferentes razones, no son consistentes con las demás. Las observaciones atípicas potenciales aparecen encerradas en círculos.






- También es importante graficar los pares de los scores factores usando los métodos de la componente principal y de máxima verosimilitud.

⇒ Si las ponderaciones sobre un factor concuerdan, los scores deberían agruparse estrechamente alrededor de una recta de 45° que pasa por el origen.

⇒ Si no concuerdan, los scores de los factores producirán patrones que se desvían de este patrón. En este caso, generalmente ocurre que el número de factores es muy grande, es decir, los últimos factores no son significantes.

➤ Los siguientes gráficos de dispersión presentan los pares de scores para los tres factores usando los métodos de la componente principal y de máxima verosimilitud.





Observe que el gráfico (c) se desvía del patrón lineal, sugiriendo que el último factor no parece ser significativo.

- Los gráficos de los pares de scores usando los dos métodos también es útil para detectar observaciones atípicas.

⇒ Si los conjuntos de ponderaciones para un factor tienden a concordar, las observaciones atípicas aparecerán como puntos en las vecindades de la recta de 45° , pero lejos del origen y del grupo de las otras observaciones. El gráfico (b) anterior muestra que una de las 276 observaciones no es consistente con las otras. Es un score inusualmente grande para F_2 . Cuando esta observación es removida, el análisis con los datos restantes muestra que las ponderaciones no se alteran apreciablemente.

- Cuando el conjunto de datos es grande, se puede dividir en dos grupos con el mismo número (aproximado) de observaciones y realizar el análisis en cada uno de ellos. Para el ejemplo, los datos fueron divididos en dos conjuntos con $n_1=137$ y $n_2=139$ observaciones. Las matrices de correlación resultantes son,

$$\mathbf{R}_1 = \begin{bmatrix} 1.000 & & & & & & \\ .696 & 1.000 & & & & & \\ .588 & .540 & 1.000 & & & & \\ .639 & .575 & .901 & 1.000 & & & \\ .694 & .606 & .844 & .835 & 1.000 & & \\ .660 & .584 & .866 & .863 & .931 & 1.000 & \end{bmatrix}$$

$$\mathbf{R}_2 = \begin{bmatrix} 1.000 & & & & & & \\ .366 & 1.000 & & & & & \\ .572 & .352 & 1.000 & & & & \\ .587 & .406 & .950 & 1.000 & & & \\ .587 & .420 & .909 & .911 & 1.000 & & \\ .598 & .386 & .894 & .927 & .940 & 1.000 & \end{bmatrix}$$

➤ La siguiente tabla presenta la solución de la componente principal para cada subconjunto y $m=3$.

	First set ($n_1 = 137$ observations) Rotated estimated factor loadings				Second set ($n_2 = 139$ observations) Rotated estimated factor loadings			
Variable	F_1^*	F_2^*	F_3^*	$\tilde{\psi}_i$	F_1^*	F_2^*	F_3^*	$\tilde{\psi}_i$
1. Skull length	.360	.361	.853	.01	.352	.921	.167	.00
2. Skull breadth	.303	.899	.312	.00	.203	.145	.968	.00
3. Femur length	.914	.238	.175	.08	.930	.239	.130	.06
4. Tibia length	.877	.270	.242	.10	.925	.248	.187	.05
5. Humerus length	.830	.247	.395	.11	.912	.252	.208	.06
6. Ulna length	.871	.231	.332	.08	.914	.272	.168	.06
Cumulative proportion of total (standardized) sample variance explained	.546	.743	.940		.593	.780	.962	

Los resultados para los dos grupos son muy similares.

⇒ Los factores F_2^* y F_3^* se intercambian con respecto a sus nombres, longitud del cráneo y amplitud del cráneo, pero colectivamente parecen representar *el tamaño de la cabeza*.

⇒ El primer factor F_1^* , de nuevo parece ser *el tamaño del cuerpo*, dominado por las dimensiones de las piernas y de las alas. Estas son las mismas interpretaciones obtenidas antes por el método de la componente principal para los datos completos.

⇒ La solución es notablemente estable, y podemos tener bastante confianza de que las ponderaciones grandes sean “reales”.

⇒ Para estos datos, seguramente es mejor un modelo de un factor o de dos factores.

El análisis de factor tiene un gran atractivo para las ciencias del comportamiento y sociales. En estas áreas, es natural considerar las observaciones multivariadas sobre los procesos animales y humanos como manifestaciones de “atributos” subyacentes no observables. El análisis de factor proporciona una manera de explicar la variabilidad observada en el comportamiento, en términos de estos “atributos”.

Empleo del programa R

```
# lectura de los datos desde un archivo de texto
stock<-read.table("c:/unal/datos/j-wdata/t8_3.txt", header = TRUE)
list(stock)
attach(stock)

# obtención de matriz de correlación
cormat=cor(stock)
cormat

# obtención del análisis de factores por el método de la componente principal
# usando la matriz de correlación

pcfactor<-function (xmat, factors=NULL, cor=TRUE) {

  prc <- princomp ( covmat = xmat ,cor = cor )
  eig <- prc$sdev^2

  if (is.null(factors)) factors <- sum ( eig >= 1 )

  loadings <- prc$loadings [ , 1:factors ]

  coefficients <- loadings [ , 1:factors ] %*% diag ( prc$sdev[1:factors] )

  rotated <- varimax ( coefficients ) $ loadings

  fct.ss <- apply( rotated, 2 , function (x) sum (x^2) )
  pct.ss <- fct.ss / sum (eig)
  cum.ss <- cumsum ( pct.ss )
  ss <- t ( cbind ( fct.ss , pct.ss, cum.ss ) )

  return ( coefficients , rotated , ss )

}

factor_out <- pcfactor(cormat, 2, TRUE); factor_out

# obtención del análisis de factores por el método de máxima verosimilitud
# usando la matriz de correlación

mvfactor<-factanal(cormat, factors=2, rotation="none",
  scores = c("regression"))
print(mvfactor, digits=2, cutoff=.3, sort=TRUE)

mvfactor<-factanal(stock, factors=2, rotation="varimax",
  scores = c("regression"),)
print(mvfactor, digits=2, cutoff=.3, sort=TRUE)
load <- mvfactor$loadings
```

```
plot(load,type="n") # plot factor 1 by 2  
text(load,labels=names(stock),cex=.7) # add variable names
```